

4

4 Teorema de Pitágoras

Sean $X, Y \in L^2(\Omega_n, \mathcal{P}(\Omega_n), P_n)$ y sea $\sigma(X)$ el conjunto de funciones que son constantes sobre los bloques inducidos por la función X sobre Ω_n .

Hemos caracterizado $E(Y | \sigma(X))$ usando el Teorema de la Proyección, lo que nos permitió escribir la siguiente descomposición:

$$Y = E(Y | \sigma(X)) + [Y - E(Y | \sigma(X))],$$

de donde se sigue que

$$\|Y\|^2 = \|E(Y | \sigma(X))\|^2 + \|Y - E(Y | \sigma(X))\|^2$$

donde $\|\cdot\|$ es la norma definida en $L^2(\Omega_n, \mathcal{P}(\Omega_n), P_n)$.

1. Demuestre que

$$E(Y - E(Y | \sigma(X))) = 0$$

1. Demuestre que la descomposición (1) es equivalente a

$$\text{Var}(Y) = \text{Var}[E(Y | \sigma(X))] + \text{Var}[Y - E(Y | \sigma(X))]$$

1. Usando la descomposición (1) hemos definido

$$r_n^2 = \frac{\|E(Y | \sigma(X))\|^2}{\|Y\|^2}$$

Usando (2) se define

$$R^2 = \frac{\text{Var}(E(Y | \sigma(X)))}{\text{Var}(Y)}.$$

Compare R^2 y r_n^2 , ya sea por medio de un ejemplo particular o por un argumento general.

Solución

Preliminares y notación

Antes de demostrar nada, fijemos con cuidado el marco y la notación, porque cada paso posterior se apoya en estos hechos.

- El espacio $L^2(\Omega_n, \mathcal{P}(\Omega_n), P_n)$ es un espacio de Hilbert con el **producto interno**

$$\langle U, V \rangle = E(UV),$$

y la **norma asociada**

$$\|U\|^2 = \langle U, U \rangle = E(U^2).$$

Esto es exactamente la norma mencionada en el enunciado; la usaremos sin volver a justificarla.

- Para abreviar escribimos la **proyección** y el **residuo**:

$$\hat{Y} := E(Y \mid \sigma(X)), \quad Z := Y - \hat{Y}.$$

Con esta notación, la descomposición (1) del enunciado es simplemente $Y = \hat{Y} + Z$.

- $\sigma(X)$ es el subespacio de L^2 formado por las funciones que son **constantes sobre los bloques** (átomos) inducidos por X . Es un subespacio cerrado, y $\hat{Y}$ es la proyección ortogonal de Y sobre él.
- **Teorema de la proyección.** Por ser $\hat{Y}$ la proyección ortogonal de Y sobre $\sigma(X)$, el residuo es ortogonal a *todo* el subespacio:

$$\langle Z, W \rangle = 0 \quad \text{para todo } W \in \sigma(X).$$

Este es el hecho central del que partimos (es lo que ya se usó para obtener (1)).

- **Las constantes están en $\sigma(X)$.** La función idénticamente igual a 1, que denotamos $\mathbf{1}$, es constante sobre cada bloque (vale 1 en todos ellos), de modo que $\mathbf{1} \in \sigma(X)$. Este detalle, aparentemente trivial, es justo lo que necesita la Parte 1.

Parte 1 — Demostrar que $E(Y - E(Y | \sigma(X))) = 0$

Queremos probar que el residuo tiene esperanza nula, es decir, $E(Z) = 0$.

Paso 1. Como observamos en los preliminares, $\mathbf{1} \in \sigma(X)$.

Paso 2. Aplicamos el Teorema de la proyección tomando $W = \mathbf{1}$. Como Z es ortogonal a todo elemento de $\sigma(X)$, en particular es ortogonal a $\mathbf{1}$:

$$\langle Z, \mathbf{1} \rangle = 0.$$

Paso 3. Calculamos explícitamente ese producto interno usando su definición $\langle U, V \rangle = E(UV)$:

$$\langle Z, \mathbf{1} \rangle = E(Z \cdot \mathbf{1}) = E(Z).$$

Paso 4. Combinando los pasos 2 y 3 obtenemos $E(Z) = 0$, es decir,

$$E(Y - E(Y | \sigma(X))) = 0. \quad \blacksquare$$

Consecuencia que usaremos en la Parte 2. Como $Z = Y - \hat{Y}$ y la esperanza es lineal,

$$0 = E(Z) = E(Y) - E(\hat{Y}) \implies E(\hat{Y}) = E(Y).$$

Introducimos el nombre $\mu := E(Y) = E(\hat{Y})$. (Nótese que $E(Z) = 0$ es precisamente la propiedad de insesgamiento de la esperanza condicional.)

Parte 2 — La descomposición (1) equivale a la descomposición de varianzas (2)

Recordemos primero la identidad básica que vincula segundo momento y varianza para cualquier variable $U \in L^2$:

$$\text{Var}(U) = E(U^2) - [E(U)]^2.$$

La aplicamos a las tres variables que aparecen, usando lo obtenido en la Parte 1.

Paso 1 — Esperanzas de cada término. De la Parte 1 sabemos:

$$E(Y) = \mu, \quad E(\hat{Y}) = \mu, \quad E(Z) = 0.$$

Paso 2 — Varianza de cada término. Sustituyendo en la identidad anterior:

$$\text{Var}(Y) = E(Y^2) - \mu^2,$$

$$\text{Var}(\hat{Y}) = E(\hat{Y}^2) - \mu^2,$$

$$\text{Var}(Z) = E(Z^2) - 0^2 = E(Z^2).$$

Observemos que en términos de norma esto es $\text{Var}(Y) = \|Y\|^2 - \mu^2$, $\text{Var}(\hat{Y}) = \|\hat{Y}\|^2 - \mu^2$ y $\text{Var}(Z) = \|Z\|^2$.

Paso 3 — De (1) a (2). La descomposición (1) (el Teorema de Pitágoras en norma) afirma

$$E(Y^2) = E(\hat{Y}^2) + E(Z^2).$$

Restamos μ^2 a ambos lados. Esto es lícito (es la misma cantidad en ambos lados) y no altera la igualdad:

$$E(Y^2) - \mu^2 = E(\hat{Y}^2) + E(Z^2) - \mu^2.$$

Agrupamos el $-\mu^2$ con el primer término del lado derecho (no con el segundo; esto es deliberado, porque $\text{Var}(\hat{Y})$ es quien lleva el μ^2 y $\text{Var}(Z)$ no):

$$\underbrace{E(Y^2) - \mu^2}_{= \text{Var}(Y)} = \underbrace{\left(E(\hat{Y}^2) - \mu^2\right)}_{= \text{Var}(\hat{Y})} + \underbrace{E(Z^2)}_{= \text{Var}(Z)}.$$

Usando las igualdades del Paso 2, esto es exactamente

$$\text{Var}(Y) = \text{Var} [E(Y | \sigma(X))] + \text{Var} [Y - E(Y | \sigma(X))],$$

que es la descomposición (2).

Paso 4 — De (2) a (1) (la otra implicación). El paso clave fue "restar μ^2 ", una operación **reversible**: si partimos de (2) y sumamos μ^2 a ambos lados, recorremos el Paso 3 al revés y recuperamos $E(Y^2) = E(\hat{Y}^2) + E(Z^2)$, es decir, (1).

Como cada descomposición se obtiene de la otra mediante una operación reversible, **(1) y (2) son equivalentes.** ■

Comentario: la equivalencia descansa por completo en la Parte 1. Es porque $E(Z) = 0$ y $E(\hat{Y}) = E(Y)$ que el ajuste por la media ($-\mu^2$) es común y se puede pasar limpiamente del segundo momento a la varianza.

Parte 3 — Comparación de R^2 y r_n^2

Paso 1 — Escribir ambos cocientes con la misma notación. Definamos

$$a := \|\hat{Y}\|^2 = E(\hat{Y}^2), \quad b := \|Y\|^2 = E(Y^2).$$

Entonces, por definición,

$$r_n^2 = \frac{\|E(Y | \sigma(X))\|^2}{\|Y\|^2} = \frac{a}{b},$$

y, usando el Paso 2 de la Parte 2,

$$R^2 = \frac{\text{Var}(\hat{Y})}{\text{Var}(Y)} = \frac{a - \mu^2}{b - \mu^2}.$$

La única diferencia entre ambos es que en R^2 se resta μ^2 en numerador y denominador. Por eso r_n^2 usa **segundos momentos crudos** (respecto al origen) y R^2 usa **varianzas** (segundos momentos centrados en la media).

Paso 2 — Desigualdades básicas entre μ^2 , a y b . Necesitamos ordenar estas cantidades antes de comparar los cocientes.

- De la descomposición (1), $b = a + E(Z^2)$ con $E(Z^2) \geq 0$, luego

$$a \leq b.$$

- Por la desigualdad de Jensen (equivalentemente, $\text{Var}(\hat{Y}) \geq 0$), $a = E(\hat{Y}^2) \geq [E(\hat{Y})]^2 = \mu^2$, luego

$$\mu^2 \leq a \leq b.$$

Supondremos además $\text{Var}(Y) > 0$ (es decir $b > \mu^2$), pues de lo contrario R^2 no está definido (no hay varianza que explicar).

Paso 3 — Comparar los cocientes. Afirmamos que $R^2 \leq r_n^2$. Como ambos denominadores b y $b - \mu^2$ son positivos, podemos comparar mediante producto cruzado sin cambiar el sentido de la desigualdad:

$$R^2 \leq r_n^2 \iff (a - \mu^2) b \leq a (b - \mu^2).$$

Desarrollamos ambos lados:

$$ab - \mu^2 b \leq ab - \mu^2 a.$$

Cancelamos ab y multiplicamos por -1 (lo que invierte la desigualdad):

$$-\mu^2 b \leq -\mu^2 a \iff \mu^2 a \leq \mu^2 b,$$

que es cierta porque $\mu^2 \geq 0$ y $a \leq b$ (Paso 2). Por lo tanto

$$\boxed{R^2 \leq r_n^2}.$$

Paso 4 — Casos de igualdad. Repasando la cadena, la igualdad $R^2 = r_n^2$ ocurre exactamente cuando $\mu^2(b - a) = 0$, es decir:

- $\mu = E(Y) = 0$ (la variable Y ya está centrada), o
- $a = b$, esto es $E(Z^2) = 0$, lo que significa $Y = \hat{Y}$ casi seguramente (la proyección es perfecta y ambos cocientes valen 1).

Interpretación. R^2 es el genuino **coeficiente de determinación**: la proporción de la *varianza* de Y explicada por $\sigma(X)$, y es invariante ante traslaciones del origen. En cambio r_n^2 compara *segundos momentos crudos*, por lo que incorpora la componente de la media y **sobrestima** el ajuste: siempre $r_n^2 \geq R^2$, y la diferencia crece cuando $|\mu|$ es grande frente a la dispersión.

Ejemplo particular concreto

Tomemos $\Omega_n = \{1, 2, 3, 4\}$ con P_n uniforme (probabilidad $1/4$ en cada punto). Supongamos que X induce dos bloques: $B_1 = \{1, 2\}$ y $B_2 = \{3, 4\}$. Definimos

$$Y(1) = 0, Y(2) = 2, Y(3) = 2, Y(4) = 4.$$

Proyección $\hat{Y}$ (media por bloque). Como $\hat{Y}$ es constante en cada bloque e igual al promedio de Y sobre él:

$$\hat{Y}|_{B_1} = \frac{0+2}{2} = 1, \quad \hat{Y}|_{B_2} = \frac{2+4}{2} = 3.$$

Esperanzas.

$$\mu = E(Y) = \frac{0+2+2+4}{4} = 2, \quad E(\hat{Y}) = \frac{1+1+3+3}{4} = 2. \checkmark$$

Segundos momentos.

$$b = E(Y^2) = \frac{0+4+4+16}{4} = 6, \quad a = E(\hat{Y}^2) = \frac{1+1+9+9}{4} = 5.$$

Varianzas.

$$\text{Var}(Y) = b - \mu^2 = 6 - 4 = 2, \quad \text{Var}(\hat{Y}) = a - \mu^2 = 5 - 4 = 1.$$

El residuo $Z = Y - \hat{Y}$ toma los valores $-1, 1, -1, 1$, de modo que $E(Z) = 0$ y $\text{Var}(Z) = E(Z^2) = \frac{1+1+1+1}{4} = 1$. Se verifica la descomposición (2): $\text{Var}(Y) = 2 = 1 + 1 = \text{Var}(\hat{Y}) + \text{Var}(Z)$. ✓

Los dos cocientes.

$$r_n^2 = \frac{a}{b} = \frac{5}{6} \approx 0,833, \quad R^2 = \frac{a - \mu^2}{b - \mu^2} = \frac{1}{2} = 0,5.$$

Efectivamente $R^2 = 0,5 < 0,833 \approx r_n^2$, como predice el argumento general. Con los **mismos datos**, r_n^2 sugiere un "ajuste" mucho mayor que R^2 solo porque no descuenta la media $\mu = 2$.