

5

5 Esperanza condicional

Sea $(H, (\cdot, \cdot))$ un espacio de Hilbert y sea $M \subset H$ un subespacio lineal cerrado.

1. Sea $x \in H$ cualquiera. Sabemos que existe un único $y_0 \in M$ tal que la distancia más pequeña entre x y M está dada por $\|x - y_0\|$. A partir de este resultado, ¿cómo se construye el operador $P : H \rightarrow M$ tal que $Px = y_0$, de modo que P sea efectivamente una proyección ortogonal de x sobre M ?
2. ¿Por qué podemos interpretar la proyección ortogonal de x sobre M como la esperanza condicional de x dado M ?
3. Demuestre, usando el Teorema de la Proyección, que

$$E[E(Y \mid \sigma(X))] = E(Y)$$

donde $X, Y \in L^2(\Omega_n, \mathcal{P}(\Omega_n), P_n)$ y $\sigma(X)$ es el conjunto de funciones que son constantes sobre los bloques inducidos por X .

Solución

Trabajaremos con escalares reales (el caso complejo es completamente análogo; donde haga falta lo comentaremos). Antes de empezar fijamos una herramienta que usaremos varias veces.

Identidad de Pitágoras. Si $u \perp v$ (es decir $(u, v) = 0$), entonces

$$\|u + v\|^2 = \|u\|^2 + 2(u, v) + \|v\|^2 = \|u\|^2 + \|v\|^2.$$

Comentario: el término cruzado $2(u, v)$ desaparece *únicamente* porque supusimos ortogonalidad; este es el único paso donde se usa esa hipótesis.

Parte 1. Construcción de P y prueba de que es proyección ortogonal

Paso 1 — Definición del operador

El dato de partida es: para cada $x \in H$ existe un **único** $y_0 \in M$ tal que

$$\|x - y_0\| = \inf_{y \in M} \|x - y\|.$$

Definimos entonces $Px := y_0$. Comentario: para que esto sea una *función* bien definida necesitamos que a cada x le corresponda un solo valor, y eso es exactamente la unicidad que nos dan. Así $P : H \rightarrow M$ está bien definido.

Paso 2 — Caracterización por ortogonalidad (lema clave)

Afirmamos: para $y_0 \in M$,

$$y_0 \text{ minimiza } \|x - y\| \text{ sobre } M \iff (x - y_0) \perp M.$$

Comentario: esta equivalencia es el corazón de todo; una vez establecida, la linealidad, idempotencia y simetría salen casi solas. La probamos en las dos direcciones.

($\Leftarrow$) Si $x - y_0 \perp M$, entonces y_0 minimiza. Sea $y \in M$ cualquiera. Como M es subespacio y $y_0, y \in M$, se tiene $y_0 - y \in M$, y por hipótesis $x - y_0$ es ortogonal a todo elemento de M , en particular $(x - y_0) \perp (y_0 - y)$. Escribimos

$$x - y = (x - y_0) + (y_0 - y),$$

y aplicamos Pitágoras (válido porque los dos sumandos son ortogonales):

$$\|x - y\|^2 = \|x - y_0\|^2 + \|y_0 - y\|^2 \geq \|x - y_0\|^2.$$

Comentario: $\|y_0 - y\|^2 \geq 0$ siempre, con igualdad solo si $y = y_0$. Por lo tanto y_0 alcanza el mínimo (y es el único que lo hace).

($\Rightarrow$) Si y_0 minimiza, entonces $x - y_0 \perp M$. Fijemos $m \in M$ arbitrario y $t \in \mathbb{R}$. Como M es subespacio, $y_0 + tm \in M$, de modo que la función

$$\varphi(t) = \|x - (y_0 + tm)\|^2 = \|x - y_0\|^2 - 2t(x - y_0, m) + t^2\|m\|^2$$

alcanza su mínimo en $t = 0$ (porque y_0 es el minimizador y $t = 0$ corresponde a y_0). Comentario: φ es un polinomio de grado ≤ 2 en t , por lo tanto derivable, así que en un mínimo interior su derivada se anula. Como

$$\varphi'(t) = -2(x - y_0, m) + 2t\|m\|^2, \quad \varphi'(0) = -2(x - y_0, m),$$

la condición $\varphi'(0) = 0$ da $(x - y_0, m) = 0$. Como $m \in M$ era arbitrario, concluimos $x - y_0 \perp M$. Comentario (caso complejo): se repite el argumento reemplazando m por im para anular también la parte imaginaria de $(x - y_0, m)$.

Paso 3 — P es lineal

Sean $x_1, x_2 \in H$ y escalares a, b . Pongamos $y_1 = Px_1$, $y_2 = Px_2$. Por el Paso 2, $x_1 - y_1 \perp M$ y $x_2 - y_2 \perp M$. Consideremos el candidato $z := ay_1 + by_2$, que pertenece a M por ser este subespacio. Entonces

$$(ax_1 + bx_2) - z = a(x_1 - y_1) + b(x_2 - y_2).$$

Para cualquier $m \in M$,

$$((ax_1 + bx_2) - z, m) = a(x_1 - y_1, m) + b(x_2 - y_2, m) = 0,$$

así que $(ax_1 + bx_2) - z \perp M$ con $z \in M$. Comentario: por el Paso 2 (dirección $\Leftarrow$) esto significa que z es el minimizador de la distancia de $ax_1 + bx_2$ a M , y por la unicidad del Paso 1 ese minimizador es justamente $P(ax_1 + bx_2)$. Por lo tanto

$$P(ax_1 + bx_2) = z = aPx_1 + bPx_2.$$

Paso 4 — P fija a M y es idempotente

Si $x \in M$, entonces $\|x - x\| = 0$ es la menor distancia posible y $x \in M$, luego el minimizador es $y_0 = x$, es decir $Px = x$. Comentario: en palabras, P restringido a M es la identidad. Ahora, para $x \in H$ cualquiera, $Px \in M$ por definición, de modo que aplicar P de nuevo lo deja fijo:

$$P(Px) = Px \implies P^2 = P.$$

Además la imagen de P es exactamente M .

Paso 5 — P es autoadjunto

Sean $x, z \in H$. Como $z - Pz \perp M$ y $Px \in M$, se tiene $(Px, z - Pz) = 0$, esto es

$$(Px, z) = (Px, Pz).$$

De forma simétrica, como $x - Px \perp M$ y $Pz \in M$, $(x - Px, Pz) = 0$, esto es

$$(x, Pz) = (Px, Pz).$$

Comparando ambas igualdades (los lados derechos coinciden):

$$(Px, z) = (x, Pz).$$

Comentario: junto con $P^2 = P$ del Paso 4, esto dice que P es una proyección **ortogonal** (idempotente y autoadjunta).

Paso 6 — P es una contracción y $H = M \oplus M^\perp$

Para todo x descomponemos $x = Px + (x - Px)$, con $Px \in M$ y $x - Px \perp M$. Por Pitágoras,

$$\|x\|^2 = \|Px\|^2 + \|x - Px\|^2 \geq \|Px\|^2,$$

de donde $\|Px\| \leq \|x\|$, es decir $\|P\| \leq 1$. Comentario: además $Px = 0$ equivale a $x = x - Px \perp M$, o sea $x \in M^\perp$; así el núcleo de P es $M^\perp$ y obtenemos la descomposición ortogonal

$$H = M \oplus M^\perp.$$

Conclusión de la Parte 1. P está bien definido, es lineal, idempotente, autoadjunto y de norma ≤ 1 : es la proyección ortogonal de H sobre M .

Parte 2. Por qué la proyección ortogonal es la esperanza condicional

Comentario: la idea es reconocer un espacio de Hilbert *probabilístico* y un subespacio cerrado adecuado, y verificar que la condición que define a la esperanza condicional es exactamente la condición de ortogonalidad del Paso 2.

El espacio de Hilbert. Sea $(\Omega, \mathcal{F}, P)$ un espacio de probabilidad y $H = L^2(\Omega, \mathcal{F}, P)$ el espacio de variables aleatorias de cuadrado integrable, con producto interno

$$(X, Y) = E[XY].$$

Este es un espacio de Hilbert (es completo). Comentario: la norma $\|X\|^2 = E[X^2]$ mide el error cuadrático medio, lo que dará la interpretación de "mejor predicción".

El subespacio. Sea $\mathcal{G} \subseteq \mathcal{F}$ una sub- σ -álgebra y

$$M = L^2(\Omega, \mathcal{G}, P)$$

el conjunto de variables $\mathcal{G}$ -medibles de cuadrado integrable. Es un subespacio lineal (combinaciones lineales de $\mathcal{G}$ -medibles son $\mathcal{G}$ -medibles) y cerrado en L^2 . Comentario: que sea cerrado es lo que permite invocar el Teorema de la Proyección de la Parte 1.

La definición coincide con la proyección. La esperanza condicional $E[X | \mathcal{G}]$ se define como la (única, salvo casi seguramente) variable Z que es $\mathcal{G}$ -medible y satisface

$$E[(X - Z)W] = 0 \quad \text{para toda } W \in M.$$

Pero $E[(X - Z)W] = (X - Z, W)$, así que esa condición dice precisamente que $Z \in M$ y $X - Z \perp M$. Por el Paso 2, esto caracteriza exactamente a $Z = PX$, la proyección ortogonal de X sobre M . Por lo tanto

$$E[X | \mathcal{G}] = PX = \text{proyección ortogonal de } X \text{ sobre } M.$$

Interpretación de mejor predicción. Por el Paso 1, PX minimiza $\|X - Z\|^2 = E[(X - Z)^2]$ sobre $Z \in M$. Es decir, $E[X | \mathcal{G}]$ es la variable $\mathcal{G}$ -medible que mejor aproxima a X en media cuadrática: la mejor predicción de X usando solo la información de $\mathcal{G}$.

Parte 3. Demostración de $E[E(Y | \sigma(X))] = E(Y)$

Paso 1 — Concretar el espacio y el subespacio

Aquí Ω_n es un conjunto **finito**, $\mathcal{P}(\Omega_n)$ es su conjunto potencia y P_n una probabilidad sobre él. Como Ω_n es finito, toda función real sobre Ω_n es de cuadrado integrable, así que

$$H = L^2(\Omega_n, \mathcal{P}(\Omega_n), P_n) = \{U : \Omega_n \rightarrow \mathbb{R}\}, \quad (U, V) = E[UV] = \sum_{\omega \in \Omega_n} U(\omega)V(\omega) P_n(\{\omega\}).$$

La variable X induce una partición de Ω_n en sus conjuntos de nivel (bloques) $B_1, \dots, B_k$, donde $B_j = \{\omega : X(\omega) = x_j\}$. El subespacio es

$$M = \sigma(X) = \{U : U \text{ es constante en cada bloque } B_j\}.$$

Comentario: M es lineal (suma y múltiplo de funciones constantes por bloque siguen siendo constantes por bloque) y es cerrado por ser de dimensión finita ($\dim M = k$). Así se cumplen las hipótesis del Teorema de la Proyección.

Paso 2 — Observación clave: la función constante 1 está en M

Sea $\mathbf{1}$ la función con $\mathbf{1}(\omega) = 1$ para todo ω . Es constante sobre cada bloque (vale 1 en todos), luego

$$\mathbf{1} \in M.$$

Comentario: esta pertenencia es lo único "especial" que necesitaremos, porque la esperanza de cualquier variable se escribe como un producto interno contra $\mathbf{1}$: para todo $Z \in H$,

$$E[Z] = \sum_{\omega} Z(\omega) P_n(\{\omega\}) = (Z, \mathbf{1}).$$

Paso 3 — Aplicar el Teorema de la Proyección

Por la Parte 2, $\hat{Y} := E[Y \mid \sigma(X)]$ es la proyección ortogonal de Y sobre M . Por el Teorema de la Proyección (Paso 2 de la Parte 1),

$$Y - \hat{Y} \perp M, \quad \text{es decir} \quad (Y - \hat{Y}, m) = 0 \text{ para todo } m \in M.$$

Paso 4 — Conclusión

Usando el Paso 2 (la esperanza es producto interno contra $\mathbf{1}$) y la linealidad del producto interno,

$$E[Y] - E[\hat{Y}] = (Y, \mathbf{1}) - (\hat{Y}, \mathbf{1}) = (Y - \hat{Y}, \mathbf{1}).$$

Comentario: aquí está el punto decisivo. Como $\mathbf{1} \in M$ (Paso 2) y $Y - \hat{Y} \perp M$ (Paso 3), ese producto interno se anula:

$$(Y - \hat{Y}, \mathbf{1}) = 0.$$

Por lo tanto $E[\hat{Y}] = E[Y]$, es decir

$$E[E(Y \mid \sigma(X))] = E(Y). \quad \blacksquare$$

Verificación explícita (opcional)

Comentario: para corroborar, calculemos $\hat{Y}$ de forma directa. Como $\hat{Y}$ es constante en cada bloque B_j y $Y - \hat{Y} \perp M$, tomando como m la indicadora $\mathbf{1}_{B_j} \in M$ se obtiene $E[(Y - \hat{Y})\mathbf{1}_{B_j}] = 0$, de donde el valor de $\hat{Y}$ en B_j es el promedio

$$\hat{Y}|_{B_j} = \frac{1}{P_n(B_j)} \sum_{\omega \in B_j} Y(\omega) P_n(\{\omega\}) = E[Y \mid B_j].$$

Entonces

$$E[\hat{Y}] = \sum_j P_n(B_j) E[Y \mid B_j] = \sum_j \sum_{\omega \in B_j} Y(\omega) P_n(\{\omega\}) = \sum_{\omega \in \Omega_n} Y(\omega) P_n(\{\omega\}) = E[Y],$$

que es la ley de la esperanza total y confirma el resultado.