



7 El término de error

Contraste las dos miradas del término de error, una debida a Gauss y la otra basada en el Teorema de la Proyección. Enfatique el estilo de análisis estadístico y el desarrollo metodológico que cada una de estas perspectivas implica.

0. Punto de partida común: fijar el objeto del que vamos a hablar

Antes de contrastar las dos miradas conviene fijar el escenario, porque ambas hablan del *mismo* objeto formal pero le atribuyen significados distintos. Comento esto explícitamente para no dar por sentado que "el término de error" significa lo mismo en las dos perspectivas: no lo significa, y ese es justamente el corazón de la pregunta.

Trabajamos con el modelo lineal

$$y = X\beta + \varepsilon$$

donde:

- $y \in \mathbb{R}^n$ es el vector de respuestas observadas,
- $X \in \mathbb{R}^{n \times p}$ es la matriz de diseño (supondremos $\text{rango}(X) = p$ para que $X^\top X$ sea invertible; comento este supuesto porque es lo que hace única la solución más abajo),
- $\beta \in \mathbb{R}^p$ es el vector de parámetros,
- $\varepsilon \in \mathbb{R}^n$ es el **término de error**.

La pregunta es: ¿qué es ese ε ? Hay dos respuestas, y conducen a dos estilos de hacer estadística.

1. La mirada de Gauss: el error como perturbación aleatoria con ley de probabilidad

1.1. Qué se postula

En la tradición de Gauss, ε es un objeto **primitivo**: es una variable aleatoria (un vector aleatorio) que existe *antes* de estimar nada. Representa el conjunto de causas no modeladas —error de medición, fluctuaciones, factores omitidos— concebidas como un sorteo del azar. Comento el matiz: aquí el error no se *deriva*, se *supone*; uno le impone una estructura probabilística.

Los supuestos clásicos (Gauss–Markov) son:

$$\mathbb{E}[\varepsilon] = 0, \quad \text{Var}(\varepsilon) = \sigma^2 I_n$$

Descompongo qué dice cada parte, sin saltarme nada:

1. $\mathbb{E}[\varepsilon] = 0$: en promedio el error no sesga la respuesta; toda la señal sistemática está en $X\beta$.
2. $\text{Var}(\varepsilon) = \sigma^2 I_n$ encierra **dos** supuestos a la vez: la diagonal constante σ^2 es **homocedasticidad** (igual dispersión para toda observación), y los ceros fuera de la diagonal son **no correlación** entre errores. Señalo que esto es una *hipótesis sobre la población*, no algo garantizado por la construcción.

Para hacer **inferencia** (tests, intervalos) Gauss agrega la ley concreta:

$$\varepsilon \sim \mathcal{N}(0, \sigma^2 I_n)$$

1.2. El argumento histórico de Gauss (por qué la normal y por qué mínimos cuadrados)

Vale la pena reconstruir el orden lógico de Gauss, porque ahí se ve el *estilo*:

1. Gauss parte de una intuición: el valor más plausible de una cantidad medida varias veces debería ser la media aritmética.
2. Se pregunta: ¿qué distribución de los errores hace que la media aritmética sea, efectivamente, el valor de **máxima verosimilitud**?

3. Resolviendo esa condición funcional, *deduce* que la densidad del error debe ser la curva normal. Es decir, la normal aparece como **consecuencia** de un principio de estimación, no como un capricho.
4. Maximizar la verosimilitud bajo errores normales equivale a **minimizar la suma de cuadrados** $\sum_i \varepsilon_i^2$. Así queda justificado el método de mínimos cuadrados *desde la probabilidad*.

Más tarde (Theoria Combinationis), Gauss da un segundo argumento más débil en supuestos pero muy potente: el **Teorema de Gauss–Markov**. Comento la diferencia para no confundir las dos justificaciones:

Bajo solo $\mathbb{E}[\varepsilon] = 0$ y $\text{Var}(\varepsilon) = \sigma^2 I$ (sin exigir normalidad), el estimador de mínimos cuadrados $\hat{\beta}$ es **BLUE**: el de mínima varianza dentro de todos los estimadores lineales e insesgados.

1.3. Cómo se obtiene el estimador en esta mirada

Se define un criterio y se optimiza:

$$S(\beta) = \|y - X\beta\|^2 = (y - X\beta)^\top (y - X\beta)$$

Derivando e igualando a cero (paso explícito):

$$\frac{\partial S}{\partial \beta} = -2X^\top (y - X\beta) = 0 \implies X^\top X \hat{\beta} = X^\top y \implies \hat{\beta} = (X^\top X)^{-1} X^\top y$$

Clave conceptual: en esta mirada el criterio "sumar cuadrados" se justifica *probabilísticamente* (es la verosimilitud normal, o es lo que da el óptimo BLUE). La geometría no es el motor; la **ley de probabilidad** lo es.

1.4. Estilo de análisis estadístico que implica

- **Paramétrico e inferencial.** Se modela el proceso generador de datos, se asume una ley para el error y se estudian las **distribuciones muestrales** de los estimadores.
- Productos típicos: insesgadez $\mathbb{E}[\hat{\beta}] = \beta$, matriz de covarianzas $\text{Var}(\hat{\beta}) = \sigma^2 (X^\top X)^{-1}$, tests t y F , intervalos de confianza, verosimilitud, Cramér–Rao, eficiencia.

- Mentalidad: "**de abajo hacia arriba desde la probabilidad**" — primero la ley del azar, luego las propiedades del estimador como teoremas a demostrar.

2. La mirada del Teorema de la Proyección: el error como complemento ortogonal

2.1. Cambiar de escenario: de la probabilidad a la geometría

Aquí el punto de partida no es una ley de probabilidad sino un **espacio con producto interno**. Comento el cambio de escenario porque es radical: dejamos de preguntar "¿cómo se distribuye el error?" y pasamos a preguntar "¿qué parte de y no vive en el espacio de los regresores?".

Considero $\mathbb{R}^n$ con el producto interno usual $\langle u, v \rangle = u^\top v$ y la norma $\|u\| = \sqrt{u^\top u}$. Defino el subespacio generado por las columnas de X :

$$\mathcal{C}(X) = \{X\beta : \beta \in \mathbb{R}^p\} \subseteq \mathbb{R}^n$$

2.2. El Teorema de la Proyección

Teorema (Proyección ortogonal). Sea $\mathcal{M}$ un subespacio cerrado de un espacio de Hilbert $\mathcal{H}$. Para todo $y \in \mathcal{H}$ existe una **única** descomposición

Concretamente, $y = \hat{y} + e$ con $\hat{y} \in \mathcal{M}$ (la parte explicada) y $e \perp \mathcal{M}$ (el error ortogonal).

Además $\hat{y}$ es el punto de $\mathcal{M}$ más cercano a y .

Aplico el teorema con $\mathcal{M} = \mathcal{C}(X)$. La descomposición es:

$$y = \underbrace{\hat{y}}_{\in \mathcal{C}(X)} + \underbrace{e}_{\perp \mathcal{C}(X)}$$

y aquí está el giro central que comento explícitamente: **el término de error e se define como el complemento ortogonal**, es decir, la parte de y que no puede expresarse como combinación lineal de las columnas de X . No se supone su ley; se construye geoméricamente.

2.3. De la ortogonalidad salen las ecuaciones normales (sin derivar nada)

La condición $e \perp \mathcal{C}(X)$ significa que e es ortogonal a cada columna de X , esto es:

$$X^\top e = 0 \iff X^\top (y - X\hat{\beta}) = 0 \iff X^\top X\hat{\beta} = X^\top y$$

Comento el contraste con la sección 1: obtenemos **exactamente las mismas ecuaciones normales**, pero ahora no aparecieron al derivar una suma de cuadrados, sino como la **traducción algebraica de la ortogonalidad**. La proyección es:

$$\hat{y} = Py, \quad P = X(X^\top X)^{-1}X^\top, \quad e = (I - P)y$$

donde P es la matriz de proyección (idempotente y simétrica: $P^2 = P$, $P^\top = P$). Que minimizar $\|y - X\beta\|^2$ y proyectar ortogonalmente coincidan **no es coincidencia**: el teorema dice que la proyección es el punto más cercano, así que mínimos cuadrados es, literalmente, proyección ortogonal.

2.4. Pitágoras: la descomposición de la variabilidad

Como $\hat{y} \perp e$, el Teorema de Pitágoras da de forma inmediata (sin supuestos distribucionales):

$$\|y\|^2 = \|\hat{y}\|^2 + \|e\|^2$$

que, centrando, es la identidad $SCT = SCR + SCE$ del análisis de varianza. Señalo el punto pedagógico: la ANOVA no requiere normalidad para *existir*; es pura geometría. La normalidad solo se necesita después, para ponerle una distribución a los cocientes.

2.5. La versión profunda: el error en L^2 y la esperanza condicional

El teorema se vuelve aún más iluminador en el espacio de Hilbert $L^2(\Omega)$ de variables aleatorias de cuadrado integrable, con producto interno

$$\langle U, V \rangle = \mathbb{E}[UV]$$

Comento por qué este espacio importa: en él la **ortogonalidad equivale a no correlación** (cuando las medias son cero, $\langle U, V \rangle = \text{Cov}(U, V)$). Entonces:

- La **esperanza condicional** $\mathbb{E}[Y | X]$ es la proyección ortogonal de Y sobre el subespacio de todas las funciones (de cuadrado integrable) de X .
- El error $\varepsilon = Y - \mathbb{E}[Y | X]$ es, **por construcción del teorema**, ortogonal a toda función de X ; es decir, no correlacionado con los regresores.
- El **mejor predictor lineal** se obtiene proyectando sobre el subespacio más chico $\{a + b^\top X\}$.

Resultado conceptual que comento para que no quede como salto: en esta mirada la frase "el error no está correlacionado con los regresores" **no es un supuesto**, es una *propiedad automática* de la proyección. Lo que en Gauss era una hipótesis impuesta, aquí es un teorema gratuito.

2.6. Estilo de análisis estadístico que implica

- **Geométrico y libre de distribución.** Se razona con subespacios, ortogonalidad y descomposiciones; no hace falta postular la ley del error para *definir* el estimador.
- Productos típicos: matrices de proyección, descomposición de Pitágoras/ANOVA, geometría de la regresión, esperanza condicional como proyección, unificación de regresión–ANOVA–predicción bajo un mismo marco.
- Mentalidad: "**de arriba hacia abajo desde la estructura del espacio**" — la geometría dicta las ecuaciones, y la probabilidad se incorpora *después*, solo cuando se quiere inferir.

3. Contraste explícito

Criterio	Mirada de Gauss	Mirada del Teorema de la Proyección
Naturaleza del error	Objeto primitivo : variable aleatoria con ley supuesta	Objeto derivado : residuo ortogonal construido
No correlación / ortogonalidad	Supuesto sobre la población ($\text{Var}(\varepsilon) = \sigma^2 I$)	Consecuencia automática de proyectar
Origen de las ecuaciones normales	Derivar y anular la suma de cuadrados	Traducir la condición $X^\top e = 0$
Por qué mínimos cuadrados	Verosimilitud normal / optimalidad BLUE	La proyección es el punto más cercano
Papel de la distribución	Central y desde el inicio	Postergada; solo para inferir, no para estimar
Estilo metodológico	Inferencial, paramétrico, muestral (tests, IC, eficiencia)	Geométrico, estructural, libre de distribución
Dirección del razonamiento	De la probabilidad hacia las propiedades	De la geometría del espacio hacia las ecuaciones

Síntesis

Las dos miradas convergen en el **mismo estimador** $\hat{\beta} = (X^\top X)^{-1} X^\top y$, pero por caminos opuestos, y conviene no leer esa coincidencia como trivial:

- Gauss responde "**por qué es óptimo**": porque, dada una ley de probabilidad del error, mínimos cuadrados es el de máxima verosimilitud / mínima varianza. Su aporte es **inferencial**.
- La proyección responde "**por qué tiene esa forma**": porque estimar es separar y en lo que vive en $\mathcal{C}(X)$ y lo ortogonal a ello. Su aporte es **estructural**.

Una distinción fina que vale la pena comentar para cerrar sin salto lógico: los **errores verdaderos** ε (objeto de Gauss) y los **residuos** e (objeto de la proyección) no son lo mismo — e es una estimación de ε , ligada a X vía $e = (I - P)\varepsilon$ —. La síntesis moderna usa ambas miradas en conjunto: la **geometría** explica la forma y las propiedades algebraicas del estimador, y la **probabilidad** de Gauss le añade la capa de inferencia (distribuciones, tests, intervalos) sobre esa estructura ya construida.