

Modelos Lineales Generalizados:

Una mirada crítica

Ernesto San Martín & Sébastien Van Belleghem

1. Presentación estándar de los modelos lineales generalizados

1.1. Motivación

Los modelos lineales generalizados (GLM, por su denominación en inglés *generalized linear models*) son presentados como una familia de modelos lineales de regresión, definidos por dos componentes: una componente *sistemática* y una componente *aleatoria*.

Para describir estas componentes, vamos a usar los datos proporcionados por Dunn y Smyth (2018), a saber un estudio de 654 jóvenes en East Boston que exploró las relaciones entre la capacidad pulmonar (medida mediante el volumen espiratorio forzado, o *FEV*, en litros) y el estado de fumador, la edad, la estatura y el sexo. Los datos están disponibles en *R* como el *data frame* `lungcap` (abreviatura de ‘lung capacity’), que forma parte del paquete `GLMsData`.

Una manera estándar de describir estos datos es mediante *scatter plots* y *box plots*, como se muestra en las Figuras 1, 2 y 3.

A continuación presentamos el análisis realizado por Dunn y Smyth (2018): los gráficos (Fig. 1) muestran una relación moderada (con variación apreciable) entre FEV y la edad, que podría ser aproximadamente lineal (al menos hasta alrededor de los 15 años). Sin embargo, se observa una relación más fuerte (con menor variación) entre FEV y la estatura, aunque esta relación no parece ser lineal. Asimismo, la variabilidad de FEV parece aumentar para valores mayores de FEV.

En términos generales, también parece que los hombres presentan valores de FEV ligeramente superiores, así como una mayor variabilidad, en comparación con las mujeres. Por otra parte, los fumadores parecen tener valores de FEV mayores que los no fumadores.

Si bien muchas de estas observaciones son esperables, la última resulta sorprendente y podría sugerir que es necesario examinar más de una variable simultáneamente. Los gráficos de la Fig. 1 solo exploran la relación entre FEV y cada variable considerada de manera individual; por ello, continuamos examinando relaciones que involucran más de dos variables a la vez. Una forma de hacerlo es representar los datos por separado para fumadores y no fumadores (véanse las Fig. 2 y 3), utilizando escalas comparables en los ejes para facilitar la comparación.




Figura 1: Relaciones generales entre FEV, estatura, género y hábito de fumar.




Figura 2: Relación entre FEV y edad, diferenciando entre fumadores y no fumadores.




Figura 3: Relación entre FEV y estatura, diferenciando entre fumadores y no fumadores.

Usando este ejemplo, Dunn y Smyth (2018) presentan una descripción de las componentes sistemática y aleatoria en los siguientes términos:

Consideremos nuevamente los datos de capacidad pulmonar [...]. Para cualquier combinación dada de estatura, edad, género y condición de fumador, pueden observarse muchos valores distintos de FEV, lo que da lugar a una distribución de valores registrados de FEV. Un modelo para esta distribución de valores se denomina la *componente aleatoria* del modelo estadístico.

Para esa misma combinación de estatura, edad, género y condición de fumador, la distribución de valores de FEV tiene una media. La relación matemática entre la media de FEV y los valores dados de estatura, edad, género y condición de fumador se denomina la *componente sistemática* del modelo.

Un modelo estadístico consta de una componente aleatoria y una componente sistemática para dar cuenta de estas dos características de los datos reales. En este contexto, el papel de un modelo estadístico es representar matemáticamente tanto la componente sistemática como la componente aleatoria de los datos (p.11).

Dunn y Smyth (2018) presentan como *una posible componente sistemática* la siguiente relación:

$$\mu_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \beta_3 x_{3i} + \beta_4 x_{4i}, \quad (1)$$

donde $\mu_i = E(y_i)$ —la esperanza de la i -ésima observación—, x_{1i} representa la edad (en años cumplidos), x_{2i} la estatura (en pulgadas), x_{3i} el género y x_{4i} la condición de fumador o no fumador.

En relación a esta especificación, Dunn y Smyth (2018) hacen el siguiente comentario:

Este modelo es probablemente una componente sistemática inadecuada, pues los gráficos (Fig. 1) sugieren que la relación entre FEV y la estatura no es lineal. Otras formas de componente sistemática son posibles.

La variabilidad en torno a esta componente puede modelarse de diversas maneras. Por ejemplo, asumir $\text{Var}(y_i) = \sigma^2$ implica varianza constante alrededor de μ_i , sin especificar la distribución. Una elección habitual es suponer $y_i \sim N(\mu_i, \sigma^2)$, es decir, normalidad con varianza constante.

Ambos supuestos parecen inadecuados para estos datos, ya que los gráficos indican que la variabilidad de FEV aumenta con su nivel. Otras distribuciones podrían ser consideradas en lugar de la normal (p.12).

En este comentario podemos ver que el interés se centra en buscar el mejor ajuste de μ_i utilizando las covariables, en el sentido de encontrar la función de dichas covariables que sea lo más cercana posible a μ_i . Este es,

precisamente, el modo en que los GLM son introducidos. En efecto, la componente sistemática (1) es considerada como “una posible representación para explicar cómo cambia la media de FEV al variar la estatura, la edad, el género y la condición de fumador” (p.12). Muchas otras representaciones son también posibles, por lo que un modelo de regresión supone que la media de la respuesta μ_i para la observación i depende de las p variables explicativas $x_{1i}, \dots, x_{pi}$ a través de una función general f , mediante un conjunto de parámetros de regresión β_j (para $j = 0, 1, \dots, q$):

$$E[y_i] = \mu_i = f(x_{1i}, \dots, x_{pi}; \beta_0, \beta_1, \dots, \beta_q).$$

De acuerdo a Dunn y Smyth (2018), comúnmente se asume que los parámetros β_j combinan linealmente los efectos de las variables explicativas, de modo que la componente sistemática adopta la forma más específica

$$\mu_i = f(\beta_0 + \beta_1 x_{1i} + \dots + \beta_p x_{pi}). \quad (1.5)$$

Los modelos de regresión de la forma (1.5) se denominan modelos lineales en los parámetros, por lo que $\beta_0 + \beta_1 x_{1i} + \dots + \beta_p x_{pi}$ se denomina predictor lineal.

En la literatura sobre GLM se distinguen, por tanto, dos tipos de especificaciones:

- **Modelos de regresión lineal:** La componente sistemática de un modelo de regresión lineal adopta la forma

$$E[y_i] = \mu_i = \beta_0 + \beta_1 x_{1i} + \dots + \beta_p x_{pi},$$

mientras que la componente aleatoria se modela suponiendo una varianza constante σ^2 alrededor de μ_i .

- **Modelos lineales generalizados:** La componente sistemática de un modelo lineal generalizado adopta la forma

$$\mu_i = g^{-1}(\beta_0 + \beta_1 x_{1i} + \dots + \beta_p x_{pi}),$$

o, de manera equivalente,

$$g(\mu_i) = \beta_0 + \beta_1 x_{1i} + \dots + \beta_p x_{pi},$$

donde $g(\cdot)$ (denominada función de enlace) es una función monótona y diferenciable (por ejemplo, el logaritmo). La componente aleatoria se introduce suponiendo que y sigue una distribución perteneciente a una familia específica de distribuciones de probabilidad (que incluye, como casos particulares, distribuciones comunes como la normal, Poisson y binomial).

Este es precisamente el objetivo del siguiente ejemplo proporcionado por (Dunn y Smyth, 2018):

Algunas otras posibles componentes sistemáticas que involucran FEV (y), edad (x_1), estatura (x_2), género (x_3) y condición de fumador (x_4) incluyen:

$$\mu = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_4 x_4 \quad (2)$$

$$\mu = \beta_0 + \beta_2 x_2 + \beta_3 x_2^2 + \beta_4 x_4 \quad (3)$$

$$\mu = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \beta_4 x_4 \quad (4)$$

$$\mu = \beta_0 + \beta_1 \log x_1 + \beta_2 x_2 + \beta_4 x_4 \quad (5)$$

$$\mu = \beta_0 + \beta_2 x_2 + \beta_3 x_1 x_2 + \beta_4 x_4 \quad (6)$$

$$\frac{1}{\mu} = \beta_1 x_1 + \beta_2 x_2 + \beta_4 x_4 \quad (7)$$

$$\log \mu = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_4 x_4 \quad (8)$$

$$\mu = \beta_0 + \exp(\beta_1 x_1) - \exp(\beta_2 x_2) + \beta_4 x_4^2 \quad (9)$$

Todas estas componentes sistemáticas, excepto (9), son lineales en los parámetros y podrían utilizarse como componente sistemática de un modelo lineal generalizado. Solo las expresiones (2)–(6) podrían emplearse para especificar un modelo de regresión lineal (p.15).

1.2. Un paradigma . . . que tiene su origen en los trabajos de Gauss

McCullagh y Nelder (1989, p. 27), autores que desarrollaron los modelos GLM, introducen la siguiente distinción:

1. The *random component*: the components of $\mathbf{Y}$ have independent Normal distributions with $E(\mathbf{Y}) = \mu$ and constant variance σ^2 ;
2. The *systematic component*: covariates $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_p$ produce a *linear predictor* η given by

$$\eta = \sum_{j=1}^p \mathbf{x}_j \beta_j;$$

3. The *link* between the random and systematic components:

$$\mu = \eta.$$

Encontramos la misma idea en Tukey (1951), que constituye uno de los fundamentos conceptuales de la llamada *Ciencia de Datos*:

We shall be principally concerned with simple linear regression where both variables are subject to “error”, although the same problem and methods apply to problems involving three, four, or many variates. By saying that we deal with “both variates subject to error” we mean that two measured quantities, which we may as well call x and y , are thought of as made up of two independent (or at least orthogonal) parts as follows

$$\text{observed quantity} = \text{steady part} + \text{fluctuation},$$

where what is included in the steady part and what is fluctuation depend on the problem and our purposes (p. 33).

De hecho, la relación entre Tukey y la Ciencia de Datos es reconocida explícitamente por Cleveland (2005), quien además comparte este paradigma:

While there are many new tools, the attitudes and approaches of data-oriented research in computer science are not at all new. They closely resemble those behind the currents of research in

statistics that John Tukey named “exploratory data analysis”. Methods in this area of work search for patterns in data through visualization tools and through fitting mathematical structure to the data, and do not necessarily invoke formal probability models for the data or carry out probabilistic inductive inference (p. 28).

Estas citaciones tienen, por un lado, como objetivo mostrar que existe una suerte de *continuum* en el modo de concebir los datos; y, por otro lado, evidenciar hasta qué punto una perspectiva probabilística (que no es necesariamente la misma que la alegada por la Estadística) puede abrir la puerta a otra forma de concebir los datos.

El punto importante es que este *paradigma* tiene un origen explícito, a saber, los trabajos de Gauss (1823) y Gauss (1809).

Para el primer texto, traduciremos del latín y lo compararemos con la traducción realizada por Bertrand (1855), *Méthode des moindres carrés. Mémoires sur la combinaison des observations*, publicada en París en 1855. Bertrand menciona que Gauss acababa de fallecer y que el propio Gauss le escribió indicándole que vería con gran placer la publicación de dicha traducción.

1.2.1. Errores de medición

Gauss comienza estableciendo un supuesto que a primera vista puede parecer natural, pero que es empíricamente imposible de testear:

Quantacunque cura instituantur obseruationes, rerum naturalium magnitudinem spectantes, semper tamen erroribus maioribus minoribusue obnoxiae manent. Errores obseruationum plerumque non sunt simplices, sed e pluribus fontibus simul originem trahunt: horum fontium duas species probe distinguere oportet. Quaedam errorum caussae ita sunt comparatae, ut ipsarum effectus in qualibet obseruatione a circumstantiis variabilibus pendeat, inter quae et ipsam obseruationem nullus nexus essentialis concipitur: errores hinc oriundi irregulares seu fortuiti vocantur, quatenusque illae circumstantiae calculo subiici nequeunt, idem etiam de erroribus ipsis valet. Tales sunt errores ab imperfectione sensuum provenientes, nec non a causis extraneis irregularibus, e.g., a motu tremulo aeris visum tantillum turbante; plura quoque vitia instrumentorum vel optimorum huc trahenda sint, e.g. asperitas partis interioris libellularum, defectus firmitatis absolutae,

etc. Contra aliae errorum caussae in omnibus obseruationibus ad idem genus relatis natura sua effectum vel absolute constantem exserunt, vel saltem talem, cuius magnitudo secundum legem determinatam unice a circumstantiis, quae tamquam essentialiter cum obseruatione nexae spectantur, pendet. Huiusmodi errores constantes seu regulares appellantur.

Traducción:

Por más cuidado (*quantacunque cura*) que se ponga en las observaciones relativas a la medida de las magnitudes de cosas naturales (*rerum naturalium magnitudinem*), estas están inevitablemente expuestas a errores (*semper tamen erroribus [...] obnoxiae manent*) más o menos considerables. Los errores de las observaciones, por lo general, no son simples, sino que provienen simultáneamente de varias fuentes (*pluribus fontibus simul originem*); es necesario distinguir claramente dos especies (*duas species*) de estas fuentes.

Ciertas causas (*caussae*) de los errores están dispuestas de tal modo que sus efectos (*effectus*), en cada observación, dependen de circunstancias variables, entre las cuales y la observación misma no se concibe ningún vínculo esencial (*nexus essentialis*); los errores que de aquí se originan se llaman irregulares o fortuitos (*irregulares seu fortuiti vocantur*), y en la medida en que esas circunstancias no pueden someterse a cálculo (*circumstantiae calculo subiici nequeunt*), lo mismo vale también para los errores mismos. Tales son los errores que provienen de la imperfección de los sentidos (*ab imperfectione sensuum provenientes*), así como de causas externas irregulares, por ejemplo, del movimiento tembloroso del aire que perturba ligeramente la visión; además, muchos defectos de los instrumentos (*vitia instrumentorum*), incluso de los mejores, deben incluirse aquí, como la rugosidad de la parte interior de los niveles, la falta de estabilidad absoluta, etc. Por el contrario, otras causas de los errores producen, en todas las observaciones referidas al mismo tipo, por su propia naturaleza, un efecto o bien absolutamente constante, o al menos tal cuya magnitud depende, según una ley determinada, únicamente de circunstancias que se consideran esencialmente ligadas a la observación. Los errores de este tipo se llaman constantes o regulares (*constantes seu regulares appellantur*).

Comentarios:

- El término latino *cura* significa *solicitud, preocupación, cuidado, atención, amor* (ver el comentario y traducción de F. Boyer de las *Geórgicas* de Virgilio: *Le souci de la terre*, Gallimard, París, 2019).
- *Rerum naturalium magnitudinem*: magnitudes de las cosas naturales. El texto latino es más amplio que el texto español (traducido del francés) que presentamos.
- *obnoxius* es un término con cierto rasgo peyorativo: significa estar prisionero de, peso de, expuesto a.
- La afirmación de Gauss es un supuesto (no un hecho), pues es imposible saber si todas las mediciones de cantidades físicas que se hagan en la historia de la humanidad están efectivamente sujetas a errores.
- Para Gauss, los errores son *causados* por determinadas circunstancias y tienen *efectos* en cada observación. Más aún, entre cada error y cada observación *no se concibe ninguna conexión esencial*: es decir, se trata de dos componentes totalmente independientes.
- Estos son los errores fortuitos o irregulares. Son el reflejo de las imperfecciones de nuestros sentidos, de la imposibilidad de construir instrumentos de medición sin imperfecciones. Es decir, se trata de una imperfección propia de los seres humanos, que no permite acceder a la *cantidad natural en sí*, sino que se trata de un acceso *con error*. Más todavía, este error, así como las circunstancias que lo causan (imperfecciones humanas), no son sometibles al cálculo, es decir, no son del todo comprensibles.
- Siempre es posible perfeccionar el alcance de nuestros sentidos por medio de nuevos instrumentos; siempre es posible perfeccionar nuestros instrumentos de medición: hacer que la regla sea más rígida, que la gradación del sextante en grados, minutos y segundos sea más precisa; siempre es posible que el reloj marque los milisegundos cada vez de la manera más precisa. Toda esta búsqueda de precisión se debe a que la magnitud natural que se pretende medir es una idealización, mientras que las mediciones reales son aproximaciones sujetas a errores.
- Los errores regulares o constantes tienen una conexión esencial con las observaciones.

Gauss afirma que esta distinción depende del sentido que se le quiere dar a la expresión *observaciones de un mismo tipo* (*observationum ad idem genus*): si un mismo ángulo se mide repetidas veces, los errores que se deben a una división imperfecta del círculo graduado serán errores constantes. Si, por el contrario, se miden sucesivamente ángulos diferentes, los errores provenientes de la imperfección de la división serán considerados como errores fortuitos.

1.2.2. Errores fortuitos que sigue una ley de continuidad

En primer lugar, Gauss considera razonable considerar que los errores se encuentran entre ciertos límites, además de mostrar cualitativamente cómo se podría encontrar la probabilidad de la combinación de los errores simples:

Errores *observationum ad idem genus pertinentium*, qui a causa simplici determinata oriuntur, per rei naturam certis *limitibus* sunt circumscripti, quos sine dubio exacte assignare liceret si indole ipsius causae *penitus* esset perspecta. Pleraeque errorum fortuitorum causae ita sunt comparatae, ut secundum legem continuitatis omnes errores intra istos limites comprehensi pro possibilibus haberi debeant, perfectaue causae cognitio etiam doceret, utrum omnes hi errores aequali facilitate gaudeant an inaequali, et quanta probabilitas relativa, in casu posteriori, cuius errori tribuenda sit.

Traducción:

Los errores de observaciones pertenecientes a un mismo tipo (*idem genus*), que se originan de una causa simple y determinada, están, por la naturaleza misma de la cosa (*per rei naturam*), circunscritos dentro de ciertos límites, que sin duda sería posible determinar exactamente si la índole de esa causa fuese conocida en profundidad (*penitus*).

Pero la mayoría de las causas de los errores fortuitos están dispuestas de tal modo que, según la ley de continuidad (*secundum legem continuitatis*), todos los errores comprendidos dentro de esos límites deben considerarse posibles (*omnes errores intra istos limites comprehendi pro possibilibus haberi debeant*); y un conocimiento perfecto de la causa (*perfectaue causae cognitio*) también indicaría si todos esos errores se presentan con igual

facilidad (*aequali facilitate*) o con desigual, y cuál es, en este último caso, la probabilidad relativa (*probabilitas relativa*) que debe atribuirse a cada uno.

Comentarios:

1. Para Gauss, por la naturaleza misma de la cosa, los errores están circunscritos a ciertos límites, los cuales podrían ser asignados con exactitud si la índole propia de dicha causa fuese plenamente conocida. Hay que enfatizar que se trata de observaciones de una mismo tipo/género.
2. Gauss invoca la *ley de continuidad* para afirmar que los errores comprendidos entre los límites inferior y superior antes mencionado pueden ser *cualquier número real* de dicho intervalo. Aquí tenemos un probable origen de lo que hoy llamamos *variables aleatorias continuas*. Veremos más adelante que el modo en que Gauss concibe la probabilidad que un error se encuentre en un intervalo infinitesimal es igual al modo en que se deriva la densidad de probabilidad de una variable aleatoria continua.
3. El modo de combinar los errores individuales parece ser por medio de una suma. Sin embargo, el texto latino usa la expresión *aggregato*.

Luego, Gauss hace la siguiente observación:

Exstant utique quaedam errorum causae, quae errores non secundum legem continuitatis progredientes, sed discretos tantum, producere possunt, quales sunt errores divisionis instrumentorum (siquidem illos erroribus fortuitis annumerare placet): divisionum enim multitudo in quovis instrumento determinato est finita. Manifesto autem, hoc non obstat, si modo non omnes errorum causae errores discretos producant, complexus omnium errorum totalium possibilium constituet seriem secundum legem continuitatis progredientem, sive plures eiusmodi series interruptas, si forte, omnibus erroribus discretis possibilibus secundum magnitudinem ordinatis, una alterave differentia inter binos terminos proximos maior evadat, quam differentia inter limites errorum totalium, quatenus e solis erroribus continuis demanant. Sed in praxi casus posterior vix umquam locum habebit, nisi divisio vitiis crassioribus laboret.

Traducción:

Existen, ciertamente, ciertas causas de los errores que pueden producir errores no progresivos según la ley de continuidad, sino únicamente discretos, como son los errores de división de los instrumentos (si se quiere incluirlos entre los fortuitos); en efecto, el número de divisiones en cualquier instrumento determinado es finito. Pero es manifiesto que esto no constituye un obstáculo, con tal de que no todas las causas de error produzcan errores discretos: el conjunto de todos los errores totales posibles constituirá una serie que progresa según la ley de continuidad, o bien varias series de este tipo, aunque discontinuas, si acaso, una vez ordenados todos los errores discretos posibles según su magnitud, alguna que otra diferencia entre dos términos consecutivos resultara mayor que la diferencia entre los límites de los errores totales, en cuanto estos provienen únicamente de errores continuos. Sin embargo, en la práctica, este último caso difícilmente tendrá lugar, a menos que la división esté afectada por defectos más groseros.

1.2.3. La función de probabilidad de los errores fortuitos

Designando facilitatem relatiuam erroris totalis x , in determinato obferuationum genere, per characterificam ϕx , hoc, propter errorum continuitatem, ita intelligendum erit, probabilitatem erroris inter limites infinite proximos x et $x + dx$ effe $= \phi x \cdot dx$. Vix, ac ne vix quidem, vnquam in praxi poffibile erit, hanc functionem a priori assignare: nihilominus plura generalia eam fpectantia ftabiliri poffunt, quae deinceps proferemus. Obuium eft, functionem ϕx eatenus ad functiones discontinuas referendam effe, quod pro omnibus valoribus ipfius x , extra limites errorum poffibilium iacentibus effe debet $= 0$; intra hos limites vero vbique valorem poffituum nancifcetur (omittendo cafum, de quo in fine art. praec. locuti fumus). In plerifque cafibus errores poffituios et negatiuos eiusdem magnitudinis aequae faciles fupponere licebit, quo pacto erit $\phi(-x) = \phi x$. Porro quum errores leuiores facilius committantur quam grauiore, plerumque valor ipfius ϕx erit maximus pro $x = 0$, continuo decrefcet, dum x augetur.

Generaliter autem valor integralis $\int \phi x \cdot dx$, ab $x = a$ vfque ad $x = b$ extenti exprimit probabilitatem, quod error aliquis nondum cognitus iaceat inter limites a et b . Valor itaque illius integralis a limite inferiori omnium errorum poffibilium vfque ad limitem

fuperiorem extenti femper erit $= 1$. Et quum ϕx pro omnibus valoribus ipfius x extra hos limites iacentibus femper fit $= 0$, manifefto etiam $\int \phi x \cdot dx$ ab $x = -\infty$ vfque ad $x = +\infty$ extensum femper fit $= 1$.

Definiendo la facilidad relativa (*facilitatem relatiuam*) del error total x , en un determinado tipo de observaciones, mediante la característica ϕx , esto, debido a la continuidad de los errores, debe entenderse de tal modo que la probabilidad del error (*probabilitatem erroris*) entre los límites infinitamente próximos x y $x + dx$ sea $= \phi x \cdot dx$. Dificilmente, por no decir casi nunca, será posible en la práctica asignar esta función *a priori*; sin embargo, pueden establecerse varias propiedades generales relativas a ella, que exponaremos a continuación.

Es evidente que la función ϕx debe contarse entre las funciones discontinuas en este sentido: que para todos los valores de x situados fuera de los límites de los errores posibles debe ser $= 0$; mientras que dentro de esos límites toma en todas partes un valor positivo (omitiendo el caso del que se habló al final del artículo precedente). En la mayoría de los casos puede suponerse que los errores positivos y negativos de igual magnitud son igualmente fáciles, de modo que $\phi(-x) = \phi x$. Además, puesto que los errores más leves se cometen más fácilmente que los graves (*Porro quum errores leuiores facilius committantu quam graviores*), el valor de ϕx será generalmente máximo para $x = 0$, y decrecerá continuamente a medida que x aumenta.

En general, el valor de la integral $\int \phi x \cdot dx$, extendida desde $x = a$ hasta $x = b$, expresa la probabilidad de que un error, aún desconocido, se encuentre entre los límites a y b . Por consiguiente, el valor de dicha integral, extendida desde el límite inferior de todos los errores posibles hasta el límite superior, será siempre $= 1$. Y puesto que ϕx es $= 0$ para todos los valores de x situados fuera de esos límites, resulta igualmente manifefto que $\int \phi x \cdot dx$ ab $x = -\infty$ vfque ad $x = +\infty$ extensum semper sit $= 1$.

Comentarios:

1. Se trata de errores de observaciones de un mismo género.
2. La característica $\phi(x)$ corresponde a la facilidad del error total x . Gracias a la ley de continuidad, esta se entiende de la siguiente manera:

está relacionada con la probabilidad de que el error esté entre los límites infinitamente próximos x y $x + dx$. Dicha probabilidad es igual a $\phi(x) dx$. En la traducción francesa de Bertrand no se incluye la expresión *infinitamente cercano*.

3. Resulta interesante el argumento cualitativo de Gauss, a saber, que los errores leves se cometen con mayor facilidad que los errores graves: esto es lo que determina la forma de la característica $\phi(x)$. También hay que resaltar que la facilidad de cometer errores positivos o negativos es la misma.

Consideremus porro integrale $\int x\phi x \cdot dx$ inter eosdem limites, cuius valorem statuemus $= k$. Si omnes errorum caussae simplices ita sint comparatae, vt nulla adsit ratio, cur errorum aequalium sed signis oppositis affectorum alter facilius producatum quam alter, hoc etiam respectu erroris totalis valebit, siue erit $\phi(-x) = \phi x$, et proin necessario $k = 0$. Hinc colligimus, quoties k non euanescat sed e.g. sit quantitas positiva, necessario adesse debere vnam alteramue errorum caussam, quae vel errores positivos tantum producere possit, vel certe positivos facilius quam negativos. Haecce quantitas k , quae reuera est medium omnium errorum possibilium, seu valor medius ipsius x , commode dici potest erroris pars constans. Ceterum facile probari potest, partem constantem erroris totalis aequalem esse aggregato partium constantium, quas continent errores e singulis caussis simplicibus prodeuntes. Quodsi quantitas k nota supponitur, a quauis observatione resecatur, errorque observationis ita correcta designatur per x' , ipsiusque probabilitas per $\phi x'$, erit $x' = x - k$, $\phi x' = \phi x$, ac proin $\int x' \phi x' \cdot dx' = \int x \phi x \cdot dx - \int k \phi x \cdot dx = k - k = 0$, i.e. errores observationum correctarum partem constantem non habebunt, quod et per se clarum est.

Traducción:

Consideremos además la integral $\int x\phi x \cdot dx$ dentro de los mismos límites, cuyo valor fijaremos como $= k$. Si todas las causas simples de los errores están dispuestas de tal manera que no exista ninguna razón por la cual, entre errores iguales pero de signos opuestos, uno sea producido con mayor facilidad que el otro, esto también será válido respecto del error total, y por tanto se tendrá $\phi(-x) = \phi x$, y en consecuencia necesariamente $k = 0$.

De aquí concluimos que, siempre que k no se anule sino que, por ejemplo, sea una cantidad positiva, debe necesariamente existir alguna causa de error que o bien produzca únicamente errores positivos, o al menos produzca los positivos con mayor facilidad que los negativos.

Esta cantidad k , que en realidad es el valor medio de todos los errores posibles, es decir, el valor medio de x , puede convenientemente llamarse la parte constante del error. Además, puede demostrarse fácilmente que la parte constante del error total es igual al agregado de las partes constantes contenidas en los errores que proceden de cada una de las causas simples. Y si la cantidad k se supone conocida y se sustrae de cada observación, y el error de la observación así corregida se designa por x' , y su probabilidad por $\phi x'$, entonces será $x' = x - k$, $\phi x' = \phi x$, y por consiguiente $\int x' \phi x' \cdot dx' = \int x \phi x \cdot dx - \int k \phi x \cdot dx = k - k = 0$, esto es, los errores de las observaciones corregidas no tendrán parte constante, lo cual también es evidente por sí mismo.

Comentario: podemos reconocer aquí que, usando nuestra terminología actual, la esperanza de los errores es la componente constante del error.

Perinde vt integrale $\int x \phi x \cdot dx$, seu valor medius ipsius x , erroris constantis vel absentiam vel praesentiam et magnitudinem docet, integrale

$$\int x \phi x \cdot dx$$

ab $x = -\infty$ vsque ad $x = +\infty$ extensum (seu valor medius quadrati xx) aptissimum videtur ad incertitudinem obseruationum in genere definiendam et dimetiendam, ita vt e duobus obseruationum systematibus, quae quoad errorum facilitatem inter se differunt, ea prae cisione praeclare censentur, in quibus integrale $\int x \phi x \cdot dx$ valorem minorem obtinet.

Quodsi quis hanc rationem pro arbitrio, nulla cogente necessitate, electam esse obiiciat, lubenter assentiemur. Quippe quaestio haec per rei naturam aliquid vagi implicat, quod limitibus circumscribi nisi per principium aliquatenus arbitrarium nequeat. Determinatio alicuius quantitatis per obseruationem errori maiori minorive obnoxiae, haud inepta comparatur ludo, in quo solae iacturae,

lucra nulla, dum quilibet error metiendus iacturae assimilis est. Talis damni dispendium aestimatur e iactura probabili, puta ex aggregato productorum singularium iacturarum possibilium in probabilitates respectivas. Quantae vero iacturae quemlibet observationis errorem aequiparare conueniat, neutiquam per se clarum est; quin potius haec determinatio aliqua ex parte ab arbitrio nostro pendet. Iacturam ipsi errori aequalem statuere manifesto non licet; si enim errores positiui pro iacturis acciperentur, negatiui lucra repraesentare deberent. Magnitudo iacturae potius per talem erroris functionem exprimi debet, quae natura sua semper sit positiva. Qualium functionum quum varietas sit infinita, simplicissima, quae hac proprietate gaudet, prae ceteris eligenda videtur, quae absque lite est quadratum: hoc pacto principium supra prolatum prodit.

Traducción:

De la misma manera que la integral $\int x\phi x \cdot dx$, es decir, el valor medio de x , muestra la ausencia o la presencia y la magnitud de la parte constante del error, la integral

$$\int xx\phi x \cdot dx$$

extendida desde $x = -\infty$ hasta $x = +\infty$ (es decir, el valor medio del cuadrado xx) parece ser la más adecuada para definir y medir la incertidumbre de las observaciones en general; de tal modo que, entre dos sistemas de observaciones que difieren entre sí en cuanto a la facilidad de los errores, se consideran con mayor precisión aquellos en los cuales la integral $\int xx\phi x \cdot dx$ toma un valor menor.

Y si alguien objetara que este criterio ha sido elegido arbitrariamente, sin necesidad imperiosa alguna, lo concederemos de buen grado. Pues esta cuestión, por la naturaleza misma de la cosa, implica algo de indeterminado, que no puede ser delimitado sino mediante algún principio en cierto modo arbitrario. La determinación de una magnitud mediante una observación sujeta a error, mayor o menor, puede compararse no inapropiadamente con un juego en el cual solo hay pérdidas y ninguna ganancia, puesto que todo error que ha de medirse es semejante a una pérdida. Tal pérdida se estima mediante la pérdida probable, esto es, mediante

el agregado de los productos de cada una de las pérdidas posibles por sus probabilidades respectivas. Pero cuánto debe valer la pérdida que se ha de asignar a cada error de observación no es en absoluto algo evidente por sí mismo; más bien, esta determinación depende en cierta medida de nuestro arbitrio. No es lícito, manifiestamente, tomar la pérdida igual al propio error; pues, si los errores positivos se consideraran pérdidas, los negativos deberían representar ganancias. La magnitud de la pérdida debe, más bien, expresarse mediante una función del error que, por su naturaleza, sea siempre positiva. Y puesto que la variedad de tales funciones es infinita, parece que debe elegirse, entre todas, la más simple que posea esta propiedad, la cual, sin discusión, es el cuadrado; y de este modo se obtiene el principio enunciado más arriba.

Comentario: el rol de la arbitrariedad y de principios arbitrarios.

III. Laplace simili quidem modo rem consideravit, sed errorem ipsum semper positive acceptum tanquam iacturae mensuram adoptavit. At si fallimur haecce ratio saltem non minus arbitraria est quam nostra: vtrum enim error duplex aeque tolerabilis putetur quam simplex bis repetitus, an acrius, et proin vtrum magis conveniat, errori duplici momentum duplex tantum, an maius, tribuere, quaestio est neque per se clara, neque demonstrationibus mathematicis decidenda, sed libero tantum arbitrio remittenda. Praeterea negari non potest, ista ratione continuitatem laedi: et propter hanc ipsam causam modus ille tractioni analyticae magis refragatur, dum ea, ad quae principium nostrum perducit, mira tum simplicitate tum generalitate commendantur.

Traducción:

El ilustre Laplace, ciertamente, consideró la cuestión de un modo semejante, pero adoptó el error mismo, siempre tomado positivamente, como medida de la pérdida. Pero, si no nos equivocamos, este criterio no es en absoluto menos arbitrario que el nuestro: pues si un error doble debe considerarse igualmente tolerable que un error simple repetido dos veces, o más bien menos tolerable, y por consiguiente si conviene atribuir al error doble un peso simplemente doble, o uno mayor, es una cuestión que no es clara por

sí misma ni puede resolverse mediante demostraciones matemáticas, sino que debe dejarse únicamente al arbitrio.

Además, no puede negarse que con este procedimiento se perjudica la continuidad; y por esta misma razón ese método se opone más al tratamiento analítico, mientras que aquellas cosas a las que conduce nuestro principio se recomiendan tanto por su admirable simplicidad como por su generalidad.

Comentario: conveniencia analítica.

Statuendo valorem integralis $\int xx\phi x \cdot dx$ ab $x = -\infty$ vsque ad $x = +\infty$ extensi = mm , quantitatem m vocabimus errorem medium metiendum, siue simpliciter errorem medium observationum, quarum errores indefiniti x habent probabilitatem relativam ϕx . Determinationem illam non ad observationes immediatas limitabimus, sed etiam ad determinationes qualescunque ex observationibus derivatas extendemus. Probe autem cauendum est, ne error medius confundatur cum medio arithmetico omnium errorum, de quo in art. 5. locuti sumus.

Vbi plura observationum genera, seu plures determinationes ex observationibus petita, quibus haud eadem praecisio concedenda est, comparantur, pondus earum relationum nobis erit quantitas ipsi mm reciproce proportionalis, dum praecisio simpliciter ipsi m reciproce proportionalis habetur. Quo igitur pondus per numerum exprimi possit, pondus certi observationum generis pro quantitate acceptum esse debet.

Traducción:

Fijando el valor de la integral $\int xx\phi x \cdot dx$, extendida desde $x = -\infty$ hasta $x = +\infty$, igual a mm , llamaremos a la cantidad m el error medio a medir, o simplemente el error medio de las observaciones cuyos errores indefinidos x tienen por probabilidad relativa ϕx . Esta determinación no la limitaremos a las observaciones inmediatas, sino que la extenderemos también a cualesquiera determinaciones derivadas de observaciones. Sin embargo, debe cuidarse atentamente no confundir el error medio con el medio aritmético de todos los errores, del cual hemos hablado en el artículo 5.

Cuando se comparan varios géneros de observaciones, o varias determinaciones obtenidas a partir de observaciones, a las cuales no debe atribuirse la misma precisión, el peso de esas relaciones será para nosotros una cantidad inversamente proporcional a mm , mientras que la precisión se considera simplemente inversamente proporcional a m . Por tanto, para que el peso pueda expresarse mediante un número, debe tomarse como unidad el peso de un determinado género de observaciones.

Comentario: aquí está la definicion del ero cuadrático medio.

Si obseruationum errores partem constantem implicant, hanc auferendo error medius minuitur, pondus et praecisio augentur.

Retinendo signa art. 5, designandoque per m' errorem medium obseruationum correctarum, erit

$$\begin{aligned}
 m'm' &= \int x'x'\phi x' \cdot dx' \\
 &= \int (x - k)^2 \phi x \cdot dx \\
 &= \int xx\phi x \cdot dx - 2k \int x\phi x \cdot dx + kk \int \phi x \cdot dx \\
 &= mm - 2kk + kk \\
 &= mm - kk.
 \end{aligned}$$

Si autem loco partis constantis veri k quantitas alia l ab obseruationibus ablata esset, quadratum erroris medii noui euaderet

$$= mm - 2kl + ll = m'm' + (l - k)^2.$$

Traducción:

Si los errores de las observaciones implican una parte constante, al eliminarla el error medio disminuye, y el peso y la precisión aumentan.

Manteniendo las notaciones del artículo 5, y designando por m' el error medio de las observaciones corregidas, se tendrá

$$\begin{aligned}
 &= mm - 2kl + ll \\
 &= m'm' + (l - k)^2.
 \end{aligned}$$

Pero si, en lugar de la verdadera parte constante k , se hubiese sustraído de las observaciones otra cantidad l , el cuadrado del nuevo error medio resultaría

$$= mm - 2kl + ll = m'm' + (l - k)^2.$$

Denotante λ coefficientem determinatum, atque μ valorem integralis

$$\int \phi x dx$$

ab $x = -\lambda m$ usque ad $x = +\lambda m$, erit μ probabilitas, quod error alicuius observationis sit minor quam λm (sine respectu signi), nec non $1 - \mu$ probabilitas erroris maioris quam λm . Si itaque valor $\mu = \frac{1}{2}$ respondet valori $\lambda m = \rho$, error aequè facile infra ρ quam supra ρ cadere potest, quocirca ρ commode dici potest error probabilis. Relatio quantitatum λ, μ manifeste pendet ab indole functionis ϕx , quae plerumque incognita est. Operae itaque pretium erit, istam relationem pro quibusdam casibus specialibus propius considerare.

I. Si limites omnium errorum possibilium sunt $-a$ et $+a$, omnesque errores intra hos limites aequè probabiles, erit ϕx inter limites $x = -a$ et $x = +a$ constans, et proin $= \frac{1}{2a}$. Hinc $m = a\sqrt{\frac{1}{3}}$, nec non $\mu = \lambda\sqrt{\frac{1}{3}}$, quamdiu λ non maior quam $\sqrt{3}$; denique $\rho = m\sqrt{\frac{3}{4}} = 0,8660254 m$, probabilitasque, quod error probabilis medio non maior, erit $= \sqrt{\frac{1}{3}} = 0,5773503$.

II. Si ut antea $-a$ et $+a$ sunt errorum possibilium limites, errorumque ipsorum probabilitas inde ab errore 0 utrinque in progressionem arithmetica decrescere supponitur, erit

$$\phi x = \frac{a - x}{aa}, \quad \text{pro valoribus ipsius } x \text{ inter } 0 \text{ et } +a,$$

$$\phi x = \frac{a + x}{aa}, \quad \text{pro valoribus ipsius } x \text{ inter } 0 \text{ et } -a.$$

Hinc deducitur $m = a\sqrt{\frac{1}{6}}$, $\mu = \lambda\sqrt{\frac{2}{3}} - \frac{1}{2}\lambda\lambda$, quamdiu λ est inter 0 et $\sqrt{6}$; denique $\lambda = \sqrt{6} - \sqrt{6 - 6\mu}$, quamdiu μ inter 0 et 1, et proin

$$\rho = m(\sqrt{6} - \sqrt{3}) = 0,7174389 m.$$

Probabilitas erroris medium non superantis erit in hoc casu

$$= \sqrt{\frac{2}{3}} - \frac{1}{2} = 0,6498299.$$

III. Si functionem ϕx proportionalem statuimus huic $e^{-\frac{xx}{hh}}$ (quod quidem in rerum natura proxime tantum verum esse potest), esse debebit

$$\phi x = \frac{e^{-\frac{xx}{hh}}}{h\sqrt{\pi}},$$

denotante π semiperipheriam circuli pro radio 1, unde porro deducimus

$$m = h\sqrt{\frac{1}{2}}.$$

(V. Disquisit. generales circa seriem infinitam etc. art. 28.)

Porro si valor integralis

$$\frac{2}{\sqrt{\pi}} \int e^{-zz} dz$$

a $z = 0$ incohati denotatur per Θz , erit

$$\mu = \Theta\left(\lambda\sqrt{\frac{1}{2}}\right).$$

Tabula sequens exhibet aliquot valores huius quantitatis:

λ	μ
0,6744897	0,5
0,8416213	0,6
1,0000000	0,6826895
1,0364334	0,7
1,2815517	0,8
1,6448537	0,9
2,5758293	0,99
3,2901830	0,999
3,8905940	0,9999
∞	1

Traducción:

Designando por λ un coeficiente determinado, y por μ el valor de la integral

$$\int \phi x dx$$

desde $x = -\lambda m$ hasta $x = +\lambda m$, μ será la probabilidad de que el error de una observación sea menor que λm (sin atender al signo), y asimismo $1 - \mu$ la probabilidad de que sea mayor que λm .

Si, por tanto, el valor $\mu = \frac{1}{2}$ corresponde al valor $\lambda m = \rho$, el error puede caer con igual facilidad por debajo de ρ que por encima de ρ ; por lo cual ρ puede llamarse convenientemente error probable.

La relación entre las cantidades λ y μ depende manifiestamente de la índole de la función ϕx , la cual en la mayoría de los casos es desconocida. Por ello, será útil considerar más de cerca esta relación en algunos casos particulares.

I. Si los límites de todos los errores posibles son $-a$ y $+a$, y todos los errores dentro de estos límites son igualmente probables, entonces ϕx es constante entre $x = -a$ y $x = +a$, y por tanto igual a $\frac{1}{2a}$.

De aquí se obtiene $m = a\sqrt{\frac{1}{3}}$, y también $\mu = \lambda\sqrt{\frac{1}{3}}$, mientras λ no sea mayor que $\sqrt{3}$; finalmente,

$$\rho = m\sqrt{\frac{3}{4}} = 0,8660254 m,$$

y la probabilidad de que el error probable no sea mayor que el error medio es

$$= \sqrt{\frac{1}{3}} = 0,5773503.$$

II. Si, como antes, $-a$ y $+a$ son los límites de los errores posibles, y se supone que la probabilidad de los errores decrece desde el error 0 hacia ambos lados según una progresión aritmética, entonces

$$\phi x = \frac{a - x}{aa}, \quad \text{para } x \text{ entre } 0 \text{ y } +a,$$

$$\phi x = \frac{a + x}{aa}, \quad \text{para } x \text{ entre } 0 \text{ y } -a.$$

De aquí se deduce

$$m = a\sqrt{\frac{1}{6}}, \quad \mu = \lambda\sqrt{\frac{2}{3}} - \frac{1}{2}\lambda^2,$$

mientras λ esté entre 0 y $\sqrt{6}$; y por tanto

$$\lambda = \sqrt{6} - \sqrt{6 - 6\mu},$$

cuando μ está entre 0 y 1, y en consecuencia

$$\rho = m(\sqrt{6} - \sqrt{3}) = 0,7174389 \, m.$$

La probabilidad de que el error probable no supere al error medio es en este caso

$$= \sqrt{\frac{2}{3}} - \frac{1}{2} = 0,6498299.$$

III. Si suponemos que la función ϕx es proporcional a $e^{-\frac{xx}{hh}}$ (lo cual en la naturaleza de las cosas sólo puede ser aproximadamente verdadero), deberá ser

$$\phi x = \frac{e^{-\frac{xx}{hh}}}{h\sqrt{\pi}},$$

donde π denota la semiperiferia del círculo de radio 1; de donde además se obtiene

$$m = h\sqrt{\frac{1}{2}}.$$

Además, si el valor de la integral

$$\frac{2}{\sqrt{\pi}} \int e^{-zz} dz$$

tomada desde $z = 0$ se denota por Θz , entonces

$$\mu = \Theta\left(\lambda\sqrt{\frac{1}{2}}\right).$$

La tabla siguiente presenta algunos valores de esta cantidad.

λ	μ
0,6744897	0,5
0,8416213	0,6
1,0000000	0,6826895
1,0364334	0,7
1,2815517	0,8
1,6448537	0,9
2,5758293	0,99
3,2901830	0,999
3,8905940	0,9999
∞	1

1.2.4. La “trampa” de Gauss

1.2.5. Resolución de la ecuación funcional Caso $f(x) = \ln(g(x))$

Supongamos que tenemos una función $f : \mathbb{R} \rightarrow \mathbb{R}$, positiva, par, diferenciable en todos los puntos, que satisface la ecuación funcional:

$$f'(ax) = af'(x) \quad \text{para todo } x \in \mathbb{R}, \text{ con } a \text{ constante.}$$

Queremos analizar esta ecuación, y en particular, estudiar el caso en que $f(x) = \ln(g(x))$. Nuestro objetivo será determinar la forma de $g(x)$, y si puede corresponder a la densidad de una distribución normal.

1. Derivada de una función par

Si f es una función **par** y diferenciable, entonces su derivada f' es **impar**. En efecto:

$$f'(-x) = \lim_{h \rightarrow 0} \frac{f(-x+h) - f(-x)}{h}.$$

Como f es par, se tiene $f(-x+h) = f(x-h)$ y $f(-x) = f(x)$, entonces:

$$f'(-x) = \lim_{h \rightarrow 0} \frac{f(x-h) - f(x)}{h} = - \lim_{u \rightarrow 0} \frac{f(x+u) - f(x)}{u} = -f'(x).$$

2. Supongamos ahora que $f(x) = \ln(g(x))$

Usando la regla de la cadena:

$$f'(x) = \frac{g'(x)}{g(x)}.$$

Sustituyendo en la ecuación funcional:

$$f'(ax) = \frac{g'(ax)}{g(ax)} = a \cdot \frac{g'(x)}{g(x)}.$$

Esto implica que la función $\phi(x) := \frac{g'(x)}{g(x)}$ satisface:

$$\phi(ax) = a\phi(x).$$

Las soluciones de esta ecuación funcional son del tipo:

$$\phi(x) = Cx,$$

para alguna constante $C \in \mathbb{R}$. Por lo tanto:

$$\frac{g'(x)}{g(x)} = Cx.$$

3. Resolviendo la ecuación diferencial

Separando variables:

$$\frac{dg}{g} = Cx \, dx \quad \Rightarrow \quad \ln |g(x)| = \frac{C}{2}x^2 + D.$$

Entonces:

$$g(x) = Ae^{\frac{C}{2}x^2}, \quad A = e^D > 0.$$

Y por tanto:

$$f(x) = \ln g(x) = \frac{C}{2}x^2 + \ln A.$$

4. ¿Cuándo $g(x)$ es la densidad de una normal?

Para que $g(x) = Ae^{\frac{C}{2}x^2}$ sea una densidad de probabilidad se requiere:

- $C < 0$, para que la integral converja;
- A tal que $\int_{-\infty}^{\infty} g(x)dx = 1$.

Tomando $C = -\frac{1}{\sigma^2}$, se tiene:

$$g(x) = Ae^{-\frac{x^2}{2\sigma^2}}.$$

Entonces:

$$A = \frac{1}{\sqrt{2\pi\sigma^2}}, \quad \text{y} \quad g(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{x^2}{2\sigma^2}}.$$

5. Conclusión

Si $f(x) = \ln(g(x))$ satisface la ecuación $f'(ax) = af'(x)$, entonces $f(x)$ es cuadrática y $g(x)$ tiene la forma $Ae^{\frac{C}{2}x^2}$. Bajo la condición $C < 0$ y normalización adecuada, $g(x)$ es exactamente la densidad de una distribución normal centrada en cero con varianza $\sigma^2 = -1/C$.

1.3. Especificación de los GLM

Siguiendo a McCullagh y Nelder (1989) and Dunn y Smyth (2018), GLM son modelos de regresión y, por tanto, constan de una componente aleatoria y una componente sistemática. En los GLM, estas componentes adoptan formas específicas que dependen de las respuestas a las siguientes preguntas:

1. ¿Qué distribución de probabilidad es apropiada? La respuesta determina la componente aleatoria del modelo. La elección de la distribución puede estar sugerida por los datos de respuesta (por ejemplo, proporciones de un total sugieren una distribución binomial) o por el conocimiento de cómo varía la varianza en función de la media.
2. ¿Cómo se relacionan las variables explicativas con la media de la respuesta μ ? La respuesta sugiere la componente sistemática del modelo. Los GLM suponen una función que vincula el predictor lineal $\eta = \beta_0 + \sum_{j=1}^p \beta_j x_j$ con la media μ , como por ejemplo $\log \mu = \eta$. Es decir, los GLM son modelos de regresión lineales en los parámetros.

1.3.1. La componente aleatoria

Los GLM suponen que las respuestas provienen de una distribución que pertenece a una familia de distribuciones llamada familia de modelos de dispersión exponencial (EDM, por sus siglas en inglés).

Los EDM continuos incluyen las distribuciones normal y gamma. Los EDM discretos incluyen las distribuciones Poisson, binomial y binomial negativa.

La familia EDM permite ajustar GLM a una amplia variedad de tipos de datos, incluyendo datos binarios, proporciones, conteos, datos continuos positivos, y datos continuos positivos con ceros exactos.

Las distribuciones de la familia EDM tienen una función de probabilidad (función de densidad si y es continua; función de masa si y es discreta) de la forma

$$P(y; \theta, \phi) = a(y, \phi) \exp \left\{ \frac{y\theta - \kappa(\theta)}{\phi} \right\}, \quad (10)$$

donde:

- θ se denomina parámetro canónico;
- $\kappa(\theta)$ es una función conocida, denominada función cumulante;
- $\phi > 0$ es el parámetro de dispersión;

- $a(y, \phi)$ es una función de normalización que asegura que (10) sea una función de probabilidad. Es decir, $a(y, \phi)$ es la función de ϕ y y que garantiza que

$$\int_S P(y; \theta, \phi) dy = 1$$

si y es continua, o

$$\sum_{y \in S} P(y; \theta, \phi) = 1$$

si y es discreta. En general, la función $a(y, \phi)$ no siempre puede escribirse en forma cerrada.

La media μ es una función conocida del parámetro canónico θ . La notación $y \sim \text{edm}(\mu, \phi)$ indica que las respuestas provienen de una distribución de la familia EDM (10), con media μ y parámetro de dispersión ϕ . La expresión (10) corresponde a la forma canónica de un EDM. Otras parametrizaciones son posibles, siendo particularmente importante la forma de modelo de dispersión.

Ejemplo 1 (Normal). La función de densidad de la distribución normal con media μ y varianza σ^2 es

$$P(y; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left\{ -\frac{(y - \mu)^2}{2\sigma^2} \right\}. \quad (11)$$

Esto puede escribirse como

$$P(y; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left\{ \frac{y\mu - \mu^2/2}{\sigma^2} - \frac{y^2}{2\sigma^2} \right\}. \quad (12)$$

Comparando con (10), se tiene:

$$\theta = \mu, \quad \kappa(\theta) = \frac{\theta^2}{2}, \quad \phi = \sigma^2,$$

y

$$a(y, \phi) = (2\pi\sigma^2)^{-1/2} \exp \left\{ -\frac{y^2}{2\sigma^2} \right\}.$$

Por lo tanto, la distribución normal es un EDM.

Ejemplo 2 (Poisson). La función de probabilidad de la distribución Poisson se escribe usualmente como

$$P(y; \mu) = \frac{e^{-\mu} \mu^y}{y!}, \quad y = 0, 1, 2, \dots$$

En la forma (10):

$$P(y; \mu) = \exp\{y \log \mu - \mu - \log(y!)\}. \quad (13)$$

De donde:

$$\theta = \log \mu, \quad \kappa(\theta) = \mu, \quad \phi = 1,$$

y

$$a(y, \phi) = \frac{1}{y!}.$$

Por lo tanto, la distribución Poisson es un EDM.

Ejemplo 3 (Binomial). La función de probabilidad binomial es

$$P(y; \mu, m) = \binom{m}{my} \mu^y (1 - \mu)^{m(1-y)}, \quad (14)$$

donde $y = 0, 1/m, 2/m, \dots, 1$ y $0 < \mu < 1$.

Puede escribirse como

$$P(y; \mu, m) = \binom{m}{my} \exp \left\{ m \left[y \log \frac{\mu}{1 - \mu} + \log(1 - \mu) \right] \right\}. \quad (15)$$

Comparando con (10), se obtiene:

$$\theta = \log \frac{\mu}{1 - \mu}, \quad \kappa(\theta) = -\log(1 - \mu), \quad \phi = \frac{1}{m},$$

y

$$a(y, \phi) = \binom{m}{my}.$$

La distribución binomial es un EDM cuando m es conocido.

Ejemplo 4 (Weibull). La función de probabilidad de la distribución Weibull es

$$P(y; \alpha, \gamma) = \frac{\alpha}{\gamma} \left(\frac{y}{\gamma} \right)^{\alpha-1} \exp \left\{ - \left(\frac{y}{\gamma} \right)^{\alpha} \right\}, \quad y > 0. \quad (16)$$

Reescribiendo:

$$P(y; \alpha, \gamma) = \exp \left\{ - \left(\frac{y}{\gamma} \right)^{\alpha} + \log \left(\frac{\alpha}{\gamma} \right) + (\alpha - 1) \log \left(\frac{y}{\gamma} \right) \right\}. \quad (17)$$

En general, no es posible extraer un término de la forma $y\theta$, salvo cuando $\alpha = 1$. Por tanto, la distribución Weibull no es un EDM en general.

Cuando $\alpha = 1$, se obtiene la distribución exponencial:

$$P(y; \gamma) = \frac{1}{\gamma} \exp \left(-\frac{y}{\gamma} \right) = \exp \left\{ -\frac{y}{\gamma} - \log \gamma \right\}. \quad (18)$$

En este caso:

$$\theta = -\frac{1}{\gamma}, \quad \kappa(\theta) = \log \gamma, \quad \phi = 1,$$

por lo que la distribución exponencial sí es un EDM.

Referencias

- Bertrand, J. (1855). *Méthode des moindres carrés: Mémoires sur la combinaison des observations*. Paris: Mallet-Bachelier. (Traducción al francés de trabajos de C. F. Gauss)
- Cleveland, W. S. (2005). Learning from data: Unifying statistics and computer science. *International Statistical Review*, 73(2), 217–221.
- Dunn, P. K., y Smyth, G. K. (2018). *Generalized linear models with examples in r* (2.^a ed.). New York: Springer. doi: 10.1007/978-1-4419-0118-7
- Gauss, C. F. (1809). *Theoria motus corporum coelestium in sectionibus conicis solem ambientium*. Hamburg: Perthes et Besser.
- Gauss, C. F. (1823). Theoria combinationis observationum erroribus minimis obnoxiae. *Commentationes Societatis Regiae Scientiarum Gottingensis Recentiores*, 5.
- McCullagh, P., y Nelder, J. A. (1989). *Generalized linear models* (2.^a ed.). London: Chapman and Hall.
- Tukey, J. W. (1951). Components in regression. *Biometrics*, 7(1), 33–69.