

Modelos Lineales Generalizados:

Una mirada crítica

Ernesto San Martín

1. Presentación estándar de los modelos lineales generalizados

1.1. MOtivación

Los modelos lineales generalizados (GLM, por su denominación en inglés *generalized linear models*) son presentados como una familia de modelos lineales de regresión, definidos por dos componentes: una componente *sistemática* y una componente *aleatoria*.

Para describir estas componentes, vamos a usar los datos proporcionados por Dunn y Smyth (2018), a saber un estudio de 654 jóvenes en East Boston que exploró las relaciones entre la capacidad pulmonar (medida mediante el volumen espiratorio forzado, o *FEV*, en litros) y el estado de fumador, la edad, la estatura y el sexo. Los datos están disponibles en *R* como el *data frame* `lungcap` (abreviatura de ‘lung capacity’), que forma parte del paquete `GLMsData`.

Una manera estándar de describir estos datos es mediante *scatter plots* y *box plots*, como se muestra en las Figuras 1, 2 y 3.

A continuación presentamos el análisis realizado por Dunn y Smyth (2018): los gráficos (Fig. 1) muestran una relación moderada (con variación apreciable) entre FEV y la edad, que podría ser aproximadamente lineal (al menos hasta alrededor de los 15 años). Sin embargo, se observa una relación más fuerte (con menor variación) entre FEV y la estatura, aunque esta relación no parece ser lineal. Asimismo, la variabilidad de FEV parece aumentar para valores mayores de FEV.

En términos generales, también parece que los hombres presentan valores de FEV ligeramente superiores, así como una mayor variabilidad, en comparación con las mujeres. Por otra parte, los fumadores parecen tener valores de FEV mayores que los no fumadores.

Si bien muchas de estas observaciones son esperables, la última resulta sorprendente y podría sugerir que es necesario examinar más de una variable simultáneamente. Los gráficos de la Fig. 1 solo exploran la relación entre FEV y cada variable considerada de manera individual; por ello, continuamos examinando relaciones que involucran más de dos variables a la vez. Una forma de hacerlo es representar los datos por separado para fumadores y no fumadores (véanse las Fig. 2 y 3), utilizando escalas comparables en los ejes para facilitar la comparación.




Figura 1: Relaciones generales entre FEV, estatura, género y hábito de fumar.




Figura 2: Relación entre FEV y edad, diferenciando entre fumadores y no fumadores.




Figura 3: Relación entre FEV y estatura, diferenciando entre fumadores y no fumadores.

Usando este ejemplo, Dunn y Smyth (2018) presentan una descripción de las componentes sistemática y aleatoria en los siguientes términos:

Consideremos nuevamente los datos de capacidad pulmonar [...]. Para cualquier combinación dada de estatura, edad, género y condición de fumador, pueden observarse muchos valores distintos de FEV, lo que da lugar a una distribución de valores registrados de FEV. Un modelo para esta distribución de valores se denomina la *componente aleatoria* del modelo estadístico.

Para esa misma combinación de estatura, edad, género y condición de fumador, la distribución de valores de FEV tiene una media. La relación matemática entre la media de FEV y los valores dados de estatura, edad, género y condición de fumador se denomina la *componente sistemática* del modelo.

Un modelo estadístico consta de una componente aleatoria y una componente sistemática para dar cuenta de estas dos características de los datos reales. En este contexto, el papel de un modelo estadístico es representar matemáticamente tanto la componente sistemática como la componente aleatoria de los datos (p.11).

Dunn y Smyth (2018) presentan como *una posible componente sistemática* la siguiente relación:

$$\mu_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \beta_3 x_{3i} + \beta_4 x_{4i}, \quad (1)$$

donde $\mu_i = E(y_i)$ —la esperanza de la i -ésima observación—, x_{1i} representa la edad (en años cumplidos), x_{2i} la estatura (en pulgadas), x_{3i} el género y x_{4i} la condición de fumador o no fumador.

En relación a esta especificación, Dunn y Smyth (2018) hacen el siguiente comentario:

Este modelo es probablemente una componente sistemática inadecuada, pues los gráficos (Fig. 1) sugieren que la relación entre FEV y la estatura no es lineal. Otras formas de componente sistemática son posibles.

La variabilidad en torno a esta componente puede modelarse de diversas maneras. Por ejemplo, asumir $\text{Var}(y_i) = \sigma^2$ implica varianza constante alrededor de μ_i , sin especificar la distribución. Una elección habitual es suponer $y_i \sim N(\mu_i, \sigma^2)$, es decir, normalidad con varianza constante.

Ambos supuestos parecen inadecuados para estos datos, ya que los gráficos indican que la variabilidad de FEV aumenta con su nivel. Otras distribuciones podrían ser consideradas en lugar de la normal (p.12).

En este comentario podemos ver que el interés se centra en buscar el mejor ajuste de μ_i utilizando las covariables, en el sentido de encontrar la función de dichas covariables que sea lo más cercana posible a μ_i . Este es,

precisamente, el modo en que los GLM son introducidos. En efecto, la componente sistemática (1) es considerada como “una posible representación para explicar cómo cambia la media de FEV al variar la estatura, la edad, el género y la condición de fumador” (p.12). Muchas otras representaciones son también posibles, por lo que un modelo de regresión supone que la media de la respuesta μ_i para la observación i depende de las p variables explicativas $x_{1i}, \dots, x_{pi}$ a través de una función general f , mediante un conjunto de parámetros de regresión β_j (para $j = 0, 1, \dots, q$):

$$E[y_i] = \mu_i = f(x_{1i}, \dots, x_{pi}; \beta_0, \beta_1, \dots, \beta_q).$$

De acuerdo a Dunn y Smyth (2018), comúnmente se asume que los parámetros β_j combinan linealmente los efectos de las variables explicativas, de modo que la componente sistemática adopta la forma más específica

$$\mu_i = f(\beta_0 + \beta_1 x_{1i} + \dots + \beta_p x_{pi}). \quad (1.5)$$

Los modelos de regresión de la forma (1.5) se denominan modelos lineales en los parámetros, por lo que $\beta_0 + \beta_1 x_{1i} + \dots + \beta_p x_{pi}$ se denomina predictor lineal.

En la literatura sobre GLM se distinguen, por tanto, dos tipos de especificaciones:

- **Modelos de regresión lineal:** La componente sistemática de un modelo de regresión lineal adopta la forma

$$E[y_i] = \mu_i = \beta_0 + \beta_1 x_{1i} + \dots + \beta_p x_{pi},$$

mientras que la componente aleatoria se modela suponiendo una varianza constante σ^2 alrededor de μ_i .

- **Modelos lineales generalizados:** La componente sistemática de un modelo lineal generalizado adopta la forma

$$\mu_i = g^{-1}(\beta_0 + \beta_1 x_{1i} + \dots + \beta_p x_{pi}),$$

o, de manera equivalente,

$$g(\mu_i) = \beta_0 + \beta_1 x_{1i} + \dots + \beta_p x_{pi},$$

donde $g(\cdot)$ (denominada función de enlace) es una función monótona y diferenciable (por ejemplo, el logaritmo). La componente aleatoria se introduce suponiendo que y sigue una distribución perteneciente a una familia específica de distribuciones de probabilidad (que incluye, como casos particulares, distribuciones comunes como la normal, Poisson y binomial).

Este es precisamente el objetivo del siguiente ejemplo proporcionado por (Dunn y Smyth, 2018):

Algunas otras posibles componentes sistemáticas que involucran FEV (y), edad (x_1), estatura (x_2), género (x_3) y condición de fumador (x_4) incluyen:

$$\mu = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_4 x_4 \quad (2)$$

$$\mu = \beta_0 + \beta_2 x_2 + \beta_3 x_2^2 + \beta_4 x_4 \quad (3)$$

$$\mu = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \beta_4 x_4 \quad (4)$$

$$\mu = \beta_0 + \beta_1 \log x_1 + \beta_2 x_2 + \beta_4 x_4 \quad (5)$$

$$\mu = \beta_0 + \beta_2 x_2 + \beta_3 x_1 x_2 + \beta_4 x_4 \quad (6)$$

$$\frac{1}{\mu} = \beta_1 x_1 + \beta_2 x_2 + \beta_4 x_4 \quad (7)$$

$$\log \mu = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_4 x_4 \quad (8)$$

$$\mu = \beta_0 + \exp(\beta_1 x_1) - \exp(\beta_2 x_2) + \beta_4 x_4^2 \quad (9)$$

Todas estas componentes sistemáticas, excepto (9), son lineales en los parámetros y podrían utilizarse como componente sistemática de un modelo lineal generalizado. Solo las expresiones (2)–(6) podrían emplearse para especificar un modelo de regresión lineal (p.15).

1.2. Un paradigma

McCullagh y Nelder (1989, p. 27), autores que desarrollaron los modelos GLM, introducen la siguiente distinción:

1. The *random component*: the components of $\mathbf{Y}$ have independent Normal distributions with $E(\mathbf{Y}) = \mu$ and constant variance σ^2 ;
2. The *systematic component*: covariates $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_p$ produce a *linear predictor* η given by

$$\eta = \sum_{j=1}^p \mathbf{x}_j \beta_j;$$

3. The *link* between the random and systematic components:

$$\mu = \eta.$$

Encontramos la misma idea en Tukey (1951), que constituye uno de los fundamentos conceptuales de la llamada *Ciencia de Datos*:

We shall be principally concerned with simple linear regression where both variables are subject to “error”, although the same problem and methods apply to problems involving three, four, or many variates. By saying that we deal with “both variates subject to error” we mean that two measured quantities, which we may as well call x and y , are thought of as made up of two independent (or at least orthogonal) parts as follows

$$\text{observed quantity} = \text{steady part} + \text{fluctuation},$$

where what is included in the steady part and what is fluctuation depend on the problem and our purposes (p. 33).

De hecho, la relación entre Tukey y la Ciencia de Datos es reconocida explícitamente por Cleveland (2005), quien además comparte este paradigma:

While there are many new tools, the attitudes and approaches of data-oriented research in computer science are not at all new. They closely resemble those behind the currents of research in statistics that John Tukey named “exploratory data analysis”.

Methods in this area of work search for patterns in data through visualization tools and through fitting mathematical structure to the data, and do not necessarily invoke formal probability models for the data or carry out probabilistic inductive inference (p. 28).

Estas citas tienen, por un lado, como objetivo mostrar que existe una suerte de *continuum* en el modo de concebir los datos; y, por otro lado, evidenciar hasta qué punto una perspectiva probabilística (que no es necesariamente la misma que la alegada por la Estadística) puede abrir la puerta a otra forma de concebir los datos.

El punto importante es que este *paradigma* tiene un origen explícito, a saber, los trabajos de Gauss (1823) y Gauss (1809).

Para el primer texto, traduciremos del latín y lo compararemos con la traducción realizada por Bertrand (1855), *Méthode des moindres carrés. Mémoires sur la combinaison des observations*, publicada en París en 1855. Bertrand menciona que Gauss acababa de fallecer y que el propio Gauss le escribió indicándole que vería con gran placer la publicación de dicha traducción.

1.2.1. Errores de medición

Gauss comienza estableciendo un supuesto que a primera vista puede parecer natural, pero que es empíricamente imposible de testear:

Quantacunque cura instituantur observationes, rerum naturalium magnitudinem spectantes, semper tamen erroribus maioribus minoribusue obnoxiae manent. Errores observationum plerumque non sunt simplices, sed e pluribus fontibus simul originem trahunt: horum fontium duas species probe distinguere oportet. Quaedam errorum caussae ita sunt comparatae, ut ipsarum effectus in qualibet observatione a circumstantiis variabilibus pendeat, inter quae et ipsam observationem nullus nexus essentialis concipitur: errores hinc oriundi irregulares seu fortuiti vocantur, quatenusque illae circumstantiae calculo subiici nequeunt, idem etiam de erroribus ipsis valet. Tales sunt errores ab imperfectione sensuum provenientes, nec non a caussis extraneis irregularibus, e.g., a motu tremulo aeris visum tantillum turbante; plura quoque vitia instrumentorum vel optimorum huc trahenda sint, e.g. asperitas partis interioris libellularum, defectus firmitatis absolutae, etc. Contra aliae errorum caussae in omnibus observationibus ad

idem genus relatis natura sua effectum vel absolute constantem exserunt, vel saltem talem, cuius magnitudo secundum legem determinatam unice a circumstantiis, quae tamquam essentialiter cum observatione nexae spectantur, pendet. Huiusmodi errores constantes seu regulares appellantur.

Por más cuidado (*quantacunque cura*) que se ponga en las observaciones relativas a la medida de las magnitudes físicas (*rerum naturalium magnitudinem*), estas están inevitablemente sujetas a errores (*semper tamen erroribus*) más o menos considerables. Errores observationum plerumque non sunt simplices, sed e pluribus fontibus simul originem trahunt: horum fontium duas species probe distinguere oportet.

Comentarios:

- El término latino *cura* significa *solicitud, preocupación, cuidado, atención, amor* (ver el comentario y traducción de F. Boyer de las *Geórgicas* de Virgilio: *Le souci de la terre*, Gallimard, Paris, 2019).
- *Rerum naturalium magnitudinem*: magnitudes de las cosas naturales. El texto latino es más amplio que el texto español (traducido del francés) que presentamos.
- La afirmación de Gauss es un supuesto (no un hecho), pues es imposible saber si todas las mediciones de cantidades físicas que se hagan en la historia de la humanidad están efectivamente sujetas a errores.

Gauss afirma que estos errores provienen de muchas fuentes distintas, por lo que es bueno distinguirlos en dos clases:

Ciertas causas de error dependen, para cada observación, de circunstancias variables e independientes del resultado obtenido: los errores que de ellas provienen se denominan *irregulares* o *fortuitos*, y al igual que las circunstancias que los producen, sus valores no son susceptibles de ser sometidos al cálculo. Tales son los errores que nacen de la imperfección de nuestros órganos y todos aquellos que son debidos a causas externas irregulares, como por ejemplo las vibraciones del aire que hacen que la visión sea menos nítida; algunos de estos errores, debidos a la imperfección

inevitable incluso de los mejores instrumentos, pertenecen a esta misma categoría. Citaremos, por ejemplo, la rugosidad de la parte interior del nivel, la falta de rigidez absoluta, etc.

Existe, por el contrario, otra clase de causas que, en todas las observaciones de la misma naturaleza, producen un error idéntico, o uno cuya magnitud depende de las circunstancias esencialmente ligadas al resultado de la observación. Llamaremos a los errores de esta categoría *errores constantes* o *regulares*.

Comentarios:

- Antes de comentar el texto, es importante revisar el texto latino de Gauss:

Quaedam errorum caussae ita sunt comparatae, ut ipsarum effectus in qualibet observatione a circumstantiis variabilibus pendeat, inter quae et ipsam observationem nullus nexus essentialis concipitur: errores hinc oriundi irregulares seu fortuiti vocantur, quatenusque illae circumstantiae calculo subiici nequeunt, idem etiam de erroribus ipsis valet. Tales sunt errores ab imperfectione sensuum provenientes, nec non a caussis extraneis irregularibus, e.g., a motu tremulo aeris visum tantillum turbante; plura quoque vitia instrumentorum vel optimorum huc trahenda sint, e.g. asperitas partis interioris libellularum, defectus firmitatis absolutae, etc. Contra aliae errorum caussae in omnibus observationibus ad idem genus relatis natura sua effectum vel absolute constantem exserunt, vel saltem talem, cuius magnitudo secundum legem determinatam unice a circumstantiis, quae tamquam essentialiter cum observatione nexae spectantur, pendet. Huiusmodi errores constantes seu regulares appellantur.

En español el texto reza así:

Algunas causas de errores son tales que sus efectos en cada observación dependen de circunstancias variables, entre las cuales y la propia observación no se concibe ninguna conexión esencial: los errores que de aquí surgen se denominan irregulares o fortuitos, y así como estas circunstancias no

pueden someterse al cálculo, lo mismo ocurre con los propios errores. Tales errores incluyen aquellos que provienen de la imperfección de los sentidos, así como de causas externas irregulares, por ejemplo, el movimiento tembloroso del aire que perturba ligeramente la visión; también, varios defectos incluso en los mejores instrumentos deben incluirse aquí, por ejemplo, la aspereza de la parte interior de los niveles, la falta de firmeza absoluta, etc. Por otro lado, otras causas de errores, en todas las observaciones de un mismo tipo, por su naturaleza ejercen un efecto que es absolutamente constante o al menos uno cuya magnitud, según una ley determinada, depende únicamente de circunstancias consideradas como esencialmente conectadas con la observación. A este tipo de errores se les llama errores constantes o regulares.

- En primer lugar, el modo en que Gauss se expresa es mucho más fuerte que la traducción de Bertrand: los errores son *causados* por determinadas circunstancias y tienen *efectos* en cada observación. Más aún, entre cada error y cada observación *no se concibe ninguna conexión esencial*: es decir, se trata de dos componentes totalmente independientes.
- Estos son los errores fortuitos o irregulares. Son el reflejo de las imperfecciones de nuestros sentidos, de la imposibilidad de construir instrumentos de medición sin imperfecciones. Es decir, se trata de una imperfección propia de los seres humanos, que no permite acceder a la *cantidad natural en sí*, sino que se trata de un acceso *con error*. Más todavía, este error, así como las circunstancias que lo causan (imperfecciones humanas), no son sometibles al cálculo, es decir, no son del todo comprensibles.
- Siempre es posible perfeccionar el alcance de nuestros sentidos por medio de nuevos instrumentos; siempre es posible perfeccionar nuestros instrumentos de medición: hacer que la regla sea más rígida, que la gradación del sextante en grados, minutos y segundos sea más precisa; siempre es posible que el reloj marque los milisegundos cada vez de la manera más precisa. Toda esta búsqueda de precisión se debe a que la magnitud natural que se pretende medir es una idealización, mientras que las mediciones reales son aproximaciones sujetas a errores.
- Los errores regulares o constantes tienen una conexión esencial con las observaciones.

Gauss afirma que esta distinción depende del sentido que se le quiere dar a la expresión *observaciones de un mismo tipo* (*observationum ad idem genus*): si un mismo ángulo se mide repetidas veces, los errores que se deben a una división imperfecta del círculo graduado serán errores constantes. Si, por el contrario, se miden sucesivamente ángulos diferentes, los errores provenientes de la imperfección de la división serán considerados como errores fortuitos.

1.2.2. Errores fortuitos que sigue una ley de continuidad

En primer lugar, Gauss considera razonable considerar que los errores se encuentran entre ciertos límites, además de mostrar cualitativamente cómo se podría encontrar la probabilidad de la combinación de los errores simples:

Los errores que, en las observaciones de una misma especie, provienen de una causa simple y determinada se encuentran encerrados entre ciertos límites que se podrían sin duda asignar si la naturaleza de esta causa fuese perfectamente conocida. En la mayoría de los casos, todos los errores comprendidos entre estos límites extremos deben ser considerados como posibles. Un conocimiento profundo de cada causa enseñaría si todos estos errores tienen una facilidad igual o desigual y, en el segundo caso, cuál es la probabilidad relativa de cada uno de ellos. La misma observación se aplica al error total que proviene de la reunión de muchos errores simples. Este error también estará comprendido entre dos límites, uno de los cuales no será superior a la suma de los límites superiores, y el otro no será inferior a la suma de los límites inferiores, correspondientes a los errores simples. Todos los errores comprendidos entre estos límites serán posibles, y cada uno podrá resultar, de una infinidad de maneras, de valores convenientes atribuidos a los errores parciales. Se entiende, sin embargo, dejando de lado las dificultades puramente analíticas, que existe la posibilidad de apreciar la probabilidad más o menos grande de cada resultado, si se suponen conocidas las probabilidades relativas a cada causa simple.

Comentarios:

1. El texto latino de Gauss de la primera oración reza así:

Errores observationum ad idem genus pertinentium, qui a causa simplici determinata oriuntur, per rei naturam certis

limitibus sunt circumscripti, quos sine dubio exacte assignare
liceret si indole ipsius causae penitus esset perspecta.

El español, el exto reza así:

Los errores de las observaciones que pertenecen a un mismo tipo y que surgen de una causa simple y determinada están, por la naturaleza misma de la cosa (rei naturam), circunscritos a ciertos límites, los cuales, sin duda, podrían ser asignados con exactitud si la índole propia de dicha causa (indoles ipsius) fuese completamente comprendida.

Para Gauss, por la naturaleza de la cosa misma, los errores están circunscritos a ciertos límites, los cuales podrían ser asignados con exactitud si la índole propia de dicha causa fuese plenamente conocida. Hay que enfatizar que se trata de observaciones de una mismo tipo /género.

2. Hay un segundo párrafo que requiere contrastarse con el texto latino:

Pleraque errorum fortuitorum causae ita sunt comparatae, ut secundum legem continuitatis omnes errores intra istos limites comprehensi pro possibilibus haberi debeant, perfectaque causae cognitio etiam doceret, utrum omnes hi errores aequali facilitate gaudeant an inaequali, et quanta probabilitas relativa, in casu posteriori, cuius errori tribuenda sit.

En español dice así:

La mayoría de las causas de errores fortuitos están dispuestas de tal manera que, según la ley de continuidad, todos los errores comprendidos dentro de estos límites deben considerarse posibles. Además, un conocimiento perfecto de la causa enseñaría si todos estos errores tienen la misma facilidad o una desigual de ocurrencia, y en este último caso, qué probabilidad relativa debe asignarse a cada error.

Gauss invoca la *ley de continuidad* para afirmar que los errores comprendidos entre los límites inferior y superior antes mencionado pueden ser *cualquier número real* de dicho intervalo. Aquí tenemos un probable origen de lo que hoy llamamos *variables aleatorias continuas*. Veremos más adelante que el modo en que Gauss concibe la probabilidad ue

un error se encuentre en un intervalo infinitesimal es igual a modo en que se deriva la densidad de probabilidad de una variable aleatoria continua.

3. El modo de combinar los errores individuales parece ser por medio de una suma. Sin embargo, el texto latino usa la expresión *aggregato*.

Luego, Gauss hace la siguiente observación:

Exstant utique quaedam errorum caussae, quae errores non secundum legem continuitatis progredientes, sed discretos tantum, producere possunt, quales sunt errores divisionis instrumentorum (siquidem illos erroribus fortuitis annumerare placet): divisionum enim multitudo in quovis instrumento determinato est finita. Manifesto autem, hoc non obstat, si modo non omnes errorum caussae errores discretos producant, complexus omnium errorum totalium possibilium constituet seriem secundum legem continuitatis progredientem, sive plures eiusmodi series interruptas, si forte, omnibus erroribus discretis possibilibus secundum magnitudinem ordinatis, una alteraue differentia inter binos terminos proximos maior evadat, quam differentia inter limites errorum totalium, quatenus e solis erroribus continuis demanant. Sed in praxi casus posterior vix umquam locum habebit, nisi divisio vitiis crassioribus laboret.

Una primera traducción al español reza así:

Existen ciertamente algunas causas de error que pueden producir no errores que progresan según una ley de continuidad, sino únicamente errores discretos, como son los errores de división de los instrumentos (si se desea incluirlos entre los errores fortuitos): en efecto, el número de divisiones en cualquier instrumento determinado es finito. Sin embargo, esto no impide que, mientras no todas las causas de error produzcan errores discretos, el conjunto de todos los errores totales posibles constituya una serie que progresa según una ley de continuidad, o bien varias series de este tipo interrumpidas, si acaso, al ordenar todos los errores discretos posibles según su magnitud, una o más diferencias entre dos términos consecutivos resultan mayores que la diferencia entre los límites de los errores totales que derivan únicamente de errores continuos. Pero en la práctica, este último caso casi nunca

ocurre, a menos que la división del instrumento sufra de defectos particularmente groseros.

El texto francés de Bertrand menciona por primera vez, en este párrafo, la ley de continuidad, por lo que, en una primera lectura, resulta curiosa la aparición de esta expresión. Sin embargo, el texto de Gauss es claro: asume que los errores fortuitos siguen la ley de continuidad y discute la posibilidad de que haya errores discretos, lo que cuestionaría los errores continuos, hipótesis que subyace a su derivación de la distribución normal. El caso que podría poner en cuestión el hecho de que todos los errores, tomados en su conjunto, no sigan dicha ley es que la diferencia entre errores discretos (puestos en una serie de menor a mayor) sea mayor que la diferencia entre los límites dentro de los cuales se encuentran los errores continuos. Ese caso le parece a Gauss fuera de toda práctica, salvo que el instrumento de medición tenga defectos muy grandes.

1.2.3. La función de probabilidad de los errores fortuitos

Gauss caracteriza la función de probabilidad de errores fortuitos:

Designando facilitatem relativam erroris totalis x , in determinato observationum genere, per characteristicam ϕ ; hoc, propter errorum continuitatem, ita intelligendum erit, probabilitatem erroris inter limites infinite proximos x et $x + dx$ esse $= \phi x \cdot dx$.

Una traducción al español es la siguiente.

Designando la facilidad relativa del error total x , en un determinado género de observaciones, mediante la característica ϕ ; esto, debido a la continuidad de los errores, debe entenderse así: la probabilidad de que el error se encuentre entre los límites infinitamente próximos x y $x + dx$ es igual a $\phi, x \cdot dx$.

Comentarios:

1. Gauss designa por x el *error total*: no se refiere al error de todas las observaciones combinadas/agregadas, sino al error total que, en principio, combina errores discretos y continuos, de acuerdo al párrafo anterior. Bertrand no menciona esta expresión, solo usa el término *erreur*.
2. Se trata de errores de observaciones de un mismo género.

3. La característica $\phi(x)$ corresponde a la facilidad del error total x . Gracias a la ley de continuidad, esta se entiende de la siguiente manera: está relacionada con la probabilidad que el error esté entre los límites infinitamente próximos x y $x + dx$. Dicha probabilidad es igual a $\phi(x) dx$.
4. Bertrand no incluye la expresión *infinitamente cercano*.

1.2.4. La “trampa” de Gauss

1.2.5. Resolución de la ecuación funcional Caso $f(x) = \ln(g(x))$

Supongamos que tenemos una función $f : \mathbb{R} \rightarrow \mathbb{R}$, positiva, par, diferenciable en todos los puntos, que satisface la ecuación funcional:

$$f'(ax) = af'(x) \quad \text{para todo } x \in \mathbb{R}, \text{ con } a \text{ constante.}$$

Queremos analizar esta ecuación, y en particular, estudiar el caso en que $f(x) = \ln(g(x))$. Nuestro objetivo será determinar la forma de $g(x)$, y si puede corresponder a la densidad de una distribución normal.

1. Derivada de una función par

Si f es una función **par** y diferenciable, entonces su derivada f' es **impar**. En efecto:

$$f'(-x) = \lim_{h \rightarrow 0} \frac{f(-x+h) - f(-x)}{h}.$$

Como f es par, se tiene $f(-x+h) = f(x-h)$ y $f(-x) = f(x)$, entonces:

$$f'(-x) = \lim_{h \rightarrow 0} \frac{f(x-h) - f(x)}{h} = - \lim_{u \rightarrow 0} \frac{f(x+u) - f(x)}{u} = -f'(x).$$

2. Supongamos ahora que $f(x) = \ln(g(x))$

Usando la regla de la cadena:

$$f'(x) = \frac{g'(x)}{g(x)}.$$

Sustituyendo en la ecuación funcional:

$$f'(ax) = \frac{g'(ax)}{g(ax)} = a \cdot \frac{g'(x)}{g(x)}.$$

Esto implica que la función $\phi(x) := \frac{g'(x)}{g(x)}$ satisface:

$$\phi(ax) = a\phi(x).$$

Las soluciones de esta ecuación funcional son del tipo:

$$\phi(x) = Cx,$$

para alguna constante $C \in \mathbb{R}$. Por lo tanto:

$$\frac{g'(x)}{g(x)} = Cx.$$

3. Resolviendo la ecuación diferencial

Separando variables:

$$\frac{dg}{g} = Cx \, dx \quad \Rightarrow \quad \ln |g(x)| = \frac{C}{2}x^2 + D.$$

Entonces:

$$g(x) = Ae^{\frac{C}{2}x^2}, \quad A = e^D > 0.$$

Y por tanto:

$$f(x) = \ln g(x) = \frac{C}{2}x^2 + \ln A.$$

4. ¿Cuándo $g(x)$ es la densidad de una normal?

Para que $g(x) = Ae^{\frac{C}{2}x^2}$ sea una densidad de probabilidad se requiere:

- $C < 0$, para que la integral converja;
- A tal que $\int_{-\infty}^{\infty} g(x)dx = 1$.

Tomando $C = -\frac{1}{\sigma^2}$, se tiene:

$$g(x) = Ae^{-\frac{x^2}{2\sigma^2}}.$$

Entonces:

$$A = \frac{1}{\sqrt{2\pi\sigma^2}}, \quad \text{y} \quad g(x) = \frac{1}{\sqrt{2\pi\sigma^2}}e^{-\frac{x^2}{2\sigma^2}}.$$

5. Conclusión

Si $f(x) = \ln(g(x))$ satisface la ecuación $f'(ax) = af'(x)$, entonces $f(x)$ es cuadrática y $g(x)$ tiene la forma $Ae^{\frac{C}{2}x^2}$. Bajo la condición $C < 0$ y normalización adecuada, $g(x)$ es exactamente la densidad de una distribución normal centrada en cero con varianza $\sigma^2 = -1/C$.

1.3. Especificación de los GLM

Referencias

- Bertrand, J. (1855). *Méthode des moindres carrés: Mémoires sur la combinaison des observations*. Paris: Mallet-Bachelier. (Traducción al francés de trabajos de C. F. Gauss)
- Cleveland, W. S. (2005). Learning from data: Unifying statistics and computer science. *International Statistical Review*, 73(2), 217–221.
- Dunn, P. K., y Smyth, G. K. (2018). *Generalized linear models with examples in r* (2.^a ed.). New York: Springer. doi: 10.1007/978-1-4419-0118-7
- Gauss, C. F. (1809). *Theoria motus corporum coelestium in sectionibus conicis solem ambientium*. Hamburg: Perthes et Besser.
- Gauss, C. F. (1823). Theoria combinationis observationum erroribus minimis obnoxiae. *Commentationes Societatis Regiae Scientiarum Gottingensis Recentiores*, 5.
- McCullagh, P., y Nelder, J. A. (1989). *Generalized linear models* (2.^a ed.). London: Chapman and Hall.
- Tukey, J. W. (1951). Components in regression. *Biometrics*, 7(1), 33–69.