

1

1 Base de datos

Un centro de estudios cercano a la Comisión Europea lo contrata con el fin de medir el impacto de las reformas fiscales sobre el crecimiento económico. Para ello, pone a su disposición una base de datos que cubre cinco países (Francia, Alemania, Bélgica, España, Italia), presentada en la Tabla 1.

1. ¿Cuál es el conjunto de etiquetas (labels) de esta base de datos?
2. ¿Cuál es la partición inducida por la variable FR (reforma fiscal)?
3. Calcule la esperanza de la variable "Invest" condicionada a la variable "Año". Notamos esta variable como E (Inversión | Año).
4. Calcule el r^2 de esta descomposición y dé una interpretación geométrica de esta cantidad.

País	Año	FR	Crecimiento	Reducción	Inversión	Deuda	Desempleo
FRA	2015	0	2.5	0.0	19.3	95.2	7.5
FRA	2016	0	3.6	0.0	17.1	85.4	7.1
FRA	2017	1	2.7	204.3	15.6	73.4	5.5
FRA	2018	1	1.6	229.4	21.9	76.7	7.6
FRA	2019	1	2.0	305.5	16.7	82.8	6.3
DEU	2015	0	2.4	0.0	18.5	90.4	8.1
DEU	2016	0	2.9	0.0	17.0	85.2	7.2
DEU	2017	1	3.1	302.5	19.7	74.6	5.8
DEU	2018	1	1.7	215.7	20.5	78.3	6.5
DEU	2019	1	2.1	276.5	18.4	75.8	6.0
BEL	2015	0	1.8	0.0	18.0	90.3	8.9
BEL	2016	0	2.4	0.0	17.1	85.8	7.7
BEL	2017	1	2.5	320.1	20.2	74.3	6.4
BEL	2018	1	1.9	251.0	21.2	77.2	5.9
BEL	2019	1	2.0	312.7	19.4	76.8	6.1
ESP	2015	0	1.7	0.0	16.9	92.8	9.3
ESP	2016	0	2.5	0.0	18.0	86.1	8.1
ESP	2017	1	3.0	298.6	19.8	75.2	6.2
ESP	2018	1	2.2	243.2	20.4	77.0	6.8
ESP	2019	1	2.3	285.6	18.8	74.9	6.4

Table 1: FR = variable indicadora que señala una reforma fiscal. Crecimiento = tasa de crecimiento. Reducción = reducción promedio de impuestos por habitante (en €). Inversión = tasa de inversión. Deuda = deuda pública como porcentaje del PIB. Desempleo = tasa de desempleo. Inflación = tasa de inflación.

Desarrollo y soluciones

Marco de trabajo: la base de datos tiene **20 individuos estadísticos** (cada fila es un par $País \times Año$) y 9 variables.

Trabajamos en el espacio $\mathbb{R}^{20}$ de variables, con pesos uniformes $p_i = 1/20$ y producto interno $\langle X, Y \rangle = \frac{1}{20} \sum_i X_i Y_i$.



Setup en R — datos comunes a todas las preguntas.

```
# Datos: 4 países × 5 años = 20 observaciones
datos <- data.frame(
  Pais = rep(c("FRA", "DEU", "BEL", "ESP"), each = 5),
  Anio = rep(2015:2019, times = 4),
  FR = rep(c(0, 0, 1, 1, 1), times = 4),
  Inv = c(19.3, 17.1, 15.6, 21.9, 16.7, # FRA
          18.5, 17.0, 19.7, 20.5, 18.4, # DEU
          18.0, 17.1, 20.2, 21.2, 19.4, # BEL
          16.9, 18.0, 19.8, 20.4, 18.8) # ESP
)
datos$Anio <- factor(datos$Anio)
str(datos)
```

1. Conjunto de etiquetas (labels)

Las **etiquetas** son los identificadores de los individuos. Cada observación queda identificada por el par $(País, Año)$, de modo que

$$I = \{ (FRA, 2015), (FRA, 2016), \dots, (ESP, 2019) \}, \quad |I| = 4 \times 5 = 20.$$

Cada label $i \in I$ tiene peso $p_i = 1/20$, y cada columna es una función $X : I \rightarrow \mathbb{R}$.

El enunciado menciona 5 países (incluida Italia), pero la Tabla 1 solo contiene 4. El conjunto de labels real es de cardinal 20.

```
# Etiquetas = identificador de cada individuo
etiquetas <- interaction(datos$Pais, datos$Anio, sep = ".")
etiquetas      # 20 labels
length(etiquetas) # 20
```

2. Partición inducida por FR

FR es binaria, así que induce **dos clases**:

$$I = A_0 \sqcup A_1, \quad A_0 = \{FR = 0\}, \quad A_1 = \{FR = 1\}, \quad |A_0| = 8, \quad |A_1| = 12.$$

FR = 0 corresponde a 2015–2016 (sin reforma) y FR = 1 a 2017–2019 (con reforma), para los 4 países: $4 \times 2 = 8$ y $4 \times 3 = 12$.

```
# Partición inducida por FR
split(etiquetas, datos$FR)
table(datos$FR) # FR=0 -> 8 (sin reforma), FR=1 -> 12 (con reforma)
```

3. Esperanza condicional $E(\text{Inversión} \mid \text{Año})$

Año induce 5 clases (una por año), cada una con 4 individuos. La esperanza condicional vale, en cada individuo, el promedio de su clase:

$$E(\text{Inv} \mid \text{Año})(i) = \frac{1}{|C_{\text{Año}(i)}|} \sum_{j: \text{Año}(j) = \text{Año}(i)} \text{Inv}(j).$$

Año	Valores (FRA, DEU, BEL, ESP)	Suma	Promedio
2015	19.3, 18.5, 18.0, 16.9	72.7	18.175
2016	17.1, 17.0, 17.1, 18.0	69.2	17.300
2017	15.6, 19.7, 20.2, 19.8	75.3	18.825
2018	21.9, 20.5, 21.2, 20.4	84.0	21.000
2019	16.7, 18.4, 19.4, 18.8	73.3	18.325

La variable $E(\text{Inv} \mid \text{Año})$ es **constante por año** con esos valores; la media global se conserva: $\bar{x} = 374.5/20 = 18.725$.

```
# E(Inv | Año): promedio por año
medias_anio <- tapply(datos$Inv, datos$Anio, mean)
medias_anio
datos$E_Inv_Anio <- ave(datos$Inv, datos$Anio, FUN = mean)

# Visualización
barplot(medias_anio, col = "steelblue",
        main = "E(Inversión | Año)", xlab = "Año", ylab = "Inversión media")
abline(h = mean(datos$Inv), col = "red", lty = 2) # media global

boxplot(Inv ~ Anio, data = datos, col = "lightblue",
        main = "Inversión por año", ylab = "Inversión")
points(1:5, medias_anio, pch = 18, col = "red", cex = 1.6)
```

4. r^2 de la descomposición e interpretación geométrica

Descomposición de la varianza (ANOVA / Pitágoras):

$$\text{Var}(\text{Inv}) = \text{Var}(E(\text{Inv} \mid \text{Año})) + E(\text{Var}(\text{Inv} \mid \text{Año})),$$

$$r^2 = \frac{\text{Var}(E(\text{Inv} \mid \text{Año}))}{\text{Var}(\text{Inv})} = \frac{\text{SC}_{\text{inter}}}{\text{SC}_{\text{total}}}.$$

Sumas de cuadrados:

$$\text{SC}_{\text{inter}} = \sum_a n_a (\bar{x}_a - \bar{x})^2 = 4 \times 7.67875 = 30.715,$$

$$\text{SC}_{\text{total}} = \sum_i x_i^2 - 20 \bar{x}^2 = 7066.41 - 7012.5125 = 53.8975,$$

$$\text{SC}_{\text{intra}} = 53.8975 - 30.715 = 23.1825.$$

$$r^2 = \frac{30.715}{53.8975} \approx 0.570$$

Es decir, el año explica $\approx 57\%$ de la variabilidad de la inversión.

Interpretación geométrica. Sea F el subespacio de variables constantes en cada clase de Año. Entonces $E(\text{Inv} \mid \text{Año})$ es la **proyección ortogonal** de Inv sobre F , y el residuo es ortogonal a F . Con vectores centrados:

$$\|\text{Inv} - \bar{x}\|^2 = \|E(\text{Inv} \mid \text{Año}) - \bar{x}\|^2 + \|\text{Inv} - E(\text{Inv} \mid \text{Año})\|^2,$$

$$r^2 = \cos^2 \theta,$$

donde θ es el ángulo entre la variable centrada Inv y el subespacio F . Aquí $\cos \theta = \sqrt{0.57} \approx 0.755$, o sea $\theta \approx 41^\circ$.

```

# Descomposición de varianza y  $r^2$  (razón de correlación  $\eta^2$ )
gran_media <- mean(datos$Inv)
SC_total <- sum((datos$Inv - gran_media)^2)
SC_inter <- sum((datos$E_Inv_Anio - gran_media)^2) # entre años
SC_intra <- sum((datos$Inv - datos$E_Inv_Anio)^2) # dentro de años
r2 <- SC_inter / SC_total
c(SC_total = SC_total, SC_inter = SC_inter, SC_intra = SC_intra, r2 = r2)

# Equivalente vía ANOVA:  $\eta^2 = SS_{\text{efecto}} / SS_{\text{total}}$ 
modelo <- aov(Inv ~ Anio, data = datos)
summary(modelo)

# Ángulo entre Inv (centrada) y el subespacio de funciones del año
theta <- acos(sqrt(r2)) * 180/pi
cat(sprintf("r2 = %.4f | cos(theta) = %.3f | theta = %.1f grados\n",
            r2, sqrt(r2), theta))

```