



2 Coherencia en una base de datos

Muchas veces se argumenta que es posible usar datos agregados para explicar datos individuales. Consideremos por ejemplo datos electorales en los que se vota por dos candidatos: cada voto, asociado a un folio único, toma uno de los siguientes valores: candidato 1, candidato 2, voto nulo o voto blanco. Además, cada folio está asociado a una mesa de votación, la cual pertenece a un local de votación en un determinado distrito.

1. ¿Cuáles son las etiquetas (labels) de la base de datos?
2. Mesa de votación, local de votación y distrito, ¿son variables? En caso de serlo, ¿qué particiones inducen?
3. Un científico político quiere explicar las opciones por uno u otro candidato en función de la tasa de cesantía de la comuna: ¿qué condiciones debe satisfacer esta variable para que pueda ser considerada como parte de la base de datos?

Desarrollo y soluciones

Marco de trabajo (San Martín): una base de datos es un espacio de probabilidad empírico $(\Omega_N, \mathcal{P}(\Omega_N), P_N)$, donde Ω_N es el **conjunto de etiquetas** (los individuos estadísticos), cada etiqueta tiene peso $p_\omega = 1/N$, y cada **variable** es una función $X : \Omega_N \rightarrow \text{Im}(X)$. Toda variable induce una **partición** de Ω_N en bloques (sus preimágenes), y el subespacio $\sigma(X)$ de funciones constantes sobre esos bloques es donde vive la esperanza condicional $E(\cdot \mid \sigma(X))$ como proyección ortogonal.



Estructura del ejemplo electoral. La unidad observada es el **voto**, identificado por un **folio único**. Sobre cada folio están definidas: la opción de voto (candidato 1, candidato 2, nulo, blanco) y su ubicación en la jerarquía territorial **mesa** → **local** → **distrito**.

1. Etiquetas (labels) de la base de datos

Las etiquetas son los **folios**, no las opciones de voto. Cada folio es un identificador único de un voto emitido, de modo que

$$\Omega_N = \{\omega_1, \omega_2, \dots, \omega_N\}, \quad N = \#\{\text{votos emitidos}\},$$

donde cada $\omega \in \Omega_N$ tiene peso $p_\omega = 1/N$.

La opción elegida **no** es una etiqueta: es una **variable**

$$V : \Omega_N \longrightarrow \{\text{cand. 1, cand. 2, nulo, blanco}\},$$

que a cada folio le asigna su contenido. Confundir la etiqueta (folio) con el valor de una variable (la opción de voto) es el error conceptual de fondo: el candidato no individualiza a la unidad, solo la describe.

Para que Ω_N sea un conjunto de etiquetas legítimo, los folios deben ser **únicos** (identifican sin ambigüedad), **exhaustivos** (cubren todos los votos) y **mutuamente excluyentes**.

2. ¿Son variables Mesa, Local y Distrito? Particiones que inducen

Sí: las tres son variables, porque son funciones bien definidas sobre el conjunto de folios Ω_N :

$$M : \Omega_N \rightarrow \{\text{mesas}\}, \quad L : \Omega_N \rightarrow \{\text{locales}\}, \quad D : \Omega_N \rightarrow \{\text{distritos}\}.$$

Cada una induce una partición de Ω_N por sus preimágenes:

- **Mesa:** bloques $M^{-1}(m) = \text{folios votados en la mesa } m$.
- **Local:** bloques $L^{-1}(\ell) = \text{folios del local } \ell$.

- **Distrito:** bloques $D^{-1}(d) = \text{folios del distrito } d$.

Lo esencial es que estas particiones son **jerárquicas / encajonadas**: cada mesa pertenece a un único local y cada local a un único distrito. Por lo tanto la partición de Mesa **refina** a la de Local, que a su vez **refina** a la de Distrito. En términos de los subespacios de funciones constantes sobre bloques:

$$\sigma(D) \subseteq \sigma(L) \subseteq \sigma(M) \subseteq L^2(\Omega_N).$$

Equivalentemente, todo bloque de Distrito es unión de bloques de Local, y todo bloque de Local es unión de bloques de Mesa. (Existe una función de paso bien definida $\text{mesa} \mapsto \text{local} \mapsto \text{distrito}$, pero **no** al revés.)

flowchart TD

D["Distrito (partición más gruesa)"] --> L1["Local 1"]

D --> L2["Local 2"]

L1 --> M1["Mesa A"]


L1 --> M2["Mesa B"]

L2 --> M3["Mesa C"]

M1 --> F1["folios ω..."]

M2 --> F2["folios ω..."]

M3 --> F3["folios ω..."]



Variable	Bloques (preimágenes)	Finura relativa
Mesa	folios de una misma mesa	más fina
Local	unión de mesas del local	intermedia
Distrito	unión de locales del distrito	más gruesa

3. Condiciones para incorporar la tasa de cesantía de la comuna

La tasa de cesantía es un dato **agregado** definido a nivel de **comuna**, no a nivel de folio. Para que sea una variable de esta base de datos debe poder escribirse como una función sobre las etiquetas,

$$C : \Omega_N \longrightarrow \mathbb{R}, \quad \omega \longmapsto \text{tasa de cesantía de la comuna del folio } \omega,$$

y esto exige dos condiciones:

1. **Coherencia con la jerarquía existente (que la comuna sea una variable bien definida).** Debe existir una asignación unívoca folio $\rightarrow$ comuna, lo que ocurre solo si cada local (o mesa/distrito) pertenece a una **única** comuna. Así la comuna queda definida como variable $K : \Omega_N \rightarrow \{\text{comunidades}\}$ compatible con la jerarquía territorial. Si un mismo local cayera en dos comunas, la asignación sería ambigua y C no estaría bien definida.
2. **Medibilidad: C debe ser constante sobre los bloques de la comuna**, es decir $C \in \sigma(K)$. La tasa de cesantía toma un solo valor por comuna, de modo que es constante dentro de cada bloque comunal (y, por la jerarquía, dentro de cada local/mesa contenidos en esa comuna).

Dicho de otro modo, C es legítima si y solo si pertenece al subespacio de funciones constantes sobre la partición comunal:

$$C \in \sigma(K), \quad K \text{ coherente con } \sigma(D) \subseteq \sigma(L) \subseteq \sigma(M).$$



El punto de fondo (la "coherencia"). Aun cumpliendo lo anterior, C es **constante por comuna**: solo aporta variabilidad *entre* comunas, no *dentro*. Por eso, al explicar la opción individual de voto con C , toda regresión factoriza a través de la proyección comunal,

$$E(V | C) = E(V | \sigma(K)),$$

y no puede distinguir a dos votantes de la misma comuna. Usar un agregado para explicar el comportamiento individual es válido como *descomposición de medias por comuna*, pero atribuir ese efecto al individuo es la **falacia ecológica**.

¿Por qué "falacia ecológica"?

La **falacia ecológica** consiste en inferir el comportamiento de los **individuos** a partir de correlaciones medidas a nivel **agregado** (aquí, la comuna). El término viene de la sociología (Robinson, 1950): una relación que se observa entre *promedios de grupos* no tiene por qué valer —y puede incluso invertirse— al interior de los grupos.

El origen del problema es exactamente la estructura de particiones de la pregunta 2. Como $C \in \sigma(K)$ es **constante dentro de cada comuna**, la única información que aporta es la que separa unas comunas de otras. Formalmente, la varianza de cualquier predicción basada en C vive por completo en el espacio *entre comunas* y es ortogonal a la variabilidad *dentro* de cada comuna:

$$\text{Var}(V) = \underbrace{\text{Var}(E(V | \sigma(K)))}_{\text{entre comunas (lo que "ve" } C)} + \underbrace{E(\text{Var}(V | \sigma(K)))}_{\text{dentro de comunas (invisible para } C)}.$$

Una asociación fuerte en el primer término **no dice nada** sobre lo que ocurre dentro de cada comuna, que es justamente el nivel individual que el cientista político quiere explicar.



Ejemplo donde la relación se invierte (paradoja de Simpson).

Supongamos dos comunas. La correlación *entre comunas* sugiere que más cesantía → más voto al candidato 1, pero *dentro* de cada comuna ocurre lo contrario.

Comuna	Cesantía (agregada)	% voto cand. 1 (individual)
A — cesantes	20%	70%
A — empleados	20%	40%
B — cesantes	5%	55%
B — empleados	5%	25%

A nivel **comuna** la comuna con más cesantía (A) vota más al candidato 1, lo que sugeriría "más cesantía → más apoyo". Pero **dentro** de cada comuna son los *empleados* quienes votan menos al candidato 1: la relación individual cesantía → voto es la opuesta a la agregada. Atribuir la correlación comunal a las personas sería la falacia ecológica.

Moraleja para la base de datos. Incorporar la tasa de cesantía comunal es legítimo y útil para describir diferencias *entre* comunas, pero **no** es información a nivel de folio: no permite afirmar que un votante *cesante* se comporta de cierto modo. Para sostener una explicación individual se necesitaría una variable definida realmente sobre el folio (p. ej. la condición de empleo de cada votante), que induzca su propia partición más fina que la comunal.