

3

3 Modelos lineales encajonados

Parece ampliamente aceptada la práctica según la cual diversas especificaciones de modelos lineales se consideran encajonadas (nested, en inglés). Más específicamente, consideremos los siguientes dos modelos lineales:

$$\begin{aligned} \text{M1: } E(Y | X_1) &= \alpha_0 + \alpha_1 X_1 \\ \text{M2: } E(Y | X_1, X_2) &= \alpha_0 + \alpha_1 X_1 + \alpha_2 X_2 \end{aligned}$$

El modelo M1 se considera encajonado en el modelo M2, pues si $\alpha_2 = 0$ en M2, entonces se obtiene M1. Como es bien sabido, esto conlleva la práctica de ajustar el modelo lineal con solo el predictor X_1 , y luego añadir el predictor X_2 y decidir cuál de los dos modelos "ajusta mejor a los datos".

En este problema van a construir dos ejemplos a partir de los cuales deberán hacer una digresión crítica de las afirmaciones anteriores.

Ejemplo 1: Consideremos la siguiente tabla de datos:

Ω_3	1	X	Y
ω_1	1	-1	y_1
ω_2	1	0	y_2
ω_3	1	1	y_3

Definimos:

$$\begin{aligned} \sigma(\mathbf{1}, X) &= \{a\mathbf{1} + bX : a, b \in \mathbb{R}\} \\ \sigma(\mathbf{1}) &= \{a\mathbf{1} : a \in \mathbb{R}\} \\ \sigma(X) &= \{aX : a \in \mathbb{R}\} \end{aligned}$$

Calcule $E(Y | \sigma(\mathbf{1}, X))$ y verifique que

$$E(Y | \sigma(\mathbf{1}, X)) = E(Y | \sigma(\mathbf{1})) + E(Y | \sigma(X)).$$

¿A qué podemos atribuir que dicha igualdad se cumple?

Ejemplo 2: Consideremos la siguiente tabla de datos:

Ω_3	$\mathbf{1}$	Z	Y
ω_1	1	1	y_1
ω_2	1	0	y_2
ω_3	1	1	y_3

Definimos:

$$\sigma(\mathbf{1}, Z) = \{a\mathbf{1} + bZ : a, b \in \mathbb{R}\}$$

$$\sigma(\mathbf{1}) = \{a\mathbf{1} : a \in \mathbb{R}\}$$

$$\sigma(Z) = \{aZ : a \in \mathbb{R}\}$$

Calcule $E(Y \mid \sigma(\mathbf{1}, Z))$ y verifique que

$$E(Y \mid \sigma(\mathbf{1}, Z)) \neq E(Y \mid \sigma(\mathbf{1})) + E(Y \mid \sigma(Z)).$$

Pregunta: ¿Cómo utilizarías este ejemplo para enunciar cuándo los modelos M1 y M2 pueden ser considerados como encajonados?

Solución

Marco: la esperanza condicional sobre un subespacio como proyección ortogonal

Antes de calcular nada conviene fijar el marco, porque de él depende todo lo que sigue. Lo explicito para no dar saltos:

- Trabajamos sobre el espacio muestral finito $\Omega_3 = \{\omega_1, \omega_2, \omega_3\}$. Supondremos —como es estándar en este tipo de tablas— que la medida de probabilidad es **uniforme**, es decir $P(\{\omega_i\}) = \frac{1}{3}$ para cada i . Comento esto explícitamente porque el valor numérico de los productos internos depende de esta elección.
- Bajo ese supuesto, cada variable aleatoria $(\mathbf{1}, X, Z, Y)$ se identifica con el vector de $\mathbb{R}^3$ formado por los valores que toma en $\omega_1, \omega_2, \omega_3$.
- En $L^2(\Omega_3, P)$ usamos el producto interno

$$\langle U, V \rangle = E(UV) = \frac{1}{3} \sum_{i=1}^3 U(\omega_i) V(\omega_i),$$

con norma $\|U\|^2 = \langle U, U \rangle$.

- Los conjuntos $\sigma(\cdot)$ del enunciado son **subespacios lineales** de $\mathbb{R}^3$. La notación $E(Y \mid \sigma(\mathcal{M}))$ designa la **proyección ortogonal** de Y sobre el subespacio $\mathcal{M}$: el único $M \in \mathcal{M}$

que minimiza $\|Y - M\|^2$. Esta es la versión geométrica de la esperanza condicional, y es la lectura que da sentido a las igualdades que se piden verificar.

Hecho clave que usaremos (y que no podemos dar por supuesto sin justificarlo): si $\mathcal{M}$ y $\mathcal{N}$ son subespacios **ortogonales** entre sí, entonces la proyección sobre la suma directa coincide con la suma de las proyecciones,

$$P_{\mathcal{M} \oplus \mathcal{N}} = P_{\mathcal{M}} + P_{\mathcal{N}}.$$

Si los subespacios **no** son ortogonales, esta igualdad en general falla. Toda la gracia de los dos ejemplos está exactamente en esta condición.

Finalmente, recordamos la fórmula de proyección sobre la recta generada por un vector $v \neq 0$:

$$P_{\sigma(v)} Y = \frac{\langle Y, v \rangle}{\langle v, v \rangle} v.$$

Ejemplo 1

Los vectores que entrega la tabla son

$$\mathbf{1} = (1, 1, 1), \quad X = (-1, 0, 1), \quad Y = (y_1, y_2, y_3).$$

Paso 1 — Productos internos necesarios. Los calculo todos de una vez para no improvisar después:

- $\langle \mathbf{1}, \mathbf{1} \rangle = \frac{1}{3}(1 + 1 + 1) = 1.$
- $\langle X, X \rangle = \frac{1}{3}((-1)^2 + 0^2 + 1^2) = \frac{2}{3}.$
- $\langle \mathbf{1}, X \rangle = \frac{1}{3}(-1 + 0 + 1) = 0.$
- $\langle Y, \mathbf{1} \rangle = \frac{1}{3}(y_1 + y_2 + y_3) = \bar{y}$, donde escribo $\bar{y} = \frac{1}{3}(y_1 + y_2 + y_3).$
- $\langle Y, X \rangle = \frac{1}{3}(-y_1 + 0 + y_3) = \frac{y_3 - y_1}{3}.$

Paso 2 — Observación central. De los cálculos anteriores, $\langle \mathbf{1}, X \rangle = 0$, es decir, $\mathbf{1} \perp X$.

Subrayo este punto porque es justamente lo que permitirá que las proyecciones se sumen; no es un detalle accesorio.

Paso 3 — Proyecciones simples (sobre cada recta). Usando la fórmula recordada:

$$P_{\sigma(\mathbf{1})} Y = \frac{\langle Y, \mathbf{1} \rangle}{\langle \mathbf{1}, \mathbf{1} \rangle} \mathbf{1} = \bar{y} \mathbf{1},$$

$$P_{\sigma(X)} Y = \frac{\langle Y, X \rangle}{\langle X, X \rangle} X = \frac{(y_3 - y_1)/3}{2/3} X = \frac{y_3 - y_1}{2} X.$$

Paso 4 — Proyección sobre $\sigma(\mathbf{1}, X)$. Como $\mathbf{1} \perp X$, el par $\{\mathbf{1}, X\}$ es una **base ortogonal** del subespacio $\sigma(\mathbf{1}, X)$. Por el hecho clave del marco, la proyección sobre el plano se obtiene sumando las proyecciones sobre cada eje ortogonal:

$$E(Y | \sigma(\mathbf{1}, X)) = P_{\sigma(\mathbf{1}, X)} Y = \frac{\langle Y, \mathbf{1} \rangle}{\langle \mathbf{1}, \mathbf{1} \rangle} \mathbf{1} + \frac{\langle Y, X \rangle}{\langle X, X \rangle} X = \bar{y} \mathbf{1} + \frac{y_3 - y_1}{2} X.$$

Paso 5 — Verificación de la igualdad pedida. Comparando el Paso 4 con el Paso 3:

$$E(Y | \sigma(\mathbf{1}, X)) = \bar{y} \mathbf{1} + \frac{y_3 - y_1}{2} X = \underbrace{\bar{y} \mathbf{1}}_{E(Y | \sigma(\mathbf{1}))} + \underbrace{\frac{y_3 - y_1}{2} X}_{E(Y | \sigma(X))},$$

que es exactamente $E(Y | \sigma(\mathbf{1})) + E(Y | \sigma(X))$. La igualdad queda verificada.

Escrita por componentes (evaluando en $X = -1, 0, 1$), la proyección es

$$E(Y | \sigma(\mathbf{1}, X)) = \left(\bar{y} - \frac{y_3 - y_1}{2}, \bar{y}, \bar{y} + \frac{y_3 - y_1}{2} \right),$$

que no es otra cosa que la recta de regresión ajustada por mínimos cuadrados evaluada en cada punto.

¿A qué se debe la igualdad? A que $\langle \mathbf{1}, X \rangle = 0$, es decir, a la **ortogonalidad** entre los regresores $\mathbf{1}$ y X . Cuando los dos ejes son ortogonales, proyectar sobre el plano que generan equivale a proyectar por separado sobre cada eje y sumar, sin interferencia entre ambos. No hay nada "mágico": es el teorema de Pitágoras / la descomposición ortogonal en acción.

Ejemplo 2

Ahora la tabla cambia X por Z :

$$\mathbf{1} = (1, 1, 1), \quad Z = (1, 0, 1), \quad Y = (y_1, y_2, y_3).$$

Paso 1 — Productos internos necesarios.

- $\langle \mathbf{1}, \mathbf{1} \rangle = 1$.
- $\langle Z, Z \rangle = \frac{1}{3}(1 + 0 + 1) = \frac{2}{3}$.
- $\langle \mathbf{1}, Z \rangle = \frac{1}{3}(1 + 0 + 1) = \frac{2}{3}$.
- $\langle Y, \mathbf{1} \rangle = \bar{y} = \frac{1}{3}(y_1 + y_2 + y_3)$.
- $\langle Y, Z \rangle = \frac{1}{3}(y_1 + 0 + y_3) = \frac{y_1 + y_3}{3}$.

Paso 2 — Observación central. Ahora $\langle \mathbf{1}, Z \rangle = \frac{2}{3} \neq 0$, es decir, $\mathbf{1}$ y Z **no son ortogonales**. Por lo tanto, no estamos autorizados a sumar las proyecciones simples: hay que calcular la

proyección sobre $\sigma(\mathbf{1}, Z)$ resolviendo directamente las ecuaciones normales. Comento esto para no repetir el atajo del Ejemplo 1, que aquí sería incorrecto.

Paso 3 — Proyección sobre $\sigma(\mathbf{1}, Z)$ vía ecuaciones normales. Buscamos $P_{\sigma(\mathbf{1}, Z)}Y = a\mathbf{1} + bZ$ tal que el residuo $Y - (a\mathbf{1} + bZ)$ sea ortogonal a $\mathbf{1}$ y a Z . Esto da el sistema

$$\begin{aligned} a\langle \mathbf{1}, \mathbf{1} \rangle + b\langle Z, \mathbf{1} \rangle &= \langle Y, \mathbf{1} \rangle \implies a + \frac{2}{3}b = \frac{y_1 + y_2 + y_3}{3}, \\ a\langle \mathbf{1}, Z \rangle + b\langle Z, Z \rangle &= \langle Y, Z \rangle \implies \frac{2}{3}a + \frac{2}{3}b = \frac{y_1 + y_3}{3}. \end{aligned}$$

Restando la segunda ecuación de la primera se cancela el término en b :

$$\left(1 - \frac{2}{3}\right)a = \frac{(y_1 + y_2 + y_3) - (y_1 + y_3)}{3} \implies \frac{1}{3}a = \frac{y_2}{3} \implies a = y_2.$$

Sustituyendo $a = y_2$ en la segunda ecuación:

$$\frac{2}{3}y_2 + \frac{2}{3}b = \frac{y_1 + y_3}{3} \implies b = \frac{y_1 + y_3}{2} - y_2.$$

Por lo tanto,

$$E(Y | \sigma(\mathbf{1}, Z)) = y_2\mathbf{1} + \left(\frac{y_1 + y_3}{2} - y_2\right)Z.$$

Evalutando por componentes (con $\mathbf{1} = (1, 1, 1)$, $Z = (1, 0, 1)$):

$$E(Y | \sigma(\mathbf{1}, Z)) = \left(\frac{y_1 + y_3}{2}, y_2, \frac{y_1 + y_3}{2} \right).$$

Paso 4 — Suma de las proyecciones simples.

$$E(Y | \sigma(\mathbf{1})) = \bar{y}\mathbf{1} = \frac{y_1 + y_2 + y_3}{3}\mathbf{1},$$

$$E(Y | \sigma(Z)) = \frac{\langle Y, Z \rangle}{\langle Z, Z \rangle} Z = \frac{(y_1 + y_3)/3}{2/3} Z = \frac{y_1 + y_3}{2} Z.$$

Sumando y evaluando por componentes:

$$E(Y | \sigma(\mathbf{1})) + E(Y | \sigma(Z)) = \left(\frac{y_1 + y_2 + y_3}{3} + \frac{y_1 + y_3}{2}, \frac{y_1 + y_2 + y_3}{3}, \frac{y_1 + y_2 + y_3}{3} + \frac{y_1 + y_3}{2} \right).$$

Paso 5 — Comparación y conclusión. Basta mirar la segunda componente (la de ω_2):

$$[E(Y | \sigma(\mathbf{1}, Z))]_{\omega_2} = y_2 \quad \text{frente a} \quad [E(Y | \sigma(\mathbf{1})) + E(Y | \sigma(Z))]_{\omega_2} = \frac{y_1 + y_2 + y_3}{3}.$$

Estas dos cantidades coinciden solo si $y_2 = \frac{y_1+y_2+y_3}{3}$, es decir, solo en el caso particular $2y_2 = y_1 + y_3$. Para datos genéricos son distintas, de modo que

$$E(Y \mid \sigma(\mathbf{1}, Z)) \neq E(Y \mid \sigma(\mathbf{1})) + E(Y \mid \sigma(Z)),$$

que es la desigualdad pedida. La razón de fondo es la del Paso 2: como $\langle \mathbf{1}, Z \rangle \neq 0$, los subespacios $\sigma(\mathbf{1})$ y $\sigma(Z)$ se "solapan", y al sumar ambas proyecciones se cuenta dos veces la parte común; la proyección correcta sobre $\sigma(\mathbf{1}, Z)$ corrige ese solapamiento (eso es justo lo que hace el coeficiente $b = \frac{y_1+y_3}{2} - y_2$, que ya no es el de la regresión simple $\frac{y_1+y_3}{2}$).

Respuesta a la pregunta: ¿cuándo pueden considerarse M1 y M2 "encajonados"?

Los dos ejemplos muestran que conviene distinguir dos nociones que en la práctica suelen confundirse:

1. **Encajonamiento como inclusión de subespacios.** Siempre se tiene $\sigma(\mathbf{1}) \subseteq \sigma(\mathbf{1}, X_1) \subseteq \sigma(\mathbf{1}, X_1, X_2)$. En este sentido geométrico M1 está *siempre* encajonado en M2, sin condición alguna. Esto valida una sola cosa: comparar ajustes (M2 nunca ajusta peor que M1, porque proyecta sobre un espacio más grande, y la mejora es $\|Y - P_{\sigma(\mathbf{1}, X_1)} Y\|^2 - \|Y - P_{\sigma(\mathbf{1}, X_1, X_2)} Y\|^2 \geq 0$).
2. **Encajonamiento como descomposición aditiva de la contribución de cada predictor.** Esta es la propiedad que de verdad usa la práctica habitual ("ajusto con X_1 , luego agrego X_2 y le atribuyo a X_2 la mejora, sin que cambie lo demás"). Los ejemplos muestran que esto **no** es automático:

$$E(Y \mid \sigma(\mathbf{1}, X)) = E(Y \mid \sigma(\mathbf{1})) + E(Y \mid \sigma(X)) \iff \langle \mathbf{1}, X \rangle = 0,$$

es decir, **se cumple si y solo si los regresores son ortogonales** (Ejemplo 1), y falla cuando no lo son (Ejemplo 2).

De aquí el criterio que yo enunciaría:

Más allá de la inclusión formal de subespacios, M1 y M2 pueden tratarse como genuinamente "encajonados" —en el sentido fuerte de que el coeficiente de X_1 no cambia al añadir X_2 y la mejora de ajuste se atribuye limpiamente a X_2 — **solo cuando el nuevo predictor X_2 es ortogonal al subespacio generado por los regresores ya presentes, $X_2 \perp \sigma(\mathbf{1}, X_1)$.**

En términos de regresión, esto equivale a pedir que el coeficiente de X_2 en la regresión simple coincida con su coeficiente en la regresión múltiple. Cuando los predictores están correlacionados (caso Z), agregar X_2 *altera* el coeficiente de X_1 y la atribución aditiva deja de ser válida; en ese caso la forma correcta de "encajonar" es **ortogonalizar** primero, es decir, comparar Y contra la parte de X_2 que es residual respecto de $\sigma(\mathbf{1}, X_1)$ (esta es precisamente

la idea del teorema de Frisch–Waugh–Lovell). La moraleja crítica es que la receta "ajusto, agrego un predictor y veo cuál ajusta mejor" solo es interpretable de manera ingenua bajo ortogonalidad; en general puede ser engañosa.