



# 7 El término de error

Contraste las dos miradas del término de error, una debida a Gauss y la otra basada en el Teorema de la Proyección. Enfatique el estilo de análisis estadístico y el desarrollo metodológico que cada una de estas perspectivas implica.

---

## 0. Punto de partida común: fijar el objeto del que vamos a hablar

Antes de contrastar las dos miradas conviene fijar el escenario, porque ambas hablan del *mismo* objeto formal pero le atribuyen significados distintos. Comento esto explícitamente para no dar por sentado que "el término de error" significa lo mismo en las dos perspectivas: no lo significa, y ese es justamente el corazón de la pregunta.

Trabajamos con el modelo lineal

$$y = X\beta + \varepsilon$$

donde:

- $y \in \mathbb{R}^n$  es el vector de respuestas observadas,
- $X \in \mathbb{R}^{n \times p}$  es la matriz de diseño (supondremos  $\text{rango}(X) = p$  para que  $X^\top X$  sea invertible; comento este supuesto porque es lo que hace única la solución más abajo),
- $\beta \in \mathbb{R}^p$  es el vector de parámetros,
- $\varepsilon \in \mathbb{R}^n$  es el **término de error**.

La pregunta es: ¿qué es ese  $\varepsilon$ ? Hay dos respuestas, y conducen a dos estilos de hacer estadística.

---

# 1. La mirada de Gauss: el error como perturbación aleatoria con ley de probabilidad

## 1.1. Qué se postula

En la tradición de Gauss,  $\varepsilon$  es un objeto **primitivo**: es una variable aleatoria (un vector aleatorio) que existe *antes* de estimar nada. Representa el conjunto de causas no modeladas —error de medición, fluctuaciones, factores omitidos— concebidas como un sorteo del azar. Comento el matiz: aquí el error no se *deriva*, se *supone*; uno le impone una estructura probabilística.

Los supuestos clásicos (Gauss–Markov) son:

$$\mathbb{E}[\varepsilon] = 0, \quad \text{Var}(\varepsilon) = \sigma^2 I_n$$

Descompongo qué dice cada parte, sin saltarme nada:

1.  $\mathbb{E}[\varepsilon] = 0$ : en promedio el error no sesga la respuesta; toda la señal sistemática está en  $X\beta$ .
2.  $\text{Var}(\varepsilon) = \sigma^2 I_n$  encierra **dos** supuestos a la vez: la diagonal constante  $\sigma^2$  es **homocedasticidad** (igual dispersión para toda observación), y los ceros fuera de la diagonal son **no correlación** entre errores. Señalo que esto es una *hipótesis sobre la población*, no algo garantizado por la construcción.

Para hacer **inferencia** (tests, intervalos) Gauss agrega la ley concreta:

$$\varepsilon \sim \mathcal{N}(0, \sigma^2 I_n)$$

## 1.2. El argumento histórico de Gauss (por qué la normal y por qué mínimos cuadrados)

Vale la pena reconstruir el orden lógico de Gauss, porque ahí se ve el *estilo*:

1. Gauss parte de una intuición: el valor más plausible de una cantidad medida varias veces debería ser la media aritmética.
2. Se pregunta: ¿qué distribución de los errores hace que la media aritmética sea, efectivamente, el valor de **máxima verosimilitud**?

3. Resolviendo esa condición funcional, *deduce* que la densidad del error debe ser la curva normal. Es decir, la normal aparece como **consecuencia** de un principio de estimación, no como un capricho.
4. Maximizar la verosimilitud bajo errores normales equivale a **minimizar la suma de cuadrados**  $\sum_i \varepsilon_i^2$ . Así queda justificado el método de mínimos cuadrados *desde la probabilidad*.

Más tarde (Theoria Combinationis), Gauss da un segundo argumento más débil en supuestos pero muy potente: el **Teorema de Gauss–Markov**. Comento la diferencia para no confundir las dos justificaciones:

Bajo solo  $\mathbb{E}[\varepsilon] = 0$  y  $\text{Var}(\varepsilon) = \sigma^2 I$  (sin exigir normalidad), el estimador de mínimos cuadrados  $\hat{\beta}$  es **BLUE**: el de mínima varianza dentro de todos los estimadores lineales e insesgados.

### 1.3. Cómo se obtiene el estimador en esta mirada

Se define un criterio y se optimiza:

$$S(\beta) = \|y - X\beta\|^2 = (y - X\beta)^\top (y - X\beta)$$

Derivando e igualando a cero (paso explícito):

$$\frac{\partial S}{\partial \beta} = -2X^\top (y - X\beta) = 0 \implies X^\top X\hat{\beta} = X^\top y \implies \hat{\beta} = (X^\top X)^{-1} X^\top y$$

Clave conceptual: en esta mirada el criterio "sumar cuadrados" se justifica *probabilísticamente* (es la verosimilitud normal, o es lo que da el óptimo BLUE). La geometría no es el motor; la **ley de probabilidad** lo es.

### 1.4. Estilo de análisis estadístico que implica

- **Paramétrico e inferencial.** Se modela el proceso generador de datos, se asume una ley para el error y se estudian las **distribuciones muestrales** de los estimadores.
- Productos típicos: insesgadez  $\mathbb{E}[\hat{\beta}] = \beta$ , matriz de covarianzas  $\text{Var}(\hat{\beta}) = \sigma^2 (X^\top X)^{-1}$ , tests  $t$  y  $F$ , intervalos de confianza, verosimilitud, Cramér–Rao, eficiencia.

- Mentalidad: "**de abajo hacia arriba desde la probabilidad**" — primero la ley del azar, luego las propiedades del estimador como teoremas a demostrar.

## 2. La mirada del Teorema de la Proyección: el error como complemento ortogonal

### 2.1. Cambiar de escenario: de la probabilidad a la geometría

Aquí el punto de partida no es una ley de probabilidad sino un **espacio con producto interno**. Comento el cambio de escenario porque es radical: dejamos de preguntar "¿cómo se distribuye el error?" y pasamos a preguntar "¿qué parte de  $y$  no vive en el espacio de los regresores?".

Considero  $\mathbb{R}^n$  con el producto interno usual  $\langle u, v \rangle = u^\top v$  y la norma  $\|u\| = \sqrt{u^\top u}$ . Defino el subespacio generado por las columnas de  $X$ :

$$\mathcal{C}(X) = \{X\beta : \beta \in \mathbb{R}^p\} \subseteq \mathbb{R}^n$$

### 2.2. El Teorema de la Proyección

**Teorema (Proyección ortogonal).** Sea  $\mathcal{M}$  un subespacio cerrado de un espacio de Hilbert  $\mathcal{H}$ . Para todo  $y \in \mathcal{H}$  existe una **única** descomposición

Concretamente,  $y = \hat{y} + e$  con  $\hat{y} \in \mathcal{M}$  (la parte explicada) y  $e \perp \mathcal{M}$  (el error ortogonal).

Además  $\hat{y}$  es el punto de  $\mathcal{M}$  más cercano a  $y$ .

Aplico el teorema con  $\mathcal{M} = \mathcal{C}(X)$ . La descomposición es:

$$y = \underbrace{\hat{y}}_{\in \mathcal{C}(X)} + \underbrace{e}_{\perp \mathcal{C}(X)}$$

y aquí está el giro central que comento explícitamente: **el término de error  $e$  se define como el complemento ortogonal**, es decir, la parte de  $y$  que no puede expresarse como combinación lineal de las columnas de  $X$ . No se supone su ley; se construye geométricamente.

### 2.3. De la ortogonalidad salen las ecuaciones normales (sin derivar nada)

La condición  $e \perp \mathcal{C}(X)$  significa que  $e$  es ortogonal a cada columna de  $X$ , esto es:

$$X^\top e = 0 \iff X^\top (y - X\hat{\beta}) = 0 \iff X^\top X\hat{\beta} = X^\top y$$

Comento el contraste con la sección 1: obtenemos **exactamente las mismas ecuaciones normales**, pero ahora no aparecieron al derivar una suma de cuadrados, sino como la **traducción algebraica de la ortogonalidad**. La proyección es:

$$\hat{y} = Py, \quad P = X(X^\top X)^{-1}X^\top, \quad e = (I - P)y$$

donde  $P$  es la matriz de proyección (idempotente y simétrica:  $P^2 = P, P^\top = P$ ). Que minimizar  $\|y - X\beta\|^2$  y proyectar ortogonalmente coincidan **no es coincidencia**: el teorema dice que la proyección es el punto más cercano, así que mínimos cuadrados es, literalmente, proyección ortogonal.

### 2.4. Pitágoras: la descomposición de la variabilidad

Como  $\hat{y} \perp e$ , el Teorema de Pitágoras da de forma inmediata (sin supuestos distribucionales):

$$\|y\|^2 = \|\hat{y}\|^2 + \|e\|^2$$

que, centrando, es la identidad  $SCT = SCR + SCE$  del análisis de varianza. Señalo el punto pedagógico: la ANOVA no requiere normalidad para *existir*; es pura geometría. La normalidad solo se necesita después, para ponerle una distribución a los cocientes.

### 2.5. La versión profunda: el error en $L^2$ y la esperanza condicional

El teorema se vuelve aún más iluminador en el espacio de Hilbert  $L^2(\Omega)$  de variables aleatorias de cuadrado integrable, con producto interno

$$\langle U, V \rangle = \mathbb{E}[UV]$$

Comento por qué este espacio importa: en él la **ortogonalidad equivale a no correlación** (cuando las medias son cero,  $\langle U, V \rangle = \text{Cov}(U, V)$ ). Entonces:

- La **esperanza condicional**  $\mathbb{E}[Y | X]$  es la proyección ortogonal de  $Y$  sobre el subespacio de todas las funciones (de cuadrado integrable) de  $X$ .
- El error  $\varepsilon = Y - \mathbb{E}[Y | X]$  es, **por construcción del teorema**, ortogonal a toda función de  $X$ ; es decir, no correlacionado con los regresores.
- El **mejor predictor lineal** se obtiene proyectando sobre el subespacio más chico  $\{a + b^\top X\}$ .

Resultado conceptual que comento para que no quede como salto: en esta mirada la frase "el error no está correlacionado con los regresores" **no es un supuesto**, es una *propiedad automática* de la proyección. Lo que en Gauss era una hipótesis impuesta, aquí es un teorema gratuito.

## 2.6. Estilo de análisis estadístico que implica

- **Geométrico y libre de distribución.** Se razona con subespacios, ortogonalidad y descomposiciones; no hace falta postular la ley del error para *definir* el estimador.
- Productos típicos: matrices de proyección, descomposición de Pitágoras/ANOVA, geometría de la regresión, esperanza condicional como proyección, unificación de regresión–ANOVA–predicción bajo un mismo marco.
- Mentalidad: "**de arriba hacia abajo desde la estructura del espacio**" — la geometría dicta las ecuaciones, y la probabilidad se incorpora *después*, solo cuando se quiere inferir.

## 3. Contraste explícito

| Criterio                          | Mirada de Gauss                                                               | Mirada del Teorema de la Proyección                   |
|-----------------------------------|-------------------------------------------------------------------------------|-------------------------------------------------------|
| Naturaleza del error              | Objeto <b>primitivo</b> : variable aleatoria con ley supuesta                 | Objeto <b>derivado</b> : residuo ortogonal construido |
| No correlación / ortogonalidad    | <b>Supuesto</b> sobre la población ( $\text{Var}(\varepsilon) = \sigma^2 I$ ) | <b>Consecuencia</b> automática de proyectar           |
| Origen de las ecuaciones normales | Derivar y anular la suma de cuadrados                                         | Traducir la condición $X^\top e = 0$                  |
| Por qué mínimos cuadrados         | Verosimilitud normal / optimalidad BLUE                                       | La proyección <b>es</b> el punto más cercano          |
| Papel de la distribución          | Central y desde el inicio                                                     | Postergada; solo para inferir, no para estimar        |
| Estilo metodológico               | Inferencial, paramétrico, muestral (tests, IC, eficiencia)                    | Geométrico, estructural, libre de distribución        |
| Dirección del razonamiento        | De la probabilidad hacia las propiedades                                      | De la geometría del espacio hacia las ecuaciones      |

## Síntesis

Las dos miradas convergen en el **mismo estimador**  $\hat{\beta} = (X^\top X)^{-1} X^\top y$ , pero por caminos opuestos, y conviene no leer esa coincidencia como trivial:

- Gauss responde "**por qué es óptimo**": porque, dada una ley de probabilidad del error, mínimos cuadrados es el de máxima verosimilitud / mínima varianza. Su aporte es **inferencial**.
- La proyección responde "**por qué tiene esa forma**": porque estimar es separar  $y$  en lo que vive en  $\mathcal{C}(X)$  y lo ortogonal a ello. Su aporte es **estructural**.

Una distinción fina que vale la pena comentar para cerrar sin salto lógico: los **errores verdaderos**  $\varepsilon$  (objeto de Gauss) y los **residuos**  $e$  (objeto de la proyección) no son lo mismo — $e$  es una estimación de  $\varepsilon$ , ligada a  $X$  vía  $e = (I - P)\varepsilon$ —. La síntesis moderna usa ambas miradas en conjunto: la **geometría** explica la forma y las propiedades algebraicas del estimador, y la **probabilidad** de Gauss le añade la capa de inferencia (distribuciones, tests, intervalos) sobre esa estructura ya construida.