

Resumen para el examen

Estadística geométrica: L^2 , proyección y esperanza condicional

Documento de estudio consolidado a partir de las 8 preguntas de examen. Todas comparten **un mismo marco teórico** (enfoque “San Martín”): una base de datos es un **espacio empírico de probabilidad**, las variables son **funciones** sobre las etiquetas, y la **esperanza condicional es una proyección ortogonal** en el espacio de Hilbert L^2 . Domina este marco y las 8 preguntas se resuelven casi mecánicamente.

0. Marco teórico común (la llave de todo)

0.1 Espacio empírico de probabilidad

Una base de datos es la terna $(\Omega_n, \mathcal{P}(\Omega_n), P_n)$ donde:

- $\Omega_n = \{\omega_1, \dots, \omega_n\}$ es el **conjunto de etiquetas (labels)** = los **individuos estadísticos** (identifican cada fila de forma única). No confundir la etiqueta con el valor de una variable.
- Probabilidad **uniforme** (Laplace): $p_\omega = 1/n$, y $P_n(A) = |A|/n$.
- Una **variable** es una función $X : \Omega_n \rightarrow \text{Im}(X)$. Cada columna es una variable.

0.2 Partición inducida por una variable

Toda X con $\text{Im}(X) = \{x_1, \dots, x_r\}$ induce una **partición** de Ω_n en sus **fibras / bloques**: $A_i := X^{-1}(\{x_i\}) = \{\omega : X(\omega) = x_i\}$. No vacíos, disjuntos, cubren Ω_n . $\sigma(X)$ designa el **subespacio de funciones constantes sobre cada bloque**.

0.3 L^2 como espacio de Hilbert

$L^2(\Omega_n, \mathcal{P}(\Omega_n), P_n)$ con

$$\langle U, V \rangle = \mathbb{E}[UV] = \sum_{\omega} U(\omega)V(\omega)P_n(\{\omega\}) = \frac{1}{n} \sum_{i=1}^n U(\omega_i)V(\omega_i), \quad \|U\|^2 = \mathbb{E}[U^2].$$

Como Ω_n es finito, toda función está en L^2 y el espacio es completo (Hilbert).

0.4 Esperanza condicional = proyección ortogonal

$$E(Y \mid \sigma(X)) = P_{\sigma(X)}Y = \text{proyección ortogonal de } Y \text{ sobre } \sigma(X).$$

Es el único $\hat{Y} \in \sigma(X)$ que minimiza $\|Y - \hat{Y}\|^2$ (mejor predicción en media cuadrática). En cada individuo vale el **promedio de Y sobre su bloque**:

$$E(Y \mid \sigma(X))(\omega) = \frac{1}{|B|} \sum_{\omega' \in B} Y(\omega'), \quad B = \text{bloque de } \omega.$$

Teorema de la Proyección (hecho central): el residuo $Z = Y - \hat{Y}$ es ortogonal a todo el subespacio: $\langle Z, W \rangle = 0$ para todo $W \in \sigma(X)$.

Dato clave: la función constante **1** siempre está en $\sigma(X)$.

0.5 Tres consecuencias inmediatas

1. **Inssegamiento / esperanza total:** como $\mathbf{1} \in \sigma(X)$ y $Z \perp \sigma(X)$, $\mathbb{E}[Z] = \langle Z, \mathbf{1} \rangle = 0 \Rightarrow \mathbb{E}[E(Y | \sigma(X))] = \mathbb{E}[Y]$.
2. **Pitágoras (norma):** $\|Y\|^2 = \|\hat{Y}\|^2 + \|Z\|^2$.
3. **Descomposición de varianza (ANOVA):**

$$\text{Var}(Y) = \underbrace{\text{Var}(E(Y | \sigma(X)))}_{\text{entre bloques (SC}_{\text{inter}})} + \underbrace{\mathbb{E}(\text{Var}(Y | \sigma(X)))}_{\text{dentro (SC}_{\text{intra}})}.$$

0.6 Fórmulas de proyección útiles

- Sobre una recta generada por $v \neq 0$: $P_{\sigma(v)}Y = \frac{\langle Y, v \rangle}{\langle v, v \rangle}v$.
- **Suma de proyecciones SOLO si hay ortogonalidad:** si $\mathcal{M} \perp \mathcal{N}$ entonces $P_{\mathcal{M} \oplus \mathcal{N}} = P_{\mathcal{M}} + P_{\mathcal{N}}$. Si no, falla (ecuaciones normales).

1. Base de datos (reformas fiscales)

Planteo: tabla País×Año (20 individuos, 9 variables). Espacio $\mathbb{R}^{20}$, pesos 1/20.

1. **Etiquetas:** los pares (País, Año): $I = \{(FRA, 2015), \dots\}$, $|I| = 4 \times 5 = 20$. (El enunciado nombra 5 países pero la tabla trae 4.)
2. **Partición por FR:** binaria $\Rightarrow$ 2 clases: $A_0 = \{FR = 0\}$ (2015–16, $|A_0| = 8$) y $A_1 = \{FR = 1\}$ (2017–19, $|A_1| = 12$).
3. $E(\text{Inv} | \text{Año})$: 5 clases (4 individuos c/u), valor = promedio del año: 2015 $\rightarrow$ 18.175, 2016 $\rightarrow$ 17.300, 2017 $\rightarrow$ 18.825, 2018 $\rightarrow$ 21.000, 2019 $\rightarrow$ 18.325. Media global $\bar{x} = 374,5/20 = 18,725$.
4. r^2 e interpretación: razón de correlación η^2 .

Cálculo del r^2 :

$$SC_{\text{inter}} = \sum_a n_a (\bar{x}_a - \bar{x})^2 = 30,715, \quad SC_{\text{total}} = \sum_i x_i^2 - 20\bar{x}^2 = 53,8975, \quad SC_{\text{intra}} = 23,1825.$$

$$r^2 = \frac{SC_{\text{inter}}}{SC_{\text{total}}} = \frac{30,715}{53,8975} \approx 0,570 \text{ } (\approx 57 \%).$$

Interpretación geométrica: $E(\text{Inv} | \text{Año})$ es la proyección ortogonal de Inv sobre el subespacio F de funciones constantes por año; el residuo es ortogonal a F . Con vectores centrados, $\|\text{Inv} - \bar{x}\|^2 = \|\hat{Y} - \bar{x}\|^2 + \|\text{Inv} - \hat{Y}\|^2$ y $r^2 = \cos^2 \theta$, con $\cos \theta = \sqrt{0,57} \approx 0,755 \Rightarrow \theta \approx 41^\circ$.

2. Coherencia en una base de datos (falacia ecológica)

Planteo: votos identificados por folio único; cada folio tiene opción de voto y pertenece a mesa $\rightarrow$ local $\rightarrow$ distrito.

1. **Etiquetas = los folios.** La opción de voto NO es etiqueta, es una variable $V : \Omega_N \rightarrow \{\text{cand.1, cand.2, nulo, blanco}\}$. Los folios deben ser únicos, exhaustivos y mutuamente excluyentes.
2. **Mesa, Local, Distrito SÍ son variables**, con particiones jerárquicas/encajonadas: $\sigma(D) \subseteq \sigma(L) \subseteq \sigma(M) \subseteq L^2(\Omega_N)$ (Mesa más fina, Distrito más gruesa).

3. **Tasa de cesantía comunal** C : (i) *coherencia jerárquica*: asignación unívoca folio $\rightarrow$ comuna, $K : \Omega_N \rightarrow \{\text{comunidades}\}$; (ii) *medibilidad*: C constante por comuna, i.e. $C \in \sigma(K)$.

El punto de fondo (falacia ecológica): como $C \in \sigma(K)$ es constante dentro de cada comuna, solo aporta variabilidad *entre* comunas. Toda regresión factoriza por $E(V | C) = E(V | \sigma(K))$:

$$\text{Var}(V) = \underbrace{\text{Var}(E(V | \sigma(K)))}_{\text{entre comunas (ve } C)} + \underbrace{\mathbb{E}(\text{Var}(V | \sigma(K)))}_{\text{dentro: invisible}}.$$

Atribuir el efecto agregado al individuo es la **falacia ecológica** (Robinson, 1950); puede invertirse (**paradoja de Simpson**). Para el nivel individual hace falta una variable definida sobre el folio con partición más fina que la comunal.

3. Modelos lineales encajonados (nested)

Modelos: M1: $E(Y | X_1) = \alpha_0 + \alpha_1 X_1$; M2: $E(Y | X_1, X_2) = \alpha_0 + \alpha_1 X_1 + \alpha_2 X_2$.

Marco: Ω_3 , uniforme $1/3$, $\langle U, V \rangle = \frac{1}{3} \sum U_i V_i$.

Ejemplo 1 — regresores ORTOGONALES (se cumple la aditividad). $\mathbf{1} = (1, 1, 1)$, $X = (-1, 0, 1)$. Como $\langle \mathbf{1}, X \rangle = 0$:

$$E(Y | \sigma(\mathbf{1}, X)) = \bar{y} \mathbf{1} + \frac{y_3 - y_1}{2} X = E(Y | \sigma(\mathbf{1})) + E(Y | \sigma(X)). \checkmark$$

La igualdad se debe a la **ortogonalidad**: proyectar sobre el plano = sumar proyecciones sobre cada eje (Pitágoras).

Ejemplo 2 — regresores NO ortogonales (falla). $\mathbf{1} = (1, 1, 1)$, $Z = (1, 0, 1)$, $\langle \mathbf{1}, Z \rangle = \frac{2}{3} \neq 0$. Por **ecuaciones normales**:

$$a = y_2, \quad b = \frac{y_1 + y_3}{2} - y_2, \quad E(Y | \sigma(\mathbf{1}, Z)) = \left(\frac{y_1 + y_3}{2}, y_2, \frac{y_1 + y_3}{2} \right).$$

En ω_2 : y_2 vs $\frac{y_1 + y_2 + y_3}{3}$; coinciden solo si $2y_2 = y_1 + y_3$. En general la suma de proyecciones cuenta dos veces la parte común.

Respuesta (¿cuándo son “encajonados”?):

1. **Inclusión de subespacios**: $\sigma(\mathbf{1}) \subseteq \sigma(\mathbf{1}, X_1) \subseteq \sigma(\mathbf{1}, X_1, X_2)$ *siempre*. Solo valida comparar ajustes (M2 nunca ajusta peor).
2. **Descomposición aditiva**: se cumple *si y solo si* $X_2 \perp \sigma(\mathbf{1}, X_1)$.

Criterio: M1 y M2 son “encajonados” en sentido fuerte solo cuando $X_2 \perp \sigma(\mathbf{1}, X_1)$. Si los predictores están correlacionados, agregar X_2 altera el coeficiente de X_1 . La forma correcta es **ortogonalizar primero (teorema de Frisch–Waugh–Lovell)**. La receta ingenua “ajusto, agrego, comparo” solo es interpretable bajo ortogonalidad.

4. Teorema de Pitágoras (R^2 vs r_n^2)

Setup: $Y = \hat{Y} + Z$, $\hat{Y} = E(Y | \sigma(X))$, $Z = Y - \hat{Y}$, $\|Y\|^2 = \|\hat{Y}\|^2 + \|Z\|^2$.

Parte 1 — $\mathbb{E}(Y - E(Y | \sigma(X))) = 0$: como $\mathbf{1} \in \sigma(X)$ y $Z \perp \sigma(X)$, $\langle Z, \mathbf{1} \rangle = \mathbb{E}[Z] = 0$. Consecuencia: $\mathbb{E}[\hat{Y}] = \mathbb{E}[Y] =: \mu$.

Parte 2 — equivalencia (1) $\Leftrightarrow$ (2): con $\text{Var}(U) = \mathbb{E}[U^2] - [\mathbb{E}(U)]^2$ y $\mathbb{E}[\hat{Y}] = \mathbb{E}[Y] = \mu$, $\mathbb{E}[Z] = 0$. Restando μ^2 a $\mathbb{E}[Y^2] = \mathbb{E}[\hat{Y}^2] + \mathbb{E}[Z^2]$:

$$\text{Var}(Y) = \text{Var}(E(Y | \sigma(X))) + \text{Var}(Y - E(Y | \sigma(X))).$$

“Restar μ^2 ” es reversible $\Rightarrow$ (1) y (2) equivalentes.

Parte 3 — comparar. Con $a = \|\hat{Y}\|^2 = \mathbb{E}[\hat{Y}^2]$, $b = \|Y\|^2 = \mathbb{E}[Y^2]$:

$$r_n^2 = \frac{\|E(Y | \sigma(X))\|^2}{\|Y\|^2} = \frac{a}{b} \text{ (crudos)}, \quad R^2 = \frac{\text{Var}(\hat{Y})}{\text{Var}(Y)} = \frac{a - \mu^2}{b - \mu^2} \text{ (varianzas)}.$$

Como $b = a + \mathbb{E}[Z^2] \Rightarrow a \leq b$, y por Jensen $a \geq \mu^2$: $\mu^2 \leq a \leq b$. Producto cruzado:

$$R^2 \leq r_n^2.$$

Igualdad sii $\mu = \mathbb{E}[Y] = 0$ (centrada) o $a = b$ ($Y = \hat{Y}$ c.s.). R^2 es el genuino coeficiente de determinación (invariante a traslaciones); r_n^2 usa momentos crudos y **sobrestima**.

Ejemplo: $\Omega = \{1, 2, 3, 4\}$ uniforme, bloques $\{1, 2\}, \{3, 4\}$, $Y = (0, 2, 2, 4)$, $\hat{Y} = (1, 1, 3, 3)$, $\mu = 2$, $b = 6$, $a = 5$, $\text{Var}(Y) = 2$, $\text{Var}(\hat{Y}) = 1$. Entonces $r_n^2 = \frac{5}{6} \approx 0,833$, $R^2 = \frac{1}{2} = 0,5$ ($R^2 < r_n^2$).

5. Esperanza condicional (construcción y ley total)

Parte 1 — $P : H \rightarrow M$ es proyección ortogonal (M cerrado):

- **Definición:** $Px := y_0$, el único minimizador de $\|x - y\|$ sobre M .
- **Lema clave:** y_0 minimiza $\iff (x - y_0) \perp M$. ($\Leftarrow$) Pitágoras; ($\Rightarrow$) $\varphi(t) = \|x - (y_0 + tm)\|^2$ tiene mínimo en $t = 0 \Rightarrow \langle x - y_0, m \rangle = 0$.
- **Lineal** (por unicidad), **idempotente** ($P^2 = P$), **autoadjunto** ($\langle Px, z \rangle = \langle x, Pz \rangle$), **contracción** ($\|P\| \leq 1$), $H = M \oplus M^\perp$.

Parte 2 — la proyección ES la esperanza condicional: en $L^2(\Omega, \mathcal{F}, P)$ con $\langle X, Y \rangle = \mathbb{E}[XY]$, $M = L^2(\Omega, \mathcal{G}, P)$ es cerrado. La definición de $E[X | \mathcal{G}]$ ($\mathcal{G}$ -medible con $\mathbb{E}[(X - Z)W] = 0 \forall W \in M$) es exactamente la condición de ortogonalidad $\Rightarrow E[X | \mathcal{G}] = PX$ (mejor predicción en media cuadrática).

Parte 3 — $\mathbb{E}[E(Y | \sigma(X))] = \mathbb{E}(Y)$: como $\mathbf{1} \in M$ y $Y - \hat{Y} \perp M$:

$$\mathbb{E}[Y] - \mathbb{E}[\hat{Y}] = \langle Y - \hat{Y}, \mathbf{1} \rangle = 0.$$

Verificación: $\hat{Y}|_{B_j} = \mathbb{E}[Y | B_j]$ y $\mathbb{E}[\hat{Y}] = \sum_j P(B_j)\mathbb{E}[Y | B_j] = \mathbb{E}[Y]$ (ley de la esperanza total).

6. Igualdad del paralelogramo

Enunciado: en un espacio con producto interno, $\|x + y\|^2 + \|x - y\|^2 = 2\|x\|^2 + 2\|y\|^2$.

1. Demostración: expandir con $\|v\|^2 = \langle v, v \rangle$, bilinealidad y simetría: $\|x \pm y\|^2 = \|x\|^2 \pm 2\langle x, y \rangle + \|y\|^2$. Al sumar, los cruzados $\pm 2\langle x, y \rangle$ se cancelan.

2. Relevancia para la esperanza condicional: es una **proyección ortogonal en L^2** , cuya existencia/unicidad (Teorema de la Proyección) usa la igualdad: para una sucesión minimizante (Y_n) ,

$$\|Y_m - Y_n\|^2 = 2\|X - Y_n\|^2 + 2\|X - Y_m\|^2 - 4\left\|X - \frac{Y_n + Y_m}{2}\right\|^2 \leq 2\|X - Y_n\|^2 + 2\|X - Y_m\|^2 - 4d^2 \rightarrow 0,$$

luego (Y_n) es de Cauchy; por completitud converge a $Y^* \in M$. Sin producto interno (norma sin la igualdad) el argumento se rompe.

3. $\|\cdot\|_\infty$ en $\mathbb{R}^n$ ($n \geq 2$): $x = e_1$, $y = e_2$. $\|x\|_\infty = \|y\|_\infty = 1$, $\|x \pm y\|_\infty = 1$. LI= $1 + 1 = 2$, LD= $2 + 2 = 4$. $2 \neq 4 \Rightarrow$ falla.

4. $\|\cdot\|_\infty$ en $C[0,1]$: $F(x) = 1$, $G(x) = x$. $\|F\|_\infty = \|G\|_\infty = 1$, $\|F + G\|_\infty = 2$, $\|F - G\|_\infty = 1$. LI= $4 + 1 = 5$, LD= 4. $5 \neq 4 \Rightarrow$ falla.

7. El término de error — dos miradas

Modelo: $y = X\beta + \varepsilon$, $\text{rango}(X) = p$. Ambas llegan al mismo $\hat{\beta} = (X^\top X)^{-1}X^\top y$ por caminos opuestos.

Mirada de Gauss (probabilística). ε es objeto **primitivo** con ley supuesta: $\mathbb{E}[\varepsilon] = 0$, $\text{Var}(\varepsilon) = \sigma^2 I_n$ (homocedasticidad + no correlación); para inferir $\varepsilon \sim \mathcal{N}(0, \sigma^2 I_n)$. La normal surge de exigir que la media sea máximo-verosímil $\Rightarrow$ MV = minimizar $\sum \varepsilon_i^2$. Sin normalidad, Gauss–Markov: $\hat{\beta}$ es **BLUE**. Estilo: paramétrico, inferencial ($\text{Var}(\hat{\beta}) = \sigma^2(X^\top X)^{-1}$, tests t, F , IC).

Mirada de la Proyección (geométrica). $y = \hat{y} + e$, $\hat{y} \in \mathcal{C}(X)$, $e \perp \mathcal{C}(X)$. El error **se define** como complemento ortogonal. Ecuaciones normales = ortogonalidad: $X^\top e = 0$. $P = X(X^\top X)^{-1}X^\top$, $\hat{y} = Py$, $e = (I - P)y$. Pitágoras = ANOVA sin distribución: $\|y\|^2 = \|\hat{y}\|^2 + \|e\|^2$. En L^2 , la no correlación del error con los regresores es **teorema**, no supuesto. Estilo: geométrico, libre de distribución.

Criterio	Gauss	Proyección
Naturaleza del error	Primitivo (v.a. con ley)	Derivado (residuo ortogonal)
No correlación	Supuesto	Consecuencia automática
Ecuaciones normales	Anular $\partial S / \partial \beta$	Traducir $X^\top e = 0$
Por qué MCO	Verosimilitud normal / BLUE	Proyección = punto más cercano
Distribución	Central desde el inicio	Postergada (solo para inferir)
Estilo	Inferencial/paramétrico	Geométrico/estructural

Síntesis: Gauss responde *por qué es óptimo* (inferencial); la proyección, *por qué tiene esa forma* (estructural). Distinción fina: errores verdaderos $\varepsilon \neq$ residuos $e = (I - P)\varepsilon$.

8. Independencia de funciones ($n = 13$ primo)

Setup: Ω_n empírico uniforme, $X : \Omega_{13} \rightarrow \{x_1, \dots, x_r\}$, $Y : \Omega_{13} \rightarrow \{y_1, \dots, y_q\}$.

1. **¿ r arbitrario?** No: $1 \leq r \leq n$, pues $n = \sum_{i=1}^r |A_i| \geq r$ (bloques no vacíos). $r = 1 \iff X$ constante; $r = n \iff X$ inyectiva. Con $n = 13$: $r \in \{1, \dots, 13\}$.

2. **Partición de (X, Y) :** la fibra es $(X, Y)^{-1}(\{(x_i, y_j)\}) = A_i \cap B_j$, luego la partición es $\{A_i \cap B_j : A_i \cap B_j \neq \emptyset\}$: el **refinamiento común** de $\{A_i\}$ y $\{B_j\}$ (más bloques $\leq r \cdot q$ y $\leq n$).

3. **¿Qué Y son independientes de X fija?** Independencia $\iff P(X = x_i, Y = y_j) = P(X = x_i)P(Y = y_j)$. En el espacio empírico:

$$\frac{|A_i \cap B_j|}{13} = \frac{|A_i|}{13} \cdot \frac{|B_j|}{13} \iff |A_i \cap B_j| = \frac{|A_i||B_j|}{13}.$$

El lado izquierdo es entero $\Rightarrow 13 \mid |A_i||B_j|$. Como **13 es primo** (Euclides): $13 \mid |A_i|$ o $13 \mid |B_j|$, y como $1 \leq |A_i|, |B_j| \leq 13$, esto fuerza $|A_i| = 13$ (X constante) o $|B_j| = 13$ (Y constante).

- **X no constante** ($r \geq 2$): $\Rightarrow Y$ debe ser constante ($q = 1$).
- **X constante:** toda Y es independiente de X .

Papel de la primalidad de 13: la independencia exige $|A_i \cap B_j| = |A_i||B_j|/n$ entero; dos variables no triviales independientes requerirían $n = a \cdot b$ con $1 < a, b < n$, imposible si n es primo. Por eso sobre Ω_{13} dos variables solo pueden ser independientes si al menos una es constante. Con n compuesto (p.ej. $n = 12$) sí existirían no constantes genuinamente independientes.

Apéndice — Conceptos transversales

- **Etiqueta vs. variable:** la etiqueta identifica; la variable describe (preguntas 1, 2, 8).
- **Partición** / $\sigma(X)$: fibras de la variable; $\sigma(X)$ = funciones constantes por bloque.
- **Esperanza condicional = proyección ortogonal** = promedio por bloque = mejor predictor.
- **Teorema de la Proyección** $\Rightarrow$ residuo ortogonal $\Rightarrow$ esperanza total, Pitágoras, ANOVA.
- **Ortogonalidad lo es todo:** proyecciones se suman solo si los subespacios son ortogonales (p. 3); no correlación $\equiv$ ortogonalidad en L^2 centrado (p. 7).
- R^2 (**centrado**) $\leq r_n^2$ (**crudo**); iguales si $\mu = 0$ o ajuste perfecto (p. 4).
- **Norma del supremo** no viene de producto interno (falla paralelogramo) $\Rightarrow$ no sirve para definir esperanza condicional (p. 6).