

Resumen para el examen

Estadística geométrica en L^2 : proyección, esperanza condicional y MCO

Cómo usar este resumen. Domina el §0 (la “llave”): todo lo demás se deduce de él. Cada pregunta está dividida en sus **incisos** tal como aparecen en el enunciado. Los recuadros azules marcan lo que hay que poder reproducir de memoria. Al final, tres tablas de repaso.

0. Marco teórico común (la llave de todo)

0.1 Espacio empírico de probabilidad

Una base de datos es la terna $(\Omega_n, \mathcal{P}(\Omega_n), P_n)$ donde:

- $\Omega_n = \{\omega_1, \dots, \omega_n\}$ es el **conjunto de etiquetas (labels)** = los **individuos estadísticos** (identifican cada fila de forma única). La etiqueta *identifica*; la variable *describe*. No confundirlas.
- $\mathcal{P}(\Omega_n)$ es el σ -álgebra trivial (todas las partes): Ω_n finito $\Rightarrow$ todo subconjunto es evento.
- Probabilidad **uniforme** (Laplace): $p_\omega = 1/n$, y $P_n(A) = |A|/n$.
- Una **variable** es una función $X : \Omega_n \rightarrow \text{Im}(X)$. Cada columna es una variable.

0.2 Partición inducida por una variable

Toda X con $\text{Im}(X) = \{x_1, \dots, x_r\}$ induce una **partición** de Ω_n en sus **fibras / bloques**: $A_i := X^{-1}(\{x_i\}) = \{\omega : X(\omega) = x_i\}$. Es partición porque los bloques son *no vacíos* ($x_i \in \text{Im} X$), *disjuntos* (X es función) y *cubren* Ω_n . $\sigma(X)$ designa el **subespacio de funciones constantes sobre cada bloque** (dim = n° de bloques).

0.3 L^2 como espacio de Hilbert

$L^2(\Omega_n, \mathcal{P}(\Omega_n), P_n)$ con

$$\langle U, V \rangle = \mathbb{E}[UV] = \sum_{\omega} U(\omega)V(\omega)P_n(\{\omega\}) = \frac{1}{n} \sum_{i=1}^n U(\omega_i)V(\omega_i), \quad \|U\|^2 = \mathbb{E}[U^2].$$

Como Ω_n es finito, toda función está en L^2 y el espacio es completo (Hilbert) $\Rightarrow$ vale el Teorema de la Proyección.

0.4 Esperanza condicional = proyección ortogonal

$$E(Y \mid \sigma(X)) = P_{\sigma(X)}Y = \text{proyección ortogonal de } Y \text{ sobre } \sigma(X).$$

Es el único $\hat{Y} \in \sigma(X)$ que minimiza $\|Y - \hat{Y}\|^2$ (mejor predicción en media cuadrática). En cada individuo vale el **promedio de Y sobre su bloque**:

$$E(Y \mid \sigma(X))(\omega) = \frac{1}{|B|} \sum_{\omega' \in B} Y(\omega'), \quad B = \text{bloque de } \omega.$$

Teorema de la Proyección (hecho central): el residuo $Z = Y - \hat{Y}$ es ortogonal a todo el subespacio: $\langle Z, W \rangle = 0$ para todo $W \in \sigma(X)$.

Dato clave: la constante $\mathbf{1}$ siempre está en $\sigma(X)$; como $\mathbb{E}[Z] = \langle Z, \mathbf{1} \rangle$, la ortogonalidad da $\mathbb{E}[Z] = 0$.

0.5 Tres consecuencias inmediatas

1. **Insesgamiento / esperanza total:** $\mathbf{1} \in \sigma(X)$, $Z \perp \sigma(X) \Rightarrow \mathbb{E}[Z] = 0 \Rightarrow \mathbb{E}[E(Y | \sigma(X))] = \mathbb{E}[Y]$.
2. **Pitágoras (norma):** $\|Y\|^2 = \|\hat{Y}\|^2 + \|Z\|^2$.
3. **Descomposición de varianza (ANOVA):**

$$\text{Var}(Y) = \underbrace{\text{Var}(E(Y | \sigma(X)))}_{\text{entre bloques (SC}_{\text{inter}})} + \underbrace{\mathbb{E}(\text{Var}(Y | \sigma(X)))}_{\text{dentro (SC}_{\text{intra}})}.$$

0.6 Fórmulas de proyección útiles

- Sobre una recta generada por $v \neq 0$: $P_{\sigma(v)}Y = \frac{\langle Y, v \rangle}{\langle v, v \rangle} v$.
- **Suma de proyecciones SOLO si hay ortogonalidad:** si $\mathcal{M} \perp \mathcal{N}$ entonces $P_{\mathcal{M} \oplus \mathcal{N}} = P_{\mathcal{M}} + P_{\mathcal{N}}$. Si no, falla (ecuaciones normales).

Mapa mental. Variable $\rightarrow$ partición $\rightarrow$ subespacio $\sigma(X) \rightarrow$ proyección = esperanza condicional = promedio por bloque. De ahí: residuo ortogonal, esperanza total, Pitágoras, ANOVA, R^2 . Toda la materia es una idea geométrica repetida.

1. Base de datos (reformas fiscales)

Planteo: tabla País×Año, **20 individuos** (4 países $\times$ 5 años), 9 variables. Espacio $\mathbb{R}^{20}$, pesos $1/20$. *Trampa:* el enunciado nombra 5 países pero la tabla trae 4.

Inciso 1 — Etiquetas. Los pares (País, Año): $I = \{(FRA, 2015), \dots, (ESP, 2019)\}$, $|I| = 4 \times 5 = 20$, cada label pesa $1/20$. Ni país ni año por separado identifican: hace falta el par.

Inciso 2 — Partición por FR. FR es binaria $\Rightarrow$ 2 clases: $A_0 = \{FR = 0\}$ (2015–16, sin reforma, $|A_0| = 8$) y $A_1 = \{FR = 1\}$ (2017–19, con reforma, $|A_1| = 12$).

Inciso 3 — $E(\text{Inv} | \text{Año})$. Año $\rightarrow$ 5 clases (4 individuos c/u); valor = promedio del año:

Año	FRA	DEU	BEL	ESP	Suma	Promedio
2015	19.3	18.5	18.0	16.9	72.7	18.175
2016	17.1	17.0	17.1	18.0	69.2	17.300
2017	15.6	19.7	20.2	19.8	75.3	18.825
2018	21.9	20.5	21.2	20.4	84.0	21.000
2019	16.7	18.4	19.4	18.8	73.3	18.325

La media global se conserva (insesgamiento): $\bar{x} = 374,5/20 = 18,725$.

Inciso 4 — Cálculo de r^2 e interpretación. Razón de correlación η^2 (proporción de varianza explicada por el Año):

$$SC_{\text{inter}} = \sum_a n_a (\bar{x}_a - \bar{x})^2 = 4 \times 7,67875 = 30,715, \quad SC_{\text{total}} = \sum_i x_i^2 - 20\bar{x}^2 = 53,8975,$$

$$SC_{\text{intra}} = 23,1825, \quad r^2 = \frac{SC_{\text{inter}}}{SC_{\text{total}}} = \frac{30,715}{53,8975} \approx 0,570 (\approx 57\%).$$

Interpretación geométrica: $E(\text{Inv} \mid \text{Año}) = P_F(\text{Inv})$ es la proyección ortogonal de Inv sobre el subespacio F de funciones constantes por año; el residuo es ortogonal a F . Con vectores centrados, $\|\text{Inv} - \bar{x}\|^2 = \|\hat{Y} - \bar{x}\|^2 + \|\text{Inv} - \hat{Y}\|^2$ y $r^2 = \cos^2 \theta$, con $\cos \theta = \sqrt{0,57} \approx 0,755 \Rightarrow \theta \approx 41^\circ$.

2. Coherencia en una base de datos (falacia ecológica)

Planteo: votos con folio único, opción $\in \{\text{cand.1}, \text{cand.2}, \text{nulo}, \text{blanco}\}$; cada folio en mesa $\rightarrow$ local $\rightarrow$ distrito.

Inciso 1 — Etiquetas. Son los folios $(\Omega_N, p_\omega = 1/N)$. La **opción de voto NO es etiqueta:** es una variable $V : \Omega_N \rightarrow \{\text{cand.1}, \text{cand.2}, \text{nulo}, \text{blanco}\}$. Confundir folio con valor de variable es el error de fondo. Los folios deben ser únicos, exhaustivos y mutuamente excluyentes.

Inciso 2 — ¿Mesa/Local/Distrito son variables? Sí: funciones bien definidas sobre los folios, $M, L, D : \Omega_N \rightarrow \{\cdot\}$. Sus particiones son **jerárquicas/encajonadas** (cada mesa en un único local, cada local en un único distrito), luego Mesa refina a Local que refina a Distrito:

$$\sigma(D) \subseteq \sigma(L) \subseteq \sigma(M) \subseteq L^2(\Omega_N).$$

Existe la función de paso mesa $\rightarrow$ local $\rightarrow$ distrito, no al revés (lo fino determina lo grueso).

Inciso 3 — Condiciones para la tasa de cesantía comunal C . Para ser variable de la base, $C : \Omega_N \rightarrow \mathbb{R}$ (cesantía de la comuna del folio) debe cumplir: (i) *coherencia jerárquica:* asignación unívoca folio $\rightarrow$ comuna, $K : \Omega_N \rightarrow \{\text{comunidades}\}$ compatible con la jerarquía; (ii) *medibilidad:* C constante por comuna, i.e. $C \in \sigma(K)$.

El punto de fondo (falacia ecológica): como $C \in \sigma(K)$ es constante dentro de cada comuna, solo aporta variabilidad *entre* comunas. Toda regresión factoriza por $E(V \mid C) = E(V \mid \sigma(K))$:

$$\text{Var}(V) = \underbrace{\text{Var}(E(V \mid \sigma(K)))}_{\text{entre comunas (ve } C)} + \underbrace{\mathbb{E}(\text{Var}(V \mid \sigma(K)))}_{\text{dentro: invisible}}.$$

Atribuir el efecto agregado al individuo es la **falacia ecológica** (Robinson, 1950); puede invertirse (**paradoja de Simpson:** a nivel comunal “más cesantía $\rightarrow$ más voto”, pero dentro de cada comuna lo contrario). Para el nivel individual hace falta una variable definida sobre el folio con partición más fina que la comunal.

3. Modelos lineales encajonados (nested)

Modelos: M1: $E(Y \mid X_1) = \alpha_0 + \alpha_1 X_1$; M2: $E(Y \mid X_1, X_2) = \alpha_0 + \alpha_1 X_1 + \alpha_2 X_2$. **Marco:** Ω_3 , uniforme $1/3$, $\langle U, V \rangle = \frac{1}{3} \sum U_i V_i$.

Ejemplo 1 — regresores ORTOGONALES (se cumple la aditividad). $\mathbf{1} = (1, 1, 1)$, $X = (-1, 0, 1)$. Productos: $\langle \mathbf{1}, X \rangle = 0$, $\langle X, X \rangle = \frac{2}{3}$, $\langle Y, \mathbf{1} \rangle = \bar{y}$, $\langle Y, X \rangle = \frac{y_3 - y_1}{3}$. Como $\mathbf{1} \perp X$, $\{\mathbf{1}, X\}$ es base ortogonal y

$$E(Y \mid \sigma(\mathbf{1}, X)) = \bar{y} \mathbf{1} + \frac{y_3 - y_1}{2} X = E(Y \mid \sigma(\mathbf{1})) + E(Y \mid \sigma(X)). \checkmark$$

La igualdad se debe a la **ortogonalidad:** proyectar sobre el plano = sumar proyecciones sobre cada eje.

Ejemplo 2 — regresores NO ortogonales (falla). $\mathbf{1} = (1, 1, 1)$, $Z = (1, 0, 1)$, $\langle \mathbf{1}, Z \rangle = \frac{2}{3} \neq 0$. Por ecuaciones normales ($a\langle \mathbf{1}, \mathbf{1} \rangle + b\langle Z, \mathbf{1} \rangle = \langle Y, \mathbf{1} \rangle$, etc.):

$$a = y_2, \quad b = \frac{y_1 + y_3}{2} - y_2, \quad E(Y | \sigma(\mathbf{1}, Z)) = \left(\frac{y_1 + y_3}{2}, y_2, \frac{y_1 + y_3}{2} \right).$$

Comparando en ω_2 : y_2 vs $\frac{y_1 + y_2 + y_3}{3}$; coinciden solo si $2y_2 = y_1 + y_3$. Al solaparse $\sigma(\mathbf{1})$ y $\sigma(Z)$, sumar proyecciones cuenta dos veces la parte común.

Pregunta — ¿cuándo son “encajonados”?

1. **Inclusión de subespacios:** $\sigma(\mathbf{1}) \subseteq \sigma(\mathbf{1}, X_1) \subseteq \sigma(\mathbf{1}, X_1, X_2)$ *siempre*. Solo valida comparar ajustes (M2 nunca ajusta peor).
2. **Descomposición aditiva:** se cumple *si y solo si* $X_2 \perp \sigma(\mathbf{1}, X_1)$.

Criterio: M1 y M2 son “encajonados” en sentido fuerte solo cuando $X_2 \perp \sigma(\mathbf{1}, X_1)$ (el coef. de X_1 no cambia al agregar X_2). Si los predictores están correlacionados, agregar X_2 altera el coef. de X_1 . La forma correcta es **ortogonalizar primero (Frisch–Waugh–Lovell)**. La receta ingenua “ajusto, agrego, comparo” solo es interpretable bajo ortogonalidad.

4. Teorema de Pitágoras (R^2 vs r_n^2)

Setup: $Y = \hat{Y} + Z$, $\hat{Y} = E(Y | \sigma(X))$, $Z = Y - \hat{Y}$, (1) $\|Y\|^2 = \|\hat{Y}\|^2 + \|Z\|^2$. Recordatorio: $\mathbf{1} \in \sigma(X) \Rightarrow \langle Z, \mathbf{1} \rangle = \mathbb{E}[Z]$.

Inciso 1 — $\mathbb{E}(Y - E(Y | \sigma(X))) = 0$. $\mathbf{1} \in \sigma(X)$ y $Z \perp \sigma(X) \Rightarrow \langle Z, \mathbf{1} \rangle = \mathbb{E}[Z] = 0$. Consecuencia: $\mathbb{E}[\hat{Y}] = \mathbb{E}[Y] =: \mu$.

Inciso 2 — equivalencia (1) $\Leftrightarrow$ (2). Con $\text{Var}(U) = \mathbb{E}[U^2] - [\mathbb{E}U]^2$ y $\mathbb{E}[\hat{Y}] = \mathbb{E}[Y] = \mu$, $\mathbb{E}[Z] = 0$. Restando μ^2 a $\mathbb{E}[Y^2] = \mathbb{E}[\hat{Y}^2] + \mathbb{E}[Z^2]$ y agrupando $-\mu^2$ con el término de $\hat{Y}$:

$$\underbrace{\mathbb{E}[Y^2] - \mu^2}_{\text{Var}(Y)} = \underbrace{(\mathbb{E}[\hat{Y}^2] - \mu^2)}_{\text{Var}(\hat{Y})} + \underbrace{\mathbb{E}[Z^2]}_{\text{Var}(Z)}.$$

“Restar μ^2 ” es reversible $\Rightarrow$ (1) y (2) equivalentes (descansa en el inciso 1).

Inciso 3 — comparar R^2 y r_n^2 . Con $a = \|\hat{Y}\|^2 = \mathbb{E}[\hat{Y}^2]$, $b = \|Y\|^2 = \mathbb{E}[Y^2]$:

$$r_n^2 = \frac{\|E(Y | \sigma(X))\|^2}{\|Y\|^2} = \frac{a}{b} \text{ (crudos)}, \quad R^2 = \frac{\text{Var}(\hat{Y})}{\text{Var}(Y)} = \frac{a - \mu^2}{b - \mu^2} \text{ (centrados)}.$$

Orden: $b = a + \mathbb{E}[Z^2] \Rightarrow a \leq b$; por Jensen $a \geq \mu^2$. Producto cruzado ($R^2 \leq r_n^2 \iff \mu^2 a \leq \mu^2 b$):

$$R^2 \leq r_n^2.$$

Igualdad sii $\mu = \mathbb{E}[Y] = 0$ (centrada) o $a = b$ ($Y = \hat{Y}$ c.s.). R^2 es el genuino coeficiente de determinación (invariante a traslaciones); r_n^2 usa momentos crudos y **sobrestima**.

Ejemplo: $\Omega = \{1, 2, 3, 4\}$ uniforme, bloques $\{1, 2\}, \{3, 4\}$, $Y = (0, 2, 2, 4)$, $\hat{Y} = (1, 1, 3, 3)$, $\mu = 2$, $b = 6$, $a = 5$, $\text{Var}(Y) = 2$, $\text{Var}(\hat{Y}) = 1$, $Z = (-1, 1, -1, 1)$. Entonces $r_n^2 = \frac{5}{6} \approx 0,833$, $R^2 = \frac{1}{2} = 0,5$ ($R^2 < r_n^2$).

5. Esperanza condicional (construcción y ley total)

Setup: H Hilbert, M cerrado; dato: para cada x existe único $y_0 \in M$ con $\|x - y_0\|$ mínimo.

Inciso 1 — $P : H \rightarrow M$ es proyección ortogonal.

- **Definición:** $Px := y_0$ (bien definido por unicidad).
- **Lema clave:** y_0 minimiza $\iff (x - y_0) \perp M$. ($\Leftarrow$) Pitágoras $\|x - y\|^2 = \|x - y_0\|^2 + \|y_0 - y\|^2$; ($\Rightarrow$) $\varphi(t) = \|x - (y_0 + tm)\|^2$ tiene mínimo en $t = 0 \Rightarrow \langle x - y_0, m \rangle = 0$.
- **Lineal** (por unicidad), **idempotente** ($P^2 = P$), **autoadjunto** ($\langle Px, z \rangle = \langle x, Pz \rangle$), **contracción** ($\|P\| \leq 1$), $H = M \oplus M^\perp$.

Inciso 2 — **la proyección ES la esperanza condicional.** En $L^2(\Omega, \mathcal{F}, P)$ con $\langle X, Y \rangle = \mathbb{E}[XY]$, $M = L^2(\Omega, \mathcal{G}, P)$ es cerrado. La definición de $E[X | \mathcal{G}]$ ($\mathcal{G}$ -medible con $\mathbb{E}[(X - Z)W] = 0 \forall W \in M$) es exactamente la condición de ortogonalidad $X - Z \perp M \Rightarrow E[X | \mathcal{G}] = PX$ (mejor predicción en media cuadrática).

Inciso 3 — $\mathbb{E}[E(Y | \sigma(X))] = \mathbb{E}(Y)$. Concretando en Ω_n finito, $M = \sigma(X)$, $\mathbf{1} \in M$ y $\mathbb{E}[Z] = \langle Z, \mathbf{1} \rangle$. Como $Y - \hat{Y} \perp M$:

$$\mathbb{E}[Y] - \mathbb{E}[\hat{Y}] = \langle Y - \hat{Y}, \mathbf{1} \rangle = 0 \Rightarrow \mathbb{E}[\hat{Y}] = \mathbb{E}[Y].$$

Verificación: $\hat{Y}|_{B_j} = \mathbb{E}[Y | B_j]$ y $\mathbb{E}[\hat{Y}] = \sum_j P(B_j)\mathbb{E}[Y | B_j] = \mathbb{E}[Y]$ (ley de la esperanza total).

6. Igualdad del paralelogramo

Enunciado: en un espacio con producto interno, $\|x + y\|^2 + \|x - y\|^2 = 2\|x\|^2 + 2\|y\|^2$.

Inciso 1 — **Demostración.** Con $\|v\|^2 = \langle v, v \rangle$ (único uso del producto interno), bilinealidad y simetría: $\|x \pm y\|^2 = \|x\|^2 \pm 2\langle x, y \rangle + \|y\|^2$. Al sumar, los cruzados $\pm 2\langle x, y \rangle$ **se cancelan**. (Complejo: cruzados $2\operatorname{Re}\langle x, y \rangle$, cancela igual.)

Inciso 2 — **Relevancia para la esperanza condicional.** Es una **proyección ortogonal en L^2** , cuya existencia/unicidad (Teorema de la Proyección) usa la igualdad: para una sucesión minimizante (Y_n) con $\|X - Y_n\| \rightarrow d$, aplicando a $a = X - Y_n$, $b = X - Y_m$,

$$\|Y_m - Y_n\|^2 = 2\|X - Y_n\|^2 + 2\|X - Y_m\|^2 - 4\left\|X - \frac{Y_n + Y_m}{2}\right\|^2 \leq 2\|X - Y_n\|^2 + 2\|X - Y_m\|^2 - 4d^2 \rightarrow 0,$$

luego (Y_n) es de Cauchy; por completitud converge a $Y^* \in M$. Sin la igualdad (norma sin producto interno) el argumento se rompe.

Inciso 3 — $\|\cdot\|_\infty$ en $\mathbb{R}^n$ ($n \geq 2$). $x = e_1, y = e_2$: $\|x\|_\infty = \|y\|_\infty = 1, \|x \pm y\|_\infty = 1$. LI = $1 + 1 = 2$, LD = $2 + 2 = 4$. $2 \neq 4 \Rightarrow$ falla.

Inciso 4 — $\|\cdot\|_\infty$ en $C[0, 1]$. $F(x) = 1, G(x) = x$: $\|F\|_\infty = \|G\|_\infty = 1, \|F + G\|_\infty = 2, \|F - G\|_\infty = 1$. LI = $4 + 1 = 5$, LD = 4 . $5 \neq 4 \Rightarrow$ falla (KS usa $\|\cdot\|_\infty$, que no induce geometría de Hilbert).

7. El término de error — dos miradas

Modelo: $y = X\beta + \varepsilon$, $\operatorname{rango}(X) = p$. Ambas llegan al mismo $\hat{\beta} = (X^\top X)^{-1}X^\top y$ por caminos opuestos: el mismo objeto ε con dos significados.

Mirada de Gauss (probabilística). ε es objeto **primitivo** (v.a. con ley supuesta): $\mathbb{E}[\varepsilon] = 0$, $\text{Var}(\varepsilon) = \sigma^2 I_n$ (homocedasticidad + no correlación); para inferir $\varepsilon \sim \mathcal{N}(0, \sigma^2 I_n)$. *Argumento histórico:* la media aritmética como estimador plausible $\Rightarrow$ la ley que la hace máximo-verosímil es la normal $\Rightarrow$ MV = minimizar $\sum \varepsilon_i^2$. Sin normalidad (Gauss–Markov): $\hat{\beta}$ es **BLUE**. Estimación: $\partial_{\beta} \|y - X\beta\|^2 = 0 \Rightarrow X^T X \hat{\beta} = X^T y$. Estilo: paramétrico, inferencial ($\text{Var}(\hat{\beta}) = \sigma^2 (X^T X)^{-1}$, tests t, F , IC). Mentalidad: de la probabilidad a las propiedades.

Mirada de la Proyección (geométrica). $\mathbb{R}^n$ con $\langle u, v \rangle = u^T v$, $\mathcal{C}(X) = \{X\beta\}$. $y = \hat{y} + e$, $\hat{y} \in \mathcal{C}(X)$, $e \perp \mathcal{C}(X)$: el error **se define** como complemento ortogonal. Ecuaciones normales = ortogonalidad: $X^T e = 0$. $P = X(X^T X)^{-1} X^T$, $\hat{y} = Py$, $e = (I - P)y$. Pitágoras = ANOVA sin distribución: $\|y\|^2 = \|\hat{y}\|^2 + \|e\|^2$. En L^2 , la no correlación del error con los regresores es **teorema** (proyección), no supuesto. Estilo: geométrico, libre de distribución.

Criterio	Gauss	Proyección
Naturaleza del error	Primitivo (v.a. con ley)	Derivado (residuo ortogonal)
No correlación	Supuesto	Consecuencia automática
Ecuaciones normales	Anular $\partial S / \partial \beta$	Traducir $X^T e = 0$
Por qué MCO	Verosimilitud normal / BLUE	Proyección = punto más cercano
Distribución	Central desde el inicio	Postergada (solo para inferir)
Estilo	Inferencial/paramétrico	Geométrico/estructural

Síntesis: Gauss responde *por qué es óptimo* (inferencial); la proyección, *por qué tiene esa forma* (estructural). Distinción fina: errores verdaderos $\varepsilon \neq$ residuos $e = (I - P)\varepsilon$.

8. Independencia de funciones ($n = 13$ primo)

Setup: Ω_n empírico uniforme, $X : \Omega_{13} \rightarrow \{x_1, \dots, x_r\}$, $Y : \Omega_{13} \rightarrow \{y_1, \dots, y_q\}$.

Inciso 1 — ¿ r arbitrario? No: $1 \leq r \leq n$, pues $n = \sum_{i=1}^r |A_i| \geq r$ (bloques no vacíos) y $r \geq 1$. $r = 1 \iff X$ constante; $r = n \iff X$ inyectiva. Con $n = 13$: $r \in \{1, \dots, 13\}$.

Inciso 2 — Partición de (X, Y) . La fibra es $(X, Y)^{-1}(\{(x_i, y_j)\}) = A_i \cap B_j$, luego la partición es $\{A_i \cap B_j : A_i \cap B_j \neq \emptyset\}$: el **refinamiento común** de $\{A_i\}$ y $\{B_j\}$ (pues $A_i = \bigsqcup_j (A_i \cap B_j)$; n.º de bloques $\leq r \cdot q$ y $\leq n$).

Inciso 3 — ¿Qué Y son independientes de X fija? Independencia $\iff P(X = x_i, Y = y_j) = P(X = x_i)P(Y = y_j)$. En el espacio empírico:

$$\frac{|A_i \cap B_j|}{13} = \frac{|A_i|}{13} \cdot \frac{|B_j|}{13} \iff |A_i \cap B_j| = \frac{|A_i||B_j|}{13}.$$

El lado izquierdo es entero $\Rightarrow 13 \mid |A_i||B_j|$. Como **13 es primo** (Euclides): $13 \mid |A_i|$ o $13 \mid |B_j|$; y como $1 \leq |A_i|, |B_j| \leq 13$, esto fuerza $|A_i| = 13$ (X constante) o $|B_j| = 13$ (Y constante).

- **X no constante ($r \geq 2$):** $\Rightarrow Y$ debe ser constante ($q = 1$).
- **X constante:** toda Y es independiente de X .

Papel de la primalidad de 13: la independencia exige $|A_i \cap B_j| = |A_i||B_j|/n$ entero (“rectángulo”); dos variables no triviales independientes requerirían $n = a \cdot b$ con $1 < a, b < n$, imposible si n es primo. Por eso sobre Ω_{13} dos variables solo pueden ser independientes si al menos una es constante. Con n compuesto (p. ej. $n = 12$) sí existirían no constantes genuinamente independientes.

Apéndice — Conceptos transversales

- **Etiqueta vs. variable:** la etiqueta identifica; la variable describe (preguntas 1, 2, 8).
- **Partición / $\sigma(X)$:** fibras de la variable; $\sigma(X)$ = funciones constantes por bloque.
- **Esperanza condicional = proyección ortogonal** = promedio por bloque = mejor predictor.
- **Teorema de la Proyección** $\Rightarrow$ residuo ortogonal $\Rightarrow$ esperanza total, Pitágoras, ANOVA.
- $1 \in \sigma(X)$ **siempre** $\Rightarrow \mathbb{E}[Z] = 0$ (insesgamiento).
- **Ortogonalidad lo es todo:** proyecciones se suman solo si los subespacios son ortogonales (p. 3); no correlación $\equiv$ ortogonalidad en L^2 centrado (p. 7).
- R^2 (**centrado**) $\leq r_n^2$ (**crudo**); iguales si $\mu = 0$ o ajuste perfecto (p. 4).
- **Norma del supremo** no viene de producto interno (falla paralelogramo) $\Rightarrow$ no sirve para definir esperanza condicional (p. 6).
- **Primalidad y rectángulos:** n primo $\Rightarrow$ independencia solo con variable constante (p. 8).

Tabla 1: Fórmulas Clave

Concepto	Fórmula
Producto interno	$\langle U, V \rangle = \mathbb{E}[UV] = \frac{1}{n} \sum_{i=1}^n U(\omega_i)V(\omega_i)$
Norma en L^2	$\ U\ ^2 = \mathbb{E}[U^2] = \frac{1}{n} \sum_{i=1}^n U^2(\omega_i)$
Esperanza condicional	$E(Y \mid \sigma(X))(\omega) = \frac{1}{ B } \sum_{\omega' \in B} Y(\omega'), B = \text{bloque de } \omega$
Proyección sobre recta	$P_{\sigma(v)}Y = \frac{\langle Y, v \rangle}{\langle v, v \rangle} v$
Teorema de Pitágoras	$\ Y\ ^2 = \ \hat{Y}\ ^2 + \ Z\ ^2$
Descomposición ANOVA	$\text{Var}(Y) = \text{Var}(E(Y \mid \sigma(X))) + \mathbb{E}(\text{Var}(Y \mid \sigma(X)))$
Coef. determinación (crudo)	$r_n^2 = \frac{\ E(Y \mid \sigma(X))\ ^2}{\ Y\ ^2} = \frac{a}{b}$
Coef. determinación (centrado)	$R^2 = \frac{\text{Var}(\hat{Y})}{\text{Var}(Y)} = \frac{a - \mu^2}{b - \mu^2}$
r^2 por bloques	$r^2 = \frac{SC_{\text{inter}}}{SC_{\text{total}}} = \frac{\sum_a n_a (\bar{x}_a - \bar{x})^2}{\sum_i x_i^2 - n\bar{x}^2}$
Proyector ortogonal	$P_M x := \arg \min_{y \in M} \ x - y\ $, única solución con $x - Px \perp M$
Esperanza total (ley)	$\mathbb{E}[\hat{Y}] = \mathbb{E}[E(Y \mid \sigma(X))] = \mathbb{E}[Y]$
Residuo ortogonal	$Z = Y - E(Y \mid \sigma(X))$, $\langle Z, W \rangle = 0$ para $W \in \sigma(X)$
Igualdad del paralelogramo	$\ x + y\ ^2 + \ x - y\ ^2 = 2\ x\ ^2 + 2\ y\ ^2$ (válida en Hilbert)
Ecuaciones normales	$X^\top(y - X\beta) = 0 \Rightarrow \hat{\beta} = (X^\top X)^{-1} X^\top y$
Matriz proyectora	$P = X(X^\top X)^{-1} X^\top$, $\hat{y} = Py$, $e = (I - P)y$
Independencia (empírica)	$ A_i \cap B_j = A_i B_j /n$ para todo i, j

Tabla 2: Símbolos y Notación

Símbolo	Significado
$\Omega_n = \Omega_n$	Conjunto finito de etiquetas (individuos), $ \Omega_n = n$
$\mathcal{P}(\Omega_n)$	Álgebra σ trivial (todas las partes)
P_n	Probabilidad uniforme empírica, $P_n(\{\omega\}) = 1/n$
$\sigma(X)$	Subespacio de L^2 de funciones constantes por bloque de X
$L^2(\Omega_n, \mathcal{P}(\Omega_n), P_n)$	Espacio de Hilbert de funciones en Ω_n de cuadrado integrable
$\langle U, V \rangle$	Producto interno en L^2 : $\mathbb{E}[UV]$
$\ U\ $	Norma de U en L^2 : $\sqrt{\mathbb{E}[U^2]}$
$E(Y \mid \sigma(X))$	Esperanza condicional de Y dada la partición $\sigma(X)$
$\hat{Y}$	Predictor óptimo: $E(Y \mid \sigma(X)) = P_{\sigma(X)}Y$
Z	Residuo: $Z = Y - \hat{Y} = Y - E(Y \mid \sigma(X))$
P_M	Proyector ortogonal sobre subespacio cerrado M
$A_i = X^{-1}(\{x_i\})$	Fibra i -ésima de X (bloque de individuos con $X = x_i$)
r^2	Razón de correlación: $\eta^2 = \text{Var}(E(Y \mid \sigma(X))) / \text{Var}(Y)$
R^2	Coef. de determinación (invariante a traslaciones)
r_n^2	Coef. basado en momentos crudos (sobrestima si $\mathbb{E}[Y] \neq 0$)
$\mu = \mathbb{E}[Y]$	Esperanza (valor medio) de Y
$\text{Var}(Y)$	Varianza de Y : $\mathbb{E}[(Y - \mu)^2]$
$\mathbf{1}$	Función constante $\mathbf{1}(\omega) = 1$ para todo ω
$M \perp \mathcal{N}$	Subespacios ortogonales: $\langle m, n \rangle = 0$
$SC_{\text{inter/intra/total}}$	Sumas de cuadrados entre / dentro / total
$X \perp Y$	Variables independientes

Tabla 3: Resultados Clave y Teoremas

Teorema/Resultado	Enunciado
Caracterización de la proyección	Px minimiza $\ x - y\ $ sobre $M \iff (x - Px) \perp M$
Propiedades de P	Lineal, idempotente ($P^2 = P$), autoadjunto, contracción
Esperanza = Proyección	$E[X \mid \mathcal{G}] = P_M X$, único $\sigma(\mathcal{G})$ -medible minimizador en L^2
Inesgamiento	$\mathbb{E}[Y - E(Y \mid \sigma(X))] = 0$ (como $\mathbf{1} \in \sigma(X)$)
Ortogonalidad del residuo	$Y - E(Y \mid \sigma(X)) \perp \sigma(X)$
Esperanza total	$\mathbb{E}[E(Y \mid \sigma(X))] = \mathbb{E}[Y]$
Teorema de Pitágoras	$\ Y\ ^2 = \ \hat{Y}\ ^2 + \ Y - \hat{Y}\ ^2$
ANOVA / Descomposición	$\text{Var}(Y) = \text{Var}(\hat{Y}) + \mathbb{E}[\text{Var}(Y \mid \sigma(X))]$
Relación R^2 vs r_n^2	$R^2 \leq r_n^2$, iguales sii $\mathbb{E}[Y] = 0$ o $Y = \hat{Y}$ c.s.
Suma de proyecciones	$P_{M \oplus N} = P_M + P_N$ solo si $M \perp N$
Frisch–Waugh–Lovell	Ortogonalizar si los regresores están correlacionados
Coherencia jerárquica	$\sigma(D) \subseteq \sigma(L) \subseteq \sigma(M)$ (Distrito $\subseteq$ Local $\subseteq$ Mesa)
Falacia ecológica	Atribuir efecto agregado al nivel individual falla (Robinson, 1950)
Paradoja de Simpson	La correlación se invierte entre nivel agregado e individual
Primalidad e independencia	Con $n = 13$ primo, dos variables no triviales no pueden ser independientes
Igualdad del paralelogramo	$\ x + y\ ^2 + \ x - y\ ^2 = 2(\ x\ ^2 + \ y\ ^2)$ caracteriza Hilbert
Estimador MCO	$\hat{\beta} = (X^\top X)^{-1} X^\top y$ es BLUE bajo Gauss–Markov
Ecuaciones normales	$X^\top e = 0 \Rightarrow$ residuos ortogonales a regresores