



Resumen examen — versión mejorada

Marco teórico común (la llave de todo)

0.1 Espacio empírico de probabilidad

Una base de datos es la terna $(\Omega_n, \mathcal{P}(\Omega_n), P_n)$ donde:

- $\Omega_n = \{\omega_1, \dots, \omega_n\}$ es el **conjunto de etiquetas (labels)** = los **individuos estadísticos** (identifican cada fila de forma única). No confundir la etiqueta con el valor de una variable.
- Probabilidad **uniforme** (Laplace): $p_\omega = 1/n$, y $P_n(A) = |A|/n$.
- Una **variable** es una función $X : \Omega_n \rightarrow \text{Im}(X)$. Cada columna es una variable.

0.2 Partición inducida por una variable

Toda X con $\text{Im}(X) = \{x_1, \dots, x_r\}$ induce una **partición** de Ω_n en sus **fibras / bloques**: $A_i := X^{-1}(\{x_i\}) = \{\omega : X(\omega) = x_i\}$. No vacíos, disjuntos, cubren Ω_n . $\sigma(X)$ designa el **subespacio de funciones constantes sobre cada bloque**.

0.3 L^2 como espacio de Hilbert

$L^2(\Omega_n, \mathcal{P}(\Omega_n), P_n)$ con

$$\langle U, V \rangle = \mathbb{E}[UV] = \frac{1}{n} \sum_{i=1}^n U(\omega_i) V(\omega_i), \quad \|U\|^2 = \mathbb{E}[U^2].$$

Como Ω_n es finito, toda función está en L^2 y el espacio es completo (Hilbert).

0.4 Esperanza condicional = proyección ortogonal

🔑 $E(Y | \sigma(X)) = P_{\sigma(X)} Y =$ proyección ortogonal de Y sobre $\sigma(X)$.

Es el único $\hat{Y} \in \sigma(X)$ que minimiza $\|Y - \hat{Y}\|^2$ (mejor predicción en media cuadrática). En cada individuo vale **el promedio de Y sobre su bloque**:

$$E(Y | \sigma(X))(\omega) = \frac{1}{|B|} \sum_{\omega' \in B} Y(\omega'), \quad B = \text{bloque de } \omega.$$

Teorema de la Proyección (hecho central): el residuo $Z = Y - \hat{Y}$ es ortogonal a todo el subespacio: $\langle Z, W \rangle = 0$ para todo $W \in \sigma(X)$.

Dato clave: la función constante **1** siempre está en $\sigma(X)$.

0.5 Tres consecuencias inmediatas

1. **Insurgimiento / esperanza total:** como $\mathbf{1} \in \sigma(X)$ y $Z \perp \sigma(X)$, $\mathbb{E}[Z] = \langle Z, \mathbf{1} \rangle = 0 \Rightarrow \mathbb{E}[E(Y | \sigma(X))] = \mathbb{E}[Y]$.
2. **Pitágoras (norma):** $\|Y\|^2 = \|\hat{Y}\|^2 + \|Z\|^2$.
3. **Descomposición de varianza (ANOVA):**

$$\text{Var}(Y) = \underbrace{\text{Var}(E(Y | \sigma(X)))}_{\text{entre bloques (SC}_{\text{inter}})} + \underbrace{\mathbb{E}(\text{Var}(Y | \sigma(X)))}_{\text{dentro (SC}_{\text{intra}})}.$$

0.6 Fórmulas de proyección útiles

- Sobre una recta generada por $v \neq 0$: $P_{\sigma(v)}Y = \frac{\langle Y, v \rangle}{\langle v, v \rangle}v$.
- **Suma de proyecciones SOLO si hay ortogonalidad:** si $\mathcal{M} \perp \mathcal{N}$ entonces $P_{\mathcal{M} \oplus \mathcal{N}} = P_{\mathcal{M}} + P_{\mathcal{N}}$. Si no, **falla** (ecuaciones normales).

1. Base de datos (reformas fiscales)

Planteo: tabla País × Año (20 individuos, 9 variables). Espacio $\mathbb{R}^{20}$, pesos 1/20.

1. **Etiquetas:** los pares (País, Año): $I = \{(FRA, 2015), \dots\}$, $|I| = 4 \times 5 = 20$. (El enunciado nombra 5 países pero la tabla trae solo 4; el cardinal real es 20, no 25.)
2. **Partición por FR:** binaria $\rightarrow$ 2 clases: $A_0 = \{FR = 0\}$ (2015-16, $|A_0| = 8$) y $A_1 = \{FR = 1\}$ (2017-19, $|A_1| = 12$).
3. $E(\text{Inv} | \text{Año})$: 5 clases (4 individuos c/u), valor = promedio del año:

Año	Valores (FRA, DEU, BEL, ESP)	Suma	Promedio
2015	19.3, 18.5, 18.0, 16.9	72.7	18.175
2016	17.1, 17.0, 17.1, 18.0	69.2	17.300
2017	15.6, 19.7, 20.2, 19.8	75.3	18.825
2018	21.9, 20.5, 21.2, 20.4	84.0	21.000
2019	16.7, 18.4, 19.4, 18.8	73.3	18.325

Media global: $\bar{x} = 374.5/20 = 18.725$.

1. r^2 e **interpretación:** razón de correlación η^2 .

$$SC_{\text{inter}} = \sum_a n_a (\bar{x}_a - \bar{x})^2 = 30.715, \quad SC_{\text{total}} = \sum_i x_i^2 - 20\bar{x}^2 = 53.8975, \quad SC_{\text{intra}} = 23.1825.$$

$$r^2 = \frac{SC_{\text{inter}}}{SC_{\text{total}}} = \frac{30.715}{53.8975} \approx 0.570 (\approx 57\%).$$



Interpretación geométrica (*mejora respecto al resumen original*): $E(\text{Inv} \mid \text{Año})$ es la proyección ortogonal de Inv sobre el subespacio F de funciones constantes por año; el residuo es ortogonal a F . Con vectores centrados, $r^2 = \cos^2 \theta$, donde θ es el ángulo entre Inv centrada y el subespacio F . Aquí $\cos \theta = \sqrt{0.57} \approx 0.755$, es decir $\theta \approx 41^\circ$. La varianza no explicada corresponde al cuadrado de la distancia angular al subespacio.

2. Coherencia en una base de datos (falacia ecológica)

Planteo: votos identificados por folio único; cada folio tiene opción de voto y pertenece a mesa $\rightarrow$ local $\rightarrow$ distrito.

1. **Etiquetas = los folios.** La opción de voto NO es etiqueta, es una variable $V : \Omega_N \rightarrow \{\text{cand.1, cand.2, nulo, blanco}\}$. Los folios deben ser únicos, exhaustivos y mutuamente excluyentes.
2. **Mesa, Local, Distrito Sí son variables**, con particiones **jerárquicas/encajonadas**: $\sigma(D) \subseteq \sigma(L) \subseteq \sigma(M) \subseteq L^2(\Omega_N)$ (Mesa más fina, Distrito más gruesa).
3. **Tasa de cesantía comunal** C : (i) *coherencia jerárquica*: asignación unívoca folio $\rightarrow$ comuna, $K : \Omega_N \rightarrow \{\text{comunidades}\}$; (ii) *medibilidad*: C constante por comuna, i.e. $C \in \sigma(K)$.

El punto de fondo (falacia ecológica): como $C \in \sigma(K)$ es constante dentro de cada comuna, solo aporta variabilidad *entre* comunas:

$$\text{Var}(V) = \underbrace{\text{Var}(E(V \mid \sigma(K)))}_{\text{entre comunas (ve } C)} + \underbrace{\mathbb{E}(\text{Var}(V \mid \sigma(K)))}_{\text{dentro: invisible para } C}.$$

Atribuir el efecto agregado al individuo es la **falacia ecológica** (Robinson, 1950).



Paradoja de Simpson (*tabla ilustrativa — mejora respecto al resumen original*): la correlación puede **invertirse** entre el nivel agregado y el individual.

Comuna	Cesantía (agregada)	% voto cand. 1 (individual)
A — cesantes	20%	70%
A — empleados	20%	40%
B — cesantes	5%	55%
B — empleados	5%	25%

A nivel **comuna**, más cesantía (A) $\rightarrow$ más voto al candidato 1. Pero **dentro** de cada comuna, son los *empleados* quienes votan *menos* al candidato 1: la relación individual es opuesta a la agregada. Para sostener una explicación individual se necesita una variable definida sobre el folio, con partición más fina que la comunal.

3. Modelos lineales encajonados (nested)

Modelos: M1: $E(Y \mid X_1) = \alpha_0 + \alpha_1 X_1$; M2: $E(Y \mid X_1, X_2) = \alpha_0 + \alpha_1 X_1 + \alpha_2 X_2$.

Marco: Ω_3 , uniforme $1/3$, $\langle U, V \rangle = \frac{1}{3} \sum U_i V_i$.

Ejemplo 1 — regresores ORTOGONALES (se cumple la aditividad).

$\mathbf{1} = (1, 1, 1)$, $X = (-1, 0, 1)$. Como $\langle \mathbf{1}, X \rangle = 0$:

$$E(Y | \sigma(\mathbf{1}, X)) = \bar{y} \mathbf{1} + \frac{y_3 - y_1}{2} X = E(Y | \sigma(\mathbf{1})) + E(Y | \sigma(X)). \checkmark$$



Lectura adicional (mejora): evaluada por componentes, esta proyección es

$(\bar{y} - \frac{y_3 - y_1}{2}, \bar{y}, \bar{y} + \frac{y_3 - y_1}{2})$, que no es otra cosa que la **recta de regresión OLS** evaluada en $X = -1, 0, 1$. La igualdad se debe a la **ortogonalidad** entre $\mathbf{1}$ y X : proyectar sobre el plano = sumar proyecciones sobre cada eje (Pitágoras).

Ejemplo 2 — regresores NO ortogonales (falla).

$\mathbf{1} = (1, 1, 1)$, $Z = (1, 0, 1)$, $\langle \mathbf{1}, Z \rangle = \frac{2}{3} \neq 0$. Por **ecuaciones normales**:

$$a = y_2, \quad b = \frac{y_1 + y_3}{2} - y_2, \quad E(Y | \sigma(\mathbf{1}, Z)) = \left(\frac{y_1 + y_3}{2}, y_2, \frac{y_1 + y_3}{2} \right).$$

En ω_2 : la proyección da y_2 , pero la suma de proyecciones simples da $\frac{y_1 + y_2 + y_3}{3}$; coinciden solo si $2y_2 = y_1 + y_3$. La suma doble-cuenta la parte común.



Criterio (¿cuándo son "encajonados"?):

- **Inclusión de subespacios:** $\sigma(\mathbf{1}) \subseteq \sigma(\mathbf{1}, X_1) \subseteq \sigma(\mathbf{1}, X_1, X_2)$ *siempre*. Solo valida comparar ajustes (M2 nunca ajusta peor).
- **Descomposición aditiva (encajonamiento fuerte):** se cumple *si y solo si* $X_2 \perp \sigma(\mathbf{1}, X_1)$. Si los predictores están correlacionados, agregar X_2 *altera* el coeficiente de X_1 . La forma correcta es **ortogonalizar primero (teorema de Frisch-Waugh-Lovell)**. La receta ingenua "ajusto, agrego, comparo" solo es interpretable bajo ortogonalidad.

4. Teorema de Pitágoras (R^2 vs r_n^2)

Setup: $Y = \hat{Y} + Z$, $\hat{Y} = E(Y | \sigma(X))$, $Z = Y - \hat{Y}$, $\|Y\|^2 = \|\hat{Y}\|^2 + \|Z\|^2$.

Parte 1 — $\mathbb{E}(Y - E(Y | \sigma(X))) = 0$: como $\mathbf{1} \in \sigma(X)$ y $Z \perp \sigma(X)$, $\langle Z, \mathbf{1} \rangle = \mathbb{E}[Z] = 0$. Consecuencia: $\mathbb{E}[\hat{Y}] = \mathbb{E}[Y] =: \mu$.

Parte 2 — equivalencia (1) $\Leftrightarrow$ (2): con $\text{Var}(U) = \mathbb{E}[U^2] - [\mathbb{E}(U)]^2$ y $\mathbb{E}[\hat{Y}] = \mathbb{E}[Y] = \mu$, $\mathbb{E}[Z] = 0$. Restando μ^2 a $\mathbb{E}[Y^2] = \mathbb{E}[\hat{Y}^2] + \mathbb{E}[Z^2]$:

$$\text{Var}(Y) = \text{Var}(E(Y | \sigma(X))) + \text{Var}(Y - E(Y | \sigma(X))).$$

"Restar μ^2 " es reversible $\rightarrow$ (1) y (2) equivalentes.

Parte 3 — comparar. Con $a = \|\hat{Y}\|^2 = \mathbb{E}[\hat{Y}^2]$, $b = \|Y\|^2 = \mathbb{E}[Y^2]$:

$$r_n^2 = \frac{a}{b} \text{ (momentos crudos),} \quad R^2 = \frac{a - \mu^2}{b - \mu^2} \text{ (varianzas).}$$

Como $\mu^2 \leq a \leq b$ (por Jensen y Pitágoras), por producto cruzado:

$$\boxed{R^2 \leq r_n^2}$$

Igualdad sii $\mu = \mathbb{E}[Y] = 0$ (centrada) o $a = b$ ($Y = \hat{Y}$ c.s.). R^2 es el genuino coeficiente de determinación (invariante a traslaciones); r_n^2 usa momentos crudos y **sobrestima** cuando $|\mu|$ es grande.

12
34

Ejemplo concreto (mejora: ausente del resumen original): $\Omega = \{1, 2, 3, 4\}$ uniforme, bloques $\{1, 2\}, \{3, 4\}$, $Y = (0, 2, 2, 4)$, $\hat{Y} = (1, 1, 3, 3)$.

- $\mu = 2$, $b = E[Y^2] = 6$, $a = E[\hat{Y}^2] = 5$
- $\text{Var}(Y) = b - \mu^2 = 2$, $\text{Var}(\hat{Y}) = a - \mu^2 = 1$
- Residuo $Z = (-1, 1, -1, 1)$: $E[Z] = 0$, $\text{Var}(Z) = 1$ ✓ (descomposición verificada)
- $r_n^2 = 5/6 \approx 0.833$ vs $R^2 = 1/2 = 0.5$

Con los *mismos datos*, r_n^2 sugiere un «ajuste» del 83% y R^2 del 50%, únicamente por no descontar la media $\mu = 2$.

5. Esperanza condicional (construcción y ley total)

Parte 1 — $P : H \rightarrow M$ es **proyección ortogonal** (M cerrado):

- **Definición:** $Px := y_0$, el único minimizador de $\|x - y\|$ sobre M .
- **Lema clave:** y_0 minimiza $\iff (x - y_0) \perp M$. ($\Leftarrow$) Pitágoras; ($\Rightarrow$) $\varphi(t) = \|x - (y_0 + tm)\|^2$ tiene mínimo en $t = 0 \Rightarrow \langle x - y_0, m \rangle = 0$.
- **Lineal** (por unicidad), **idempotente** ($P^2 = P$), **autoadjunto** ($\langle Px, z \rangle = \langle x, Pz \rangle$), **contracción** ($\|P\| \leq 1$), $H = M \oplus M^\perp$.

Parte 2 — la **proyección ES la esperanza condicional**: en $L^2(\Omega, \mathcal{F}, P)$ con $\langle X, Y \rangle = \mathbb{E}[XY]$, $M = L^2(\Omega, \mathcal{G}, P)$ es cerrado. La definición de $E[X | \mathcal{G}]$ ($\mathcal{G}$ -medible con $\mathbb{E}[(X - Z)W] = 0$ para todo $W \in M$) es exactamente la condición de ortogonalidad $\Rightarrow E[X | \mathcal{G}] = PX$ (mejor predicción en media cuadrática).

Parte 3 — $\mathbb{E}[E(Y | \sigma(X))] = \mathbb{E}(Y)$: como $\mathbf{1} \in M$ y $Y - \hat{Y} \perp M$:

$$\mathbb{E}[Y] - \mathbb{E}[\hat{Y}] = \langle Y - \hat{Y}, \mathbf{1} \rangle = 0.$$



Verificación explícita vía ley de la esperanza total (mejora): $\hat{Y}|_{B_j} = E[Y | B_j]$ (promedio por bloque), luego

$$\mathbb{E}[\hat{Y}] = \sum_j P_n(B_j) E[Y | B_j] = \sum_j \sum_{\omega \in B_j} Y(\omega) P_n(\{\omega\}) = \mathbb{E}[Y].$$

Esta es la **ley de la esperanza total** obtenida directamente como consecuencia de la proyección ortogonal, sin supuestos adicionales.

6. Igualdad del paralelogramo

Enunciado: en un espacio con producto interno, $\|x + y\|^2 + \|x - y\|^2 = 2\|x\|^2 + 2\|y\|^2$.

1. Demostración: expandir con $\|v\|^2 = \langle v, v \rangle$, bilinealidad y simetría: $\|x \pm y\|^2 = \|x\|^2 \pm 2\langle x, y \rangle + \|y\|^2$. Al sumar, los cruzados $\pm 2\langle x, y \rangle$ **se cancelan**.

2. Relevancia para la esperanza condicional: es una **proyección ortogonal en L^2** , cuya existencia/unicidad (Teorema de la Proyección) usa la igualdad: para una sucesión minimizante (Y_n) ,

$$\|Y_m - Y_n\|^2 = 2\|X - Y_n\|^2 + 2\|X - Y_m\|^2 - 4\left\|X - \frac{Y_n + Y_m}{2}\right\|^2 \leq 2\|X - Y_n\|^2 + 2\|X - Y_m\|^2 - 4d^2 \rightarrow 0,$$

luego (Y_n) es de Cauchy; por completitud converge a $Y^* \in M$. Sin producto interno (norma sin la igualdad) el argumento se rompe.

3. $\|\cdot\|_\infty$ en $\mathbb{R}^n$ ($n \geq 2$): $x = e_1, y = e_2$. $\|x\|_\infty = \|y\|_\infty = 1$, $\|x \pm y\|_\infty = 1$. LI = $1 + 1 = 2$, LD = $2 + 2 =$

4. $2 \neq 4 \Rightarrow$ falla.

4. $\|\cdot\|_\infty$ en $C[0, 1]$: $F(x) = 1, G(x) = x$. $\|F\|_\infty = \|G\|_\infty = 1$, $\|F + G\|_\infty = 2$, $\|F - G\|_\infty = 1$. LI = $4 + 1 = 5$, LD = 4. $5 \neq 4 \Rightarrow$ falla.

7. El término de error — dos miradas

Modelo: $y = X\beta + \varepsilon$, $\text{rango}(X) = p$. Ambas llegan al mismo $\hat{\beta} = (X^\top X)^{-1} X^\top y$ por caminos opuestos.

Mirada de Gauss (probabilística). ε es objeto **primitivo** con ley supuesta: $\mathbb{E}[\varepsilon] = 0$, $\text{Var}(\varepsilon) = \sigma^2 I_n$ (homocedasticidad + no correlación); para inferir $\varepsilon \sim \mathcal{N}(0, \sigma^2 I_n)$. La normal surge de exigir que la media sea máximo-verosímil $\rightarrow$ MV = minimizar $\sum \varepsilon_i^2$. Sin normalidad, Gauss–Markov: $\hat{\beta}$ es **BLUE**. Estilo: paramétrico, inferencial ($\text{Var}(\hat{\beta}) = \sigma^2 (X^\top X)^{-1}$, tests t, F, IC).

Mirada de la Proyección (geométrica). $y = \hat{y} + e$, $\hat{y} \in \mathcal{C}(X)$, $e \perp \mathcal{C}(X)$. El error **se define** como complemento ortogonal. Ecuaciones normales = ortogonalidad: $X^\top e = 0$. $P = X(X^\top X)^{-1} X^\top$, $\hat{y} = Py$, $e = (I - P)y$. Pitágoras = ANOVA sin distribución: $\|y\|^2 = \|\hat{y}\|^2 + \|e\|^2$. En L^2 , la no correlación del error con los regresores es **teorema**, no supuesto. Estilo: geométrico, libre de distribución.

Criterio	Gauss	Proyección
Naturaleza del error	Primitivo (v.a. con ley)	Derivado (residuo ortogonal)
No correlación	Supuesto	Consecuencia automática
Ecuaciones normales	Anular $\partial S / \partial \beta$	Traducir $X^\top e = 0$

Criterio	Gauss	Proyección
Por qué MCO	Verosimilitud normal / BLUE	Proyección = punto más cercano
Distribución	Central desde el inicio	Postergada (solo para inferir)
Estilo	Inferencial/paramétrico	Geométrico/estructural



Distinción crucial (*mejora: ausente del resumen original*): los **errores verdaderos** ε (objeto de Gauss) y los **residuos** e (objeto de la proyección) **no son lo mismo**. El residuo es una estimación del error, ligado a X vía $e = (I - P)\varepsilon$. Por eso e no es i.i.d. incluso si ε lo es: $\text{Var}(e) = \sigma^2(I - P)$, que no es $\sigma^2 I$.

Síntesis: la **geometría** explica la forma del estimador; la **probabilidad** de Gauss le añade la capa de inferencia (distribuciones, tests, intervalos) sobre esa estructura ya construida.

8. Independencia de funciones ($n = 13$ primo)

Setup: Ω_{13} empírico uniforme, $X : \Omega_{13} \rightarrow \{x_1, \dots, x_r\}$, $Y : \Omega_{13} \rightarrow \{y_1, \dots, y_q\}$.

1. ¿ r arbitrario? No: $1 \leq r \leq n$, pues $n = \sum_{i=1}^r |A_i| \geq r$ (bloques no vacíos). $r = 1 \iff X$ constante; $r = n \iff X$ inyectiva. Con $n = 13$: $r \in \{1, \dots, 13\}$.

2. Partición de (X, Y) : la fibra es $(X, Y)^{-1}(\{(x_i, y_j)\}) = A_i \cap B_j$, luego la partición es $\{A_i \cap B_j : A_i \cap B_j \neq \emptyset\}$; el **refinamiento común** de $\{A_i\}$ y $\{B_j\}$ (número de bloques $\leq r \cdot q$ y $\leq n$).

3. ¿Qué Y son independientes de X fija? Independencia $\iff P(X = x_i, Y = y_j) = P(X = x_i)P(Y = y_j)$. En el espacio empírico:

$$\frac{|A_i \cap B_j|}{13} = \frac{|A_i|}{13} \cdot \frac{|B_j|}{13} \iff |A_i \cap B_j| = \frac{|A_i||B_j|}{13}.$$

El lado izquierdo es entero $\Rightarrow 13 \mid |A_i||B_j|$. Como **13 es primo** (Euclides): $13 \mid |A_i|$ o $13 \mid |B_j|$, y como $1 \leq |A_i|, |B_j| \leq 13$, esto fuerza $|A_i| = 13$ (X constante) o $|B_j| = 13$ (Y constante).

- X **no constante** ($r \geq 2$): $\Rightarrow Y$ debe ser constante ($q = 1$).
- X **constante**: toda Y es independiente de X .



Papel de la primalidad de 13 — y contraste con n compuesto (*mejora*): la independencia exige $|A_i \cap B_j| = |A_i||B_j|/n$ entero; dos variables no triviales independientes requerirían $n = a \cdot b$ con $1 < a, b < n$, imposible si n es primo.

Por eso sobre Ω_{13} dos variables solo pueden ser independientes si al menos una es constante. Con n **compuesto**, por ejemplo $n = 12 = 3 \times 4$, sí existen variables no constantes genuinamente independientes: basta tomar $r = 3$ bloques de tamaño 4 para X , y $q = 4$ bloques de tamaño 3 para Y , con $|A_i \cap B_j| = 1$ para todo par; se verifica $1 = (4 \cdot 3)/12$.

Apéndice — Conceptos transversales

- **Etiqueta vs. variable:** la etiqueta identifica; la variable describe (preguntas 1, 2, 8).
- **Partición / $\sigma(X)$:** fibras de la variable; $\sigma(X)$ = funciones constantes por bloque.
- **Esperanza condicional = proyección ortogonal** = promedio por bloque = mejor predictor.
- **Teorema de la Proyección** → residuo ortogonal → esperanza total, Pitágoras, ANOVA.
- **Ortogonalidad lo es todo:** proyecciones se suman solo si los subespacios son ortogonales (P3); no correlación $\equiv$ ortogonalidad en L^2 centrado (P7).
- R^2 (centrado) $\leq r_n^2$ (crudo); iguales si $\mu = 0$ o ajuste perfecto (P4).
- **Norma del supremo** no viene de producto interno (falla paralelogramo) → no sirve para definir esperanza condicional (P6).

Tabla 1: Fórmulas clave

Concepto	Fórmula
Producto interno	$\langle U, V \rangle = \mathbb{E}[UV] = \frac{1}{n} \sum_{i=1}^n U(\omega_i) V(\omega_i)$
Norma en L^2	$\ U\ ^2 = \mathbb{E}[U^2] = \frac{1}{n} \sum_{i=1}^n U^2(\omega_i)$
Esperanza condicional	$E(Y \mid \sigma(X))(\omega) = \frac{1}{ B } \sum_{\omega' \in B} Y(\omega'), B = \text{bloque de } \omega$
Proyección sobre recta	$P_{\sigma(v)} Y = \frac{\langle Y, v \rangle}{\langle v, v \rangle} v$
Teorema de Pitágoras	$\ Y\ ^2 = \ \hat{Y}\ ^2 + \ Z\ ^2$
Descomposición ANOVA	$\text{Var}(Y) = \text{Var}(E(Y \mid \sigma(X))) + \mathbb{E}(\text{Var}(Y \mid \sigma(X)))$
Coef. determinación (crudo)	$r_n^2 = \ E(Y \mid \sigma(X))\ ^2 / \ Y\ ^2 = a/b$
Coef. determinación (centrado)	$R^2 = \text{Var}(\hat{Y}) / \text{Var}(Y) = (a - \mu^2) / (b - \mu^2)$
r^2 para años	$r^2 = SC_{\text{inter}} / SC_{\text{total}} = \sum_a n_a (\bar{x}_a - \bar{x})^2 / (\sum_i x_i^2 - n \bar{x}^2)$
Proyector ortogonal	$P_M x := \arg \min_{y \in M} \ x - y\ $, única solución con $x - Px \perp M$
Esperanza total (ley)	$\mathbb{E}[\hat{Y}] = \mathbb{E}[E(Y \mid \sigma(X))] = \mathbb{E}[Y]$
Residuo ortogonal	$Z = Y - E(Y \mid \sigma(X))$, $\langle Z, W \rangle = 0$ para $W \in \sigma(X)$
Igualdad del paralelogramo	$\ x + y\ ^2 + \ x - y\ ^2 = 2\ x\ ^2 + 2\ y\ ^2$ (válida en Hilbert)
Ecuaciones normales	$X^\top (y - X\beta) = 0 \Rightarrow \hat{\beta} = (X^\top X)^{-1} X^\top y$
Matriz proyectora	$P = X(X^\top X)^{-1} X^\top$, $\hat{y} = Py$, $e = (I - P)y$

Tabla 2: Símbolos y Notación

Símbolo	Significado
Ω_n	Conjunto finito de etiquetas (individuos), $ \Omega_n = n$
$\mathcal{P}(\Omega_n)$	Álgebra σ trivial (todas las partes)
P_n	Probabilidad uniforme empírica, $P_n(\{\omega\}) = 1/n$
$\sigma(X)$	Subespacio de L^2 de funciones constantes por bloque de X
$L^2(\Omega_n, \mathcal{P}(\Omega_n), P_n)$	Espacio de Hilbert de funciones en Ω_n de cuadrado integrable
$\langle U, V \rangle$	Producto interno en L^2 : $\mathbb{E}[UV]$

Símbolo	Significado
$\ U\ $	Norma de U en L^2 : $\sqrt{\mathbb{E}[U^2]}$
$E(Y \mid \sigma(X))$	Esperanza condicional de Y dada la partición $\sigma(X)$
$\hat{Y}$	Predictor óptimo: $E(Y \mid \sigma(X)) = P_{\sigma(X)}Y$
Z	Residuo: $Z = Y - \hat{Y} = Y - E(Y \mid \sigma(X))$
P_M	Proyector ortogonal sobre subespacio cerrado M
$A_i = X^{-1}(\{x_i\})$	Fibra i -ésima de X (bloque de individuos con $X = x_i$)
$r^2 = \eta^2$	Razón de correlación: $\text{Var}(E(Y \mid \sigma(X))) / \text{Var}(Y)$
R^2	Coef. de determinación (invariante a traslaciones)
r_n^2	Coef. basado en momentos crudos (sobrestima si $\mathbb{E}[Y] \neq 0$)
$\mu = \mathbb{E}[Y]$	Esperanza (valor medio) de Y
$\text{Var}(Y)$	Varianza de Y : $\mathbb{E}[(Y - \mu)^2]$
$\mathbf{1}$	Función constante $\mathbf{1}(\omega) = 1$ para todo ω
SC_{inter}	Suma de cuadrados entre bloques (variabilidad explicada)
SC_{intra}	Suma de cuadrados dentro de bloques (variabilidad residual)
ε vs e	Errores verdaderos (Gauss) vs residuos OLS (proyección): $e = (I - P)\varepsilon$

Tabla 3: Resultados clave y Teoremas

Teorema/Resultado	Enunciado
Definición de Proyección	Px minimiza $\ x - y\ $ sobre $M \iff (x - Px) \perp M$
Propiedades de P	Lineal, idempotente ($P^2 = P$), autoadjunto, contracción
Esperanza = Proyección	$E[X \mid \mathcal{G}] = P_M X$, único $\sigma(\mathcal{G})$ -medible minimizador en L^2
Insesgamiento	$\mathbb{E}[Y - E(Y \mid \sigma(X))] = 0$ (como $\mathbf{1} \in \sigma(X)$)
Ortogonalidad del residuo	$Y - E(Y \mid \sigma(X)) \perp \sigma(X)$ (Teorema de la Proyección)
Esperanza total	$\mathbb{E}[E(Y \mid \sigma(X))] = \mathbb{E}[Y]$ (ley de la esperanza total)
Teorema de Pitágoras	$\ Y\ ^2 = \ \hat{Y}\ ^2 + \ Y - \hat{Y}\ ^2$
ANOVA / Descomposición	$\text{Var}(Y) = \text{Var}(\hat{Y}) + \mathbb{E}[\text{Var}(Y \mid \sigma(X))]$
Relación R^2 vs r_n^2	$R^2 \leq r_n^2$, iguales sii $\mathbb{E}[Y] = 0$ o $Y = \hat{Y}$ c.s.
Suma de proyecciones	$P_{M \oplus N} = P_M + P_N$ solo si $M \perp N$ (falla sin ortogonalidad)
Frisch-Waugh-Lovell	Regresión parcial: coeficiente de X_2 en M_2 = regresión de residuo de Y sobre residuo de X_2
Coherencia jerárquica	Particiones anidadas: $\sigma(D) \subseteq \sigma(L) \subseteq \sigma(M)$ (Distrito $\subseteq$ Local $\subseteq$ Mesa)
Falacia ecológica	Atribuir efecto agregado al nivel individual falla (Robinson, 1950)
Paradoja de Simpson	Dirección de correlación puede invertirse entre nivel agregado e individual
Primalidad y independencia	Con $n = 13$ primo, dos variables no triviales no pueden ser independientes
Igualdad del paralelogramo	$\ x + y\ ^2 + \ x - y\ ^2 = 2(\ x\ ^2 + \ y\ ^2)$ caracteriza espacios de Hilbert
Estimador MCO	$\hat{\beta} = (X^\top X)^{-1} X^\top y$ es BLUE bajo homocedasticidad
Ecuaciones normales	$X^\top e = 0 \Rightarrow$ residuos ortogonales a regresores

Teorema/Resultado	Enunciado
Errores vs residuos	ε (verdaderos, primitivos) $\neq e = (I - P)\varepsilon$ (residuos, derivados)